Resumen del paper: *Gradient-Based Learning Applied to Document Recognition*

LeCun, Bottou, Bengio & Haffner (1998) — *Proceedings of the IEEE*

Resumen preparado para el curso de Redes Neuronales y Aprendizaje Profundo

Universidad Nacional de Ingeniería — Unidad de Posgrado

En una frase: el paper demuestra que redes neuronales entrenadas de punta a punta con *backpropagation* — en particular la arquitectura convolucional **LeNet-5** — superan a los métodos de reconocimiento de patrones diseñados a mano, y extiende esa misma idea de aprendizaje basado en gradientes a sistemas completos de reconocimiento de documentos mediante las **Graph Transformer Networks (GTN)**, con un lector de cheques bancarios desplegado comercialmente.

1. Introducción y motivación

Durante décadas, los sistemas de reconocimiento de patrones se construían en dos etapas separadas: un *extractor de características* diseñado a mano por un experto, seguido de un *clasificador* entrenable (a menudo un clasificador lineal simple). Los autores argumentan que esta división es subóptima porque la precisión del sistema depende, sobre todo, de la calidad del extractor de características hecho a mano — algo difícil de obtener y de adaptar a nuevas tareas.

La propuesta central del paper es que, si la arquitectura de la red se diseña adecuadamente, el **aprendizaje basado en gradientes** puede entrenar directamente sistemas complejos de extracción de características y clasificación de manera conjunta, a partir de datos crudos (píxeles) y con un mínimo de preprocesamiento manual.

2. Redes Neuronales Convolucionales

El paper identifica dos limitaciones de los perceptrones multicapa completamente conectados aplicados a imágenes:

1. Una imagen es de alta dimensión, por lo que una red completamente conectada requiere una enorme cantidad de datos de entrenamiento para cubrir el espacio de variaciones posibles.
2. Una red completamente conectada ignora por completo la topología espacial de la entrada: el orden de los píxeles podría permutarse sin afectar el entrenamiento, a pesar de que las imágenes tienen una fuerte estructura local 2D.

Las **Redes Neuronales Convolucionales** resuelven ambos problemas combinando tres ideas arquitectónicas:

- **Campos receptivos locales:** cada unidad recibe información de solo una pequeña región de la capa anterior (por ejemplo 5×5), en lugar de la imagen completa.
- **Pesos compartidos:** todas las unidades de un mismo *mapa de características* (*feature map*) usan el mismo conjunto de pesos, por lo que detectan la misma característica en distintas posiciones de la imagen. Esto reduce drásticamente el número de parámetros libres y hace que la detección de una característica sea invariante a traslaciones.

- **Sub-muestreo espacial (*sub-sampling*):** capas que reducen la resolución de los mapas de características, disminuyendo la sensibilidad a pequeños desplazamientos y distorsiones, y permitiendo que las capas siguientes detecten características de mayor nivel sobre una región progresivamente más amplia de la entrada.

En la implementación descrita en el paper, cada capa de sub-muestreo no es un simple promedio fijo: cada unidad suma sus 4 entradas (un área de 2×2), las multiplica por un **coeficiente entrenable**, les suma un **sesgo entrenable**, y pasa el resultado por una función sigmoide — es decir, el *pooling* original de LeNet-5 tiene parámetros propios, a diferencia del *max-pooling* sin parámetros que se usa en la mayoría de implementaciones modernas.

3. Arquitectura de LeNet-5

LeNet-5 es la arquitectura convolucional central del paper, usada para reconocer dígitos manuscritos. Recibe una imagen de **32×32** píxeles (deliberadamente más grande que los caracteres de 20×20 de la base de datos, para que rasgos distintivos como puntas de trazo o esquinas puedan caer en el centro del campo receptivo de las capas más profundas) y la procesa a través de **7 capas con parámetros entrenables**:

Capa	Tipo	Tamaño de salida	Parámetros	Conexiones
C1	Convolución (6 filtros 5×5)	6 @ 28×28	156	122,304
S2	Sub-muestreo (2×2)	6 @ 14×14	12	5,880
C3	Convolución (16 filtros 5×5, conexión parcial)	16 @ 10×10	1,516	151,600
S4	Sub-muestreo (2×2)	16 @ 5×5	32	2,000
C5	Convolución (equivalente a densa)	120	48,120	48,120
F6	Totalmente conectada	84	10,164	10,164
Salida	Unidades RBF (Radial Basis Function)	10	—	—

Total: aproximadamente 60,000 parámetros entrenables y 340,908 conexiones. La gran diferencia entre ambas cifras es precisamente el efecto de compartir pesos: sin ese mecanismo, la red necesitaría un parámetro por cada conexión.

Detalles que distinguen a LeNet-5 de una CNN moderna típica:

- **C3 usa conexión parcial, no completa:** cada uno de los 16 mapas de C3 se conecta solo a un subconjunto de los 6 mapas de S2 (definido en una tabla de conexión), no a todos. Esto rompe la simetría entre mapas de características (forzándolos a aprender características complementarias) y mantiene acotado el número de conexiones.
- **Función de activación:** una tangente hiperbólica escalada, $f(a) = A\tanh(Sa)$, con $A = 1.7159$, en lugar de la ReLU usada hoy en día.
- **Capa de salida:** unidades de **Radial Basis Function (RBF)**, una por clase, con vectores de parámetros fijos que codifican un mapa de bits estilizado del dígito correspondiente (en vez de una capa softmax entrenada de forma convencional).

4. Entrenamiento

La red completa se entrena de punta a punta con **backpropagation** mediante **descenso de gradiente estocástico** (actualización tras cada patrón, no por lotes completos), lo cual

los autores justifican como más rápido y con mejores propiedades de generalización que el descenso de gradiente por lotes, especialmente en conjuntos de datos redundantes como el de dígitos manuscritos. El paper también discute métodos de segundo orden (aproximaciones a Newton/Levenberg-Marquardt) para acelerar la convergencia, y observa que el *weight sharing* de las capas convolucionales requiere sumar los gradientes de todas las conexiones que comparten un mismo parámetro.

5. Resultados: comparación de clasificadores en MNIST

El paper compara sistemáticamente muchos clasificadores sobre la misma base de datos de dígitos manuscritos (precursora de MNIST), incluyendo clasificadores lineales, K-vecinos más cercanos, PCA + clasificador cuadrático, redes de funciones de base radial (RBF), máquinas de vectores de soporte (SVM) y varias variantes de LeNet. Una selección de los resultados reportados (tasa de error sobre el conjunto de prueba):

Método	**Error en test (%)**
Clasificador lineal	12.0
K-NN euclidiano	5.0
40 PCA + clasificador cuadrático	3.3
1000 RBF + lineal	3.6
SVM polinomial (grado 4)	1.1
Distancia tangente (16×16)	1.1
LeNet-1	1.7
LeNet-4	1.1
LeNet-5	**0.95**
LeNet-5 (con distorsiones artificiales en entrenamiento)	0.8
Boosted LeNet-4 (con distorsiones)	**0.7**

Boosted LeNet-4 (una combinación de tres LeNet-4 entrenadas con *boosting*) obtiene el mejor resultado del estudio, 0.7% de error, al costo de aproximadamente 1.75 veces el cómputo de una sola red (no 3 veces, porque cuando la primera red ya responde con alta confianza, no se invocan las demás). Un hallazgo consistente en todo el paper: las redes convolucionales dominan sistemáticamente a los métodos que operan sobre los píxeles crudos sin estructura convolucional, y aumentar artificialmente los datos de entrenamiento con distorsiones (traslaciones, rotaciones, escalados) mejora el desempeño de forma consistente.

6. Graph Transformer Networks y lectura de cheques bancarios

La segunda mitad del paper generaliza la idea de *aprendizaje basado en gradientes* más allá de una sola red con entrada de tamaño fijo. Un sistema real de reconocimiento de documentos (por ejemplo, leer el monto de un cheque bancario) involucra múltiples módulos encadenados: localización de campos, segmentación de caracteres, reconocimiento, y un modelo de lenguaje/gramática que valida la interpretación final. Tradicionalmente, cada módulo se diseñaba y optimizaba por separado, con reglas heurísticas hechas a mano.

Los autores proponen las **Graph Transformer Networks (GTN)**: en lugar de que cada módulo produzca un único vector, cada módulo produce (y consume) un **grafo** cuyos arcos llevan vectores numéricos y puntajes. El sistema completo se entrena **globalmente** minimizando una única función de pérdida de principio a fin, propagando gradientes a través de todos los módulos (incluida la etapa de segmentación, mediante *Heuristic Over-Segmentation*: generar muchas

hipótesis de segmentación en paralelo en lugar de decidir una segmentación única y definitiva de forma temprana).

Este marco se aplica a un **lector de cheques bancarios** desplegado comercialmente (con reconocedores de caracteres basados en LeNet-5 dentro de la arquitectura GTN), que para la fecha de publicación ya operaba en varios bancos de EE. UU. desde junio de 1996, leyendo varios millones de cheques por día.

7. Conclusiones principales del paper

1. Las Redes Neuronales Convolucionales eliminan la necesidad de extractores de características diseñados a mano; las características se aprenden directamente de los ejemplos.
2. La segmentación y el reconocimiento no pueden desacoplarse por completo: es mejor generar y evaluar muchas hipótesis de segmentación en paralelo que comprometerse temprano con una única segmentación.
3. Entrenar sistemas multi-módulo con una medida de desempeño global (en lugar de etiquetar y entrenar cada módulo por separado) produce mejor desempeño y evita el costoso etiquetado manual de caracteres segmentados.
4. Las ambigüedades de segmentación, reconocimiento y modelo de lenguaje pueden integrarse de forma óptima mediante métodos de transducción generalizada sobre grafos de hipótesis ponderadas, en lugar de heurísticas específicas de cada tarea.
5. El aprendizaje basado en gradientes, aplicado a funciones de pérdida discriminativas globales, no depende de supuestos generativos difíciles de justificar (como los de un HMM con máxima verosimilitud) y garantiza una clasificación/rechazo óptimos bajo un marco mucho más simple.

El paper cierra señalando que el mismo principio —sistemas cuya arquitectura funcional puede representarse como grafos, entrenados de punta a punta por descenso de gradiente— es aplicable en principio a muchas otras tareas de reconocimiento de audio y de escenas visuales, más allá del reconocimiento de documentos.

Referencia completa: LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.