Redes Neuronales y Aprendizaje Profundo

Yolo

Ph.D. Aldo Camargo [1]

[1]Founder / CEO Knotenloserin
acamargofb@knotenloserin.com
aldo.camargo@gmail.com
www.knotenloserin.com

Tabla de Contenido

1. Introducción
2. Yolo
   - Entrenamiento
   - Aplicación práctica : Caso de Uso
3. Conclusiones
4. Preguntas

Tabla de Contenido

1. Introducción
2. Yolo
   - Entrenamiento
   - Aplicación práctica : Caso de Uso
3. Conclusiones
4. Preguntas

Introducción

Yolo es una arquitectura para detección de objetos en una imágen y video. Yolo significa: You Onnly Learn Once, que simplifica el aporte de Yolo, que es que usa una simple red neuronal que predice los bounding boxes y las probabilidades de cada clase directamente de las imágenes en una evaluación. Puede llegar a 45 fps. Yolo es mejor que otras arquitecturas de detección de objetos como DPM, y R-CNN.

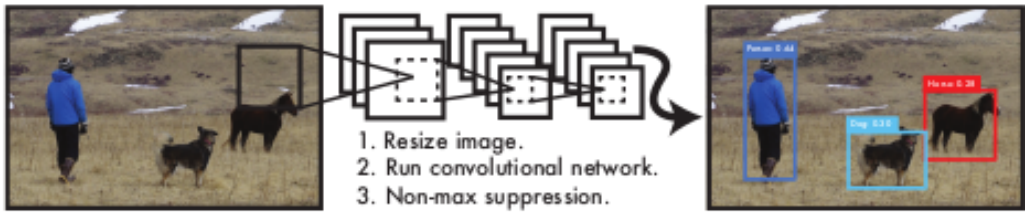


Figure 1: The YOLO Detection System. Processing images with YOLO is simple and straightforward. Our system (1) resizes the input image to 448×448, (2) runs a single convolutional network on the image, and (3) thresholds the resulting detections by the model's confidence.

Introducción

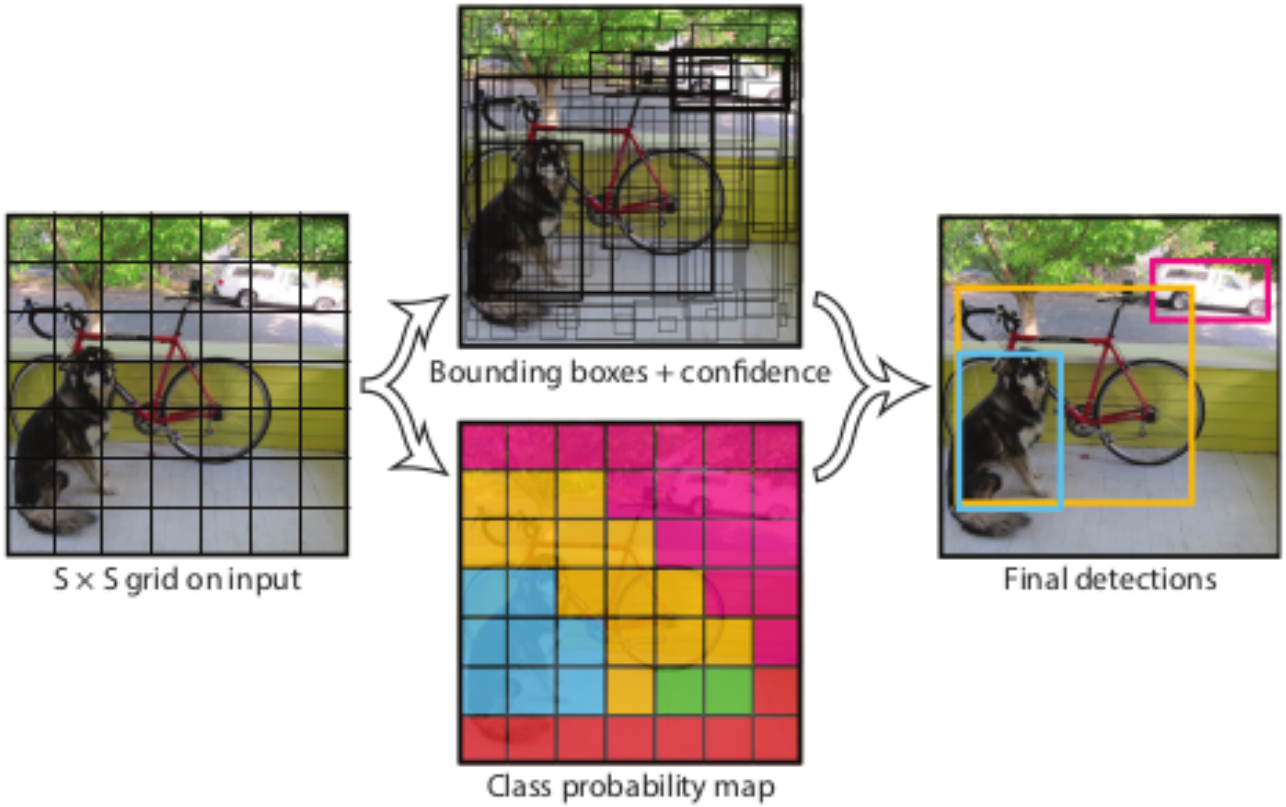


Figure 2: The Model. Our system models detection as a regression problem. It divides the image into an $S \times S$ grid and for each grid cell predicts B bounding boxes, confidence for those boxes, and C class probabilities. These predictions are encoded as an $S \times S \times (B * 5 + C)$ tensor.

Tabla de Contenido

1. Introducción
2. Yolo
   - Entrenamiento
   - Aplicación práctica : Caso de Uso
3. Conclusiones
4. Preguntas

Yolo

Yolo ve el problema como una regresión, que es lo que lo hace rápido. Yolo es eficiente en términos de velocidad y precisión. Yolo solo mira a la imágen una sola vez. La imágen es dividida en SxS grids, basado en eso produce: 1) Bounding boxes + confidence; 2) Mapa de clases de probabilidades. De estos dos se produce la decisión final.
Cada bounding box consiste de 5 predicciones: x, y, w, h, y confidence. La coordenada (x,y) representa el centro del bounding box relativo a los bordes del grid cell. El ancho y alto son predichos relativos a toda la imágen. Finalmente la predicción de la confidencia representa la IoU entre el box predicho y el box real. Cada grid cell también predice C condicional clases de probabilidades Pr(Classi —Object). Estas probabilidades son condicionadas en la grid cell conteniendo un objeto.

Yolo

Yolo solo produce una clase de probabilidades por grid cell, no importando el número de boxes B.
Cuando se hace la prueba, se multiplica la probabilidad condicional de la clase y la predicción individual de la box confidence.

$$\Pr(\text{Class}_i|\text{Object}) * \Pr(\text{Object}) * \text{IOU}_{\text{pred}}^{\text{truth}} = \Pr(\text{Class}_i) * \text{IOU}_{\text{pred}}^{\text{truth}} \quad (1)$$

Que nos da class-specific confidence scores para cada box. Estos scores encode las probabilidades de estas clases que aparece en los boxes y que tan bien los boxes predichos encajan en el objeto.

Yolo arquitectura

La arquitectura consiste en lo siguiente:

- S = 7.
- B = 2.
- Número de clases C = 20.
- Predicción final es 7x7x30
- GoogleNet para la clasificación de las imágenes.

Yolo arquitectura

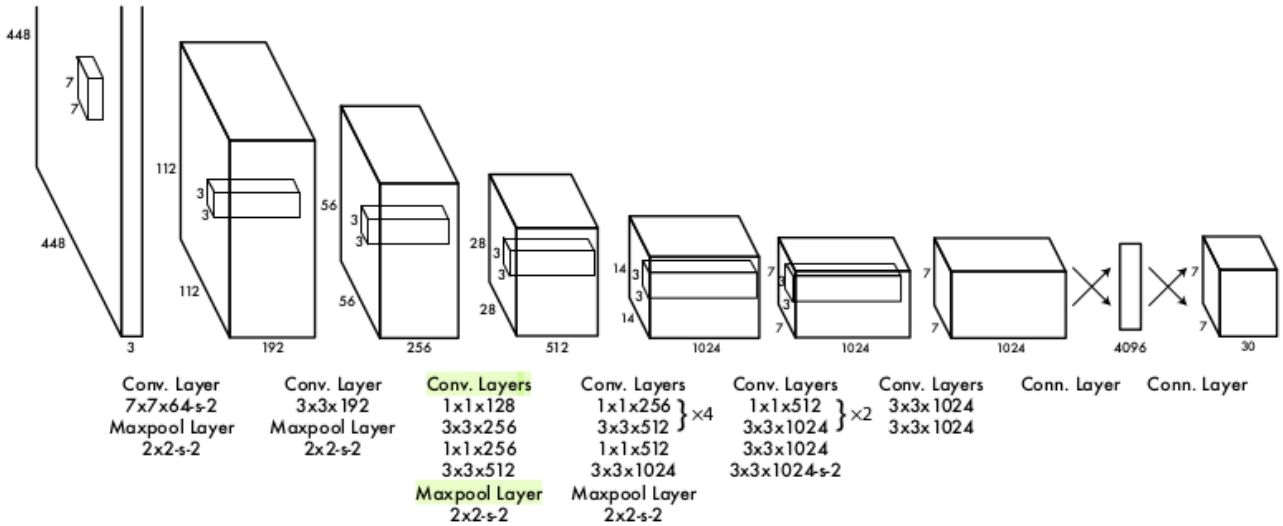


Figure 3: The Architecture. Our detection network has 24 convolutional layers followed by 2 fully connected layers. Alternating 1×1 convolutional layers reduce the features space from preceding layers. We pretrain the convolutional layers on the ImageNet classification task at half the resolution (224×224 input image) and then double the resolution for detection.

Yolo entrenamiento

El entrenamiento considera lo siguiente:

- Se entrenó con ImageNet de 1000 clases.
- Pretraining se usó los primeras 20 capas convolucionales de Figura 3 seguido por un average-pooling y una capa FC.
- Luego se convierte el modelo para hacer la detección.
- Luego se añadió 4 capas convolucionales y 2 FC con los pesos inicializados aleatoriamente.
- Los bounding boxes entre 0 y 1.

Yolo entrenamiento

loss function:

$$
\begin{aligned}
&\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\
&+ \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\
&+ \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left(C_i - \hat{C}_i \right)^2 \\
&+ \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{noobj}} \left(C_i - \hat{C}_i \right)^2 \\
&+ \sum_{i=0}^{S^2} \mathbb{1}_{i}^{\text{obj}} \sum_{c \in \text{classes}} \left(p_i(c) - \hat{p}_i(c) \right)^2 \qquad (3)
\end{aligned}
$$

where $\mathbb{1}_i^{\text{obj}}$ denotes if object appears in cell i and $\mathbb{1}_{ij}^{\text{obj}}$ denotes that the jth bounding box predictor in cell i is "responsible" for that prediction.

Aplicación práctica : Caso de Uso

Revisar el código de Yolo y ejecutar, probarlo con su propia data.

Tabla de Contenido

1. Introducción
2. Yolo
   - Entrenamiento
   - Aplicación práctica : Caso de Uso
3. Conclusiones
4. Preguntas

Conclusiones

- Hemos visto un nuevo tipo de arquitectura que permite hacer la detección y seguimiento de objetos.
- Las aplicaciones son diversas en diversos campos de la ciencia, ingeniería y medicina.
- Esta arquitectura sigue en uso en muchas aplicaciones industriales.
- Esta arquitectura evoluciona cada año, actualmente la última versión es las 11.

.

Tabla de Contenido

1. Introducción
2. Yolo
   - Entrenamiento
   - Aplicación práctica : Caso de Uso
3. Conclusiones
4. Preguntas

Preguntas

Si tienen alguna pregunta de la arquitectura o del código por favor háganlo sin dudar.