Grupo 3 · Guion de sustentación

Reconocimiento de 40 platos peruanos con transferencia de aprendizaje: ResNet-18 frente a YOLO26m-cls

MIA-203 · Redes Neuronales y Aprendizaje Profundo
Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería

25:00 de exposición + 5:00 de defensa

Este es un guion hablado con tiempos planificados. No acredita ensayo humano ni duración oral observada. Las pausas, lectura de figuras y transiciones caben en cada tramo. El equipo debe ensayar con cronómetro y ajustar el ritmo sin agregar resultados. A 25:00 termina la exposición, aunque quede texto por decir.

Distribución de bloques

Bloque	Tramo	Duración
Problema y aportes	00:00–03:00	3:00
Relacionados y fundamento	03:00–06:00	3:00
Datos y métodos	06:00–12:00	6:00
Resultados	12:00–19:00	7:00
Límites e impacto	19:00–23:00	4:00
Conclusiones	23:00–25:00	2:00
Defensa	25:00–30:00	5:00

Uso del guion

Cada página de diapositiva contiene texto hablado, una indicación para explicar el visual y la transición. El texto sirve como base de preparación, no como lectura obligatoria. Los cinco integrantes deben conocer todas las etapas. La defensa propuesta asigna una pregunta por minuto, sujeta a lo que pregunte el jurado.

Índice de exposición y responsables

N.º	Diapositiva	Expone	Tramo	Duración
1	Reconocimiento de 40 platos peruanos	Josué	00:00–00:30	00:30
2	Una foto propone un plato y abre una consulta	Josué	00:30–03:00	02:30
3	Antecedentes y aporte del grupo	Miguel	03:00–04:30	01:30
4	Dos redes, dos alcances de transferencia	Miguel	04:30–06:00	01:30
5	PeruFoodNet: balance no equivale a diversidad	Josué	06:00–08:00	02:00
6	Partición por nombre y presupuestos reales	Enzo	08:00–09:00	01:00
7	De la imagen a cuarenta logits	Miguel	09:00–10:15	01:15
8	Entrenamiento y parada temprana	Miguel	10:15–11:00	00:45
9	Selección: 16 + 16 = 32 corridas	Enzo	11:00–12:00	01:00
10	La ablación favorece adaptar el extractor	Enzo	12:00–13:30	01:30
11	Selección con tres semillas: diferencia pequeña	Enzo	13:30–15:00	01:30
12	Más fotos acompañan mejores medias	Omar	15:00–16:00	01:00
13	Prueba reservada: 543 aciertos de 600	Omar	16:00–17:00	01:00
14	Confusiones: cuatro pares empatados	Omar	17:00–17:30	00:30
15	Un error cambia la ficha de receta	Alexander	17:30–19:00	01:30
16	La unidad independiente debería ser la ración	Omar	19:00–20:30	01:30
17	Costo medido y alcance de la latencia	Alexander	20:30–22:00	01:30
18	Ejemplo local y uso responsable	Omar	22:00–23:00	01:00
19	Conclusiones y siguiente validación	Alexander	23:00–24:00	01:00
20	Qué defender y cómo comprobarlo	Alexander	24:00–25:00	01:00

Participación planificada: 5:00 por integrante

Josué Chilón Cruzado: diapositivas 1, 2, 5. Total 5:00.

Miguel Ángel Concepción Tiza: diapositivas 3, 4, 7, 8. Total 5:00.

Enzo Israel Neyra Dianderas: diapositivas 6, 9, 10, 11. Total 5:00.

Omar Salvador Tello Guerra: diapositivas 12, 13, 14, 16, 18. Total 5:00.

Alexander Vladimir Paco Cornejo: diapositivas 15, 17, 19, 20. Total 5:00.

01 · Reconocimiento de 40 platos peruanos

Josué Chilón Cruzado
Problema y aportes · 00:00–00:30 · duración 00:30

Plan de ritmo: 62 palabras habladas, incluida la transición. Promedio bruto 124 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Buenos días. Somos el Grupo 3 de la Maestría en Inteligencia Artificial de la UNI. Comparamos ResNet-18 y YOLO26m-cls para reconocer cuarenta platos peruanos con pocos ejemplos. Presentaremos qué cambia al adaptar toda la red, cómo elegimos el modelo y por qué una buena clasificación todavía exige límites de uso.

Figura y control de tiempo

Presentar al grupo y señalar la fotografía como ejemplo del dominio, sin atribuirle una predicción.

Transición incluida en el tramo

Comencemos por la decisión que sí puede apoyar una fotografía.

02 · Una foto propone un plato y abre una consulta

Josué Chilón Cruzado
Problema y aportes · 00:30–03:00 · duración 02:30

Plan de ritmo: 248 palabras habladas, incluida la transición. Promedio bruto 99 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Nuestro sistema recibe una fotografía y propone una etiqueta entre cuarenta platos. Después consulta una ficha de posibles ingredientes asociada al nombre. Pensemos en una persona que quiere preguntar al restaurante por una receta: reconocer el plato puede ordenar esa conversación, pero la imagen no garantiza cuáles ingredientes contiene la preparación concreta. La ficha es una consulta documental y depende del nombre que produjo el clasificador.

La dificultad visual aparece porque un mismo plato cambia de presentación, ángulo, porción y acompañamiento. A la vez, platos distintos pueden compartir color y textura. Elegimos redes convolucionales porque reutilizan filtros espaciales y pueden adaptar representaciones preentrenadas con pocos ejemplos. Nuestro interés no es crear un bloque neuronal nuevo, sino medir una adaptación útil en un contexto peruano.

La pregunta experimental tiene tres factores principales: qué familia de red usamos, cuántas imágenes aportamos por clase y cuánto de la red permitimos modificar. Contrastamos diez frente a cuarenta imágenes, y capa final frente a red completa. El aporte propio comprende una comparación reproducible, una ablación controlada y un análisis de errores con consecuencias para la ficha documental.

En la figura, sigan primero la foto y luego el nombre. El último vínculo ya no pertenece a la red: es una búsqueda por etiqueta. Esa frontera será importante cuando veamos un ají de gallina reconocido como locro. La evaluación cuantitativa se refiere al reconocimiento del plato. No evaluamos detección de ingredientes, diagnóstico ni seguridad alimentaria.

Figura y control de tiempo

Recorrer foto, clasificador, nombre y receta durante 8 s. Explicar la frontera entre predicción aprendida y consulta documental.

Transición incluida en el tramo

Miguel explicará los antecedentes y el fundamento de esta adaptación.

03 · Antecedentes y aporte del grupo

Miguel Ángel Concepción Tiza
Relacionados y fundamento · 03:00–04:30 · duración 01:30

Plan de ritmo: 174 palabras habladas, incluida la transición. Promedio bruto 116 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Food-101 aporta un antecedente de reconocimiento visual de comida. Lo usamos para situar el problema, sin comparar sus cifras con las nuestras, porque cambian las clases, las imágenes y el protocolo. PeruFoodNet aporta las fotografías peruanas y las tablas de posibles ingredientes. Esas dos fuentes pertenecen a sus autores, no son una creación del equipo.

En el fundamento de las redes, ResNet introduce conexiones residuales que permiten aprender una corrección sobre una representación. Los estudios de transferencia explican por qué conviene contrastar características congeladas y características adaptables. YOLO26 ofrece una variante de clasificación: aquí usamos esa variante, no detección de objetos.

Nuestra diferencia frente a reutilizar un notebook es la matriz de treinta y dos corridas, los presupuestos anidados, la selección sin consultar prueba y el análisis de errores guardado por fotografía. No combinamos ambas redes en un ensamble. Las comparamos bajo decisiones compartidas. Tampoco trasladamos automáticamente las técnicas del entrenamiento original de YOLO a nuestro entrenamiento: en las dos familias empleamos AdamW y entropía cruzada.

Figura y control de tiempo

Relacionar cada antecedente con su función. No leer la lista de referencias ni citar resultados externos como comparables.

Transición incluida en el tramo

Ahora veamos qué aprende exactamente cada alternativa.

04 · Dos redes, dos alcances de transferencia

Miguel Ángel Concepción Tiza
Relacionados y fundamento · 04:30–06:00 · duración 01:30

Plan de ritmo: 175 palabras habladas, incluida la transición. Promedio bruto 117 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Una red convolucional transforma la imagen mediante filtros compartidos. Capas sucesivas combinan patrones locales en una representación que alimenta al clasificador. No afirmamos que un filtro concreto detecte un ingrediente: no hemos medido esa interpretación causal.

ResNet-18 reutiliza pesos de ImageNet y una arquitectura con conexiones residuales. El esquema muestra la idea de sumar la entrada a una transformación aprendida, lo que facilita la optimización. YOLO26m-cls también parte de pesos preentrenados, pero usamos exclusivamente su salida de clasificación. En ambas redes sustituimos la última capa lineal por cuarenta salidas.

En capa final congelamos el extractor, incluidos sus parámetros y estadísticas de BatchNorm. Solo aprendemos la última transformación lineal. Esa es nuestra adaptación más simple y la línea base principal es ResNet-18 de capa final. En red completa dejamos que el extractor también cambie. Así preguntamos si las representaciones iniciales separan suficientemente los platos o si adaptarlas mejora la decisión. El contraste debe medirse manteniendo las otras condiciones, como veremos en la ablación.

Figura y control de tiempo

Señalar qué parte queda fija y qué parte cambia. Dar 6 s al esquema residual, sin presentar una arquitectura detallada de YOLO que no mostramos.

Transición incluida en el tramo

Josué presentará la evidencia visual y la composición del conjunto.

05 · PeruFoodNet: balance no equivale a diversidad

Josué Chilón Cruzado
Datos y métodos · 06:00–08:00 · duración 02:00

Plan de ritmo: 229 palabras habladas, incluida la transición. Promedio bruto 114 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

PeruFoodNet versión tres contiene cuatro mil fotografías, distribuidas en cuarenta platos con cien imágenes por clase. La carpeta determina la etiqueta. Conservamos todas las clases y documentamos el manifiesto y el orden de etiquetas. La fuente es Mendeley Data y la licencia de las fotografías es Creative Commons Atribución cuatro punto cero.

Miren estas dos imágenes de ají de gallina, ambas del entrenamiento elegible. El objetivo es mostrar la variación de presentación dentro de una misma clase. Las diferencias de encuadre y acompañamiento ilustran el desafío visual. Esta pareja no demuestra independencia entre fotografías ni permite conocer cuántas raciones distintas hay en el dataset.

El balance numérico evita que unas clases tengan más fotografías que otras, pero no certifica diversidad de restaurantes, dispositivos o recetas. El artículo de origen describe cambios de presentación, ángulo y condiciones de captura. Aun así, no contamos con un identificador de ración que permita agrupar vistas de la misma preparación.

Por eso distinguimos un hecho comprobado de una inferencia: comprobamos cantidades, rutas y etiquetas. La posible correlación entre tomas es un riesgo del protocolo, no una fuga demostrada imagen por imagen. Tampoco podemos afirmar su ausencia. Nuestra evaluación caracteriza esta partición de fotografías y no representa por sí sola nuevas raciones o restaurantes. Esta limitación acompaña las cifras durante toda la exposición.

Figura y control de tiempo

Comparar las fotos 01 y 40 durante 10 s. Señalar diferencias visibles sin inventar ingredientes, lugares ni identidades de ración.

Transición incluida en el tramo

Enzo mostrará cómo se asignaron los nombres de archivo a cada conjunto.

06 · Partición por nombre y presupuestos reales

Enzo Israel Neyra Dianderas
Datos y métodos · 08:00–09:00 · duración 01:00

Plan de ritmo: 111 palabras habladas, incluida la transición. Promedio bruto 111 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

El reparto depende del número inicial del archivo dentro de cada clase. Del uno al setenta queda entrenamiento elegible. Del setenta y uno al ochenta y cinco queda prueba. Del ochenta y seis al cien queda validación. El orden de prueba y validación es importante para reproducirlo.

Aunque existen dos mil ochocientas imágenes elegibles, las corridas usan cuatrocientas o mil seiscientas: diez o cuarenta por clase. El subconjunto uno a diez está incluido en uno a cuarenta. Validación selecciona y prueba se reserva. Separar nombres impide repetir el mismo archivo, pero no impide compartir vistas correlacionadas de una ración.

Figura y control de tiempo

Recorrer la barra 70/15/15 y después los subconjuntos 10/40. Pausa de 5 s para distinguir elegibilidad de uso efectivo.

Transición incluida en el tramo

Miguel continuará con el cálculo que transforma cada imagen en cuarenta puntuaciones.

07 · De la imagen a cuarenta logits

Miguel Ángel Concepción Tiza
Datos y métodos · 09:00–10:15 · duración 01:15

Plan de ritmo: 144 palabras habladas, incluida la transición. Promedio bruto 115 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

La entrada es una imagen RGB redimensionada directamente a doscientos veinticuatro por doscientos veinticuatro. Esa operación puede deformar la proporción original. Durante entrenamiento aplicamos volteo horizontal aleatorio. ResNet usa además la normalización de ImageNet y YOLO conserva los canales entre cero y uno. La geometría es comparable y la normalización respeta la familia.

El extractor produce una representación h. La capa lineal calcula z igual a W por h más b. Esos cuarenta valores son logits, uno por plato. Entropía cruzada recibe los logits y penaliza asignar poca puntuación a la clase correcta. No aplicamos softmax antes de esa pérdida.

Al predecir elegimos el logit mayor. Softmax permite reportar una puntuación operativa. F1 macro promedia el F1 de los cuarenta platos con el mismo peso por clase, mientras exactitud cuenta aciertos globales.

Figura y control de tiempo

Seguir las dimensiones y señalar que la receta queda fuera de la función aprendida. Reservar 5 s a la ecuación.

Transición incluida en el tramo

Con ese cálculo común, fijamos también la regla de optimización y parada.

08 · Entrenamiento y parada temprana

Miguel Ángel Concepción Tiza
Datos y métodos · 10:15–11:00 · duración 00:45

Plan de ritmo: 99 palabras habladas, incluida la transición. Promedio bruto 132 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Usamos AdamW con decaimiento de pesos cero coma cero uno, lote dieciséis y dos tasas constantes. No usamos un scheduler. El techo es doscientas épocas y la paciencia es diez épocas sin mejora estricta del F1 macro de validación. Un empate no reinicia la paciencia y conservamos el primer máximo.

Las treinta y dos corridas terminaron por parada temprana entre quince y noventa y seis épocas. Doscientas es el máximo permitido, no la duración real. Guardar el mejor checkpoint evita confundir la última época con la mejor.

Figura y control de tiempo

Señalar el techo y el rango observado como cantidades distintas. Pausa de 3 s.

Transición incluida en el tramo

Enzo distinguirá la búsqueda inicial y la repetición de las condiciones seleccionadas.

09 · Selección: 16 + 16 = 32 corridas

Enzo Israel Neyra Dianderas
Datos y métodos · 11:00–12:00 · duración 01:00

Plan de ritmo: 108 palabras habladas, incluida la transición. Promedio bruto 108 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Primero cruzamos dos familias, dos regímenes, dos presupuestos y dos tasas con semilla cuarenta y dos: dieciséis corridas. Elegimos una tasa para cada una de las ocho condiciones usando validación. Solo esas ocho condiciones se repiten con semillas cuarenta y tres y cuarenta y cuatro, otras dieciséis corridas.

La comparación final usa media y desviación muestral de tres semillas. Elegimos entre las condiciones de cuarenta fotos. Después fijamos el checkpoint de semilla cuarenta y dos, sin escoger la mejor semilla. Recién entonces evaluamos prueba. MLflow y los CSV conservan configuraciones, curvas, selección y predicciones para auditar esa secuencia.

Figura y control de tiempo

Señalar los dos grupos de 16 y la barrera antes de prueba durante 5 s.

Transición incluida en el tramo

La primera lectura de resultados mantiene tasa y semilla fijas.

10 · La ablación favorece adaptar el extractor

Enzo Israel Neyra Dianderas
Resultados · 12:00–13:30 · duración 01:30

Plan de ritmo: 181 palabras habladas, incluida la transición. Promedio bruto 121 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Este gráfico responde a una pregunta controlada: qué cambia al pasar de capa final a red completa. Conservamos familia, cuarenta fotos por clase, particiones, tasa cero coma cero cero cero uno y semilla cuarenta y dos. Cada línea une los dos regímenes de una misma familia.

En ResNet el F1 macro de validación pasa de cero coma siete cero dos siete a cero coma ocho ocho cero cuatro. En YOLO pasa de cero coma ocho tres cinco cinco a cero coma ocho ocho siete nueve. Conviene mirar el desplazamiento y no memorizar cuatro decimales: adaptar el extractor mejora el resultado de ambas redes en esta comparación.

Esta evidencia es compatible con que las representaciones iniciales necesiten adaptación al dominio, pero no identifica qué filtros explican la mejora. Tampoco es todavía el resumen de tres semillas. El archivo de ablación incluye ambas tasas y los dos presupuestos: el ajuste completo mejora en las ocho comparaciones a tasa fija. Aquí mostramos una pareja por familia para que la lectura sea clara.

Figura y control de tiempo

Seguir cada línea de izquierda a derecha durante 8 s. Explicar que es validación de una semilla, sin mezclarla con la siguiente diapositiva.

Transición incluida en el tramo

Ahora cambiamos de pregunta: cuál configuración tiene mayor media tras seleccionar tasas.

11 · Selección con tres semillas: diferencia pequeña

Enzo Israel Neyra Dianderas
Resultados · 13:30–15:00 · duración 01:30

Plan de ritmo: 186 palabras habladas, incluida la transición. Promedio bruto 124 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Ahora mostramos configuraciones de cuarenta fotos con sus tasas seleccionadas. Los puntos indican la media del mejor F1 de validación y las barras su desviación estándar muestral entre tres semillas. La línea base ResNet de capa final alcanza aproximadamente cero coma seis nueve nueve. Las dos redes completas quedan alrededor de cero coma ochenta y ocho y cero coma ochenta y nueve.

YOLO completo obtiene cero coma ocho nueve cero tres, más o menos cero coma cero cero siete seis. ResNet completo obtiene cero coma ocho ocho uno cero, más o menos cero coma cero uno cero tres. La diferencia de medias ronda nueve milésimas de F1. La regla preestablecida elige YOLO porque tiene la mayor media entre los candidatos de cuarenta fotos.

Eso no demuestra superioridad estadística. No realizamos una prueba de significancia ni repetimos particiones independientes. Las barras describen variación por semillas sobre la misma partición y la tasa se eligió con semilla cuarenta y dos. El desempate por latencia estaba previsto, pero no fue necesario. El ganador es local a este espacio experimental.

Figura y control de tiempo

Dar 7 s para comparar los puntos y barras. Decir desviación entre semillas, no intervalo de confianza.

Transición incluida en el tramo

Omar mostrará el efecto del presupuesto y la evaluación reservada.

12 · Más fotos acompañan mejores medias

Omar Salvador Tello Guerra
Resultados · 15:00–16:00 · duración 01:00

Plan de ritmo: 116 palabras habladas, incluida la transición. Promedio bruto 116 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Cada línea conecta diez y cuarenta fotos por clase para una misma familia y régimen. Las cuatro líneas suben: con este protocolo, ampliar de cuatrocientas a mil seiscientas fotografías acompaña mejores medias de validación.

Hay una precisión importante: en esta figura usamos las tasas seleccionadas para cada condición, por lo que algunas líneas también cambian de tasa. No es la ablación anterior, que sí mantenía la tasa fija. Los subconjuntos además se toman por nombre, no mediante múltiples muestras independientes de raciones. Por eso describimos la mejora observada y no una ley general de eficiencia de datos ni una garantía sobre nuevas fotografías.

Figura y control de tiempo

Recorrer dos líneas contrastantes durante 5 s, sin leer las ocho cifras. Ejes: fotos por clase y F1 macro de validación.

Transición incluida en el tramo

Con la selección cerrada, evaluamos una sola vez el checkpoint prefijado en prueba.

13 · Prueba reservada: 543 aciertos de 600

Omar Salvador Tello Guerra
Resultados · 16:00–17:00 · duración 01:00

Plan de ritmo: 120 palabras habladas, incluida la transición. Promedio bruto 120 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

El checkpoint oficial de YOLO completo, cuarenta fotos y semilla cuarenta y dos, acierta quinientas cuarenta y tres de seiscientas imágenes de prueba. Eso equivale a noventa coma cinco por ciento de exactitud y deja cincuenta y siete errores. El F1 macro es cero coma nueve cero cuatro tres.

Cincuenta predicciones tienen puntuación softmax máxima menor que cero coma cincuenta y quedan marcadas como inciertas. Todas permanecen en las métricas. No las eliminamos para mejorar el resultado. La puntuación no está calibrada como probabilidad de acierto ni valida detección de imágenes ajenas al dominio. Estas cifras describen este checkpoint y estas fotografías, no la media de tres pruebas.

Figura y control de tiempo

Señalar el denominador 600 y la inclusión de 50 inciertas. Pausa de 4 s.

Transición incluida en el tramo

Los errores agregados permiten ver dónde se concentra parte de la confusión.

14 · Confusiones: cuatro pares empatados

Omar Salvador Tello Guerra
Resultados · 17:00–17:30 · duración 00:30

Plan de ritmo: 69 palabras habladas, incluida la transición. Promedio bruto 138 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Cuatro pares comparten cinco errores cada uno. Mostramos la dirección real: por ejemplo, cinco chanfainitas se propusieron como cau cau y cinco humitas como tamales. No ocultamos los otros dos pares empatados. La dirección importa: sumar ambos sentidos sirve para ordenar pares, pero no significa que el error sea simétrico. Estos conteos no prueban por sí solos una causa visual.

Figura y control de tiempo

Señalar una dirección y luego el empate. No describir colores o texturas como causa comprobada.

Transición incluida en el tramo

Alexander explicará un error real y su efecto documental.

15 · Un error cambia la ficha de receta

Alexander Vladimir Paco Cornejo
Resultados · 17:30–19:00 · duración 01:30

Plan de ritmo: 177 palabras habladas, incluida la transición. Promedio bruto 118 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Esta fotografía de prueba tiene etiqueta ají de gallina. El modelo propone locro con puntuación cero coma tres cero cinco, por debajo del umbral de incertidumbre. Es el primer error del manifiesto cuyas uniones documentales de ingredientes difieren. No lo escogimos para representar todos los fallos.

Al consultar la ficha correcta, la unión de las columnas del estudio enumera apio, huevos, leche y frutos de cáscara. Al consultar locro aparecen huevos y leche. Por tanto, el error de nombre cambia la información disponible y omite apio y frutos de cáscara respecto de la ficha de ají de gallina.

Observen qué significa esa diferencia: comparamos listas de recetas publicadas. No hemos demostrado visualmente que esos ingredientes estén presentes en esta fotografía, y menos aún que una lista sin un ingrediente garantice su ausencia. La consecuencia práctica es pedir confirmación del plato, ingredientes y contacto cruzado al responsable de la preparación. El sistema puede orientar preguntas, pero no certificar que la comida sea segura para una persona.

Figura y control de tiempo

Observar la foto 5 s y comparar las dos fichas 5 s. No identificar ingredientes a partir de los píxeles.

Transición incluida en el tramo

Omar retomará el límite que más condiciona la interpretación de nuestras métricas.

16 · La unidad independiente debería ser la ración

Omar Salvador Tello Guerra
Límites e impacto · 19:00–20:30 · duración 01:30

Plan de ritmo: 180 palabras habladas, incluida la transición. Promedio bruto 120 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

La separación actual opera por archivo. Si una misma ración fue fotografiada desde varios ángulos, esos archivos podrían cruzar entrenamiento y prueba. El modelo podría reconocer detalles compartidos y obtener una métrica más alta que sobre una preparación nueva. El esquema representa ese riesgo de forma conceptual, no una coincidencia que hayamos verificado entre dos imágenes específicas.

No tenemos identificadores de ración para demostrar independencia. Podemos afirmar que los archivos están separados y que prueba no intervino en la selección. No podemos afirmar ausencia de fuga por contenido. Esa distinción es necesaria para defender el experimento con honestidad.

Una evaluación futura debería agrupar las vistas de una ración antes de dividir y reservar preparaciones o restaurantes externos. También habría que estudiar dispositivos, iluminación, deformación por redimensionamiento y platos fuera de las cuarenta etiquetas. El balance de cien fotos por clase no resuelve esos sesgos. Por ahora, las conclusiones se restringen a este reparto secuencial. Repetir semillas reduce una fuente de variación del entrenamiento, pero no crea datos independientes.

Figura y control de tiempo

Recorrer el esquema hipotético de una ración y varias vistas durante 7 s. Aclarar que el riesgo no está cuantificado.

Transición incluida en el tramo

Alexander explicará cuánto costó la campaña y qué significa la latencia reportada.

17 · Costo medido y alcance de la latencia

Alexander Vladimir Paco Cornejo
Límites e impacto · 20:30–22:00 · duración 01:30

Plan de ritmo: 191 palabras habladas, incluida la transición. Promedio bruto 127 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

La campaña se ejecutó localmente en una RTX cinco mil noventa con aproximadamente treinta y dos gigabytes. La matriz final tomó cincuenta y cinco minutos y cuarenta y tres segundos de reloj. La suma de duraciones registradas de las treinta y dos corridas es cincuenta y tres minutos y nueve segundos, unas cero coma ocho ocho seis horas de ejecución en el equipo con GPU.

Esa suma incluye preparación, entrenamiento, validación y parte del registro. No es ocupación continua de la GPU ni solo tiempo de kernels. Tampoco incluye exploraciones preliminares. No medimos electricidad, emisiones ni precio monetario, de modo que no asignamos un costo en soles o dólares.

La latencia de dos coma ochenta y siete milisegundos mide únicamente la red, con una entrada sintética de lote uno, treinta calentamientos y doscientas iteraciones en esa GPU. Excluye lectura y preprocesamiento. No acredita ese tiempo en un teléfono o CPU. La prueba completa tomó once coma cero tres segundos con carga y preparación, bajo otra definición. Mantener separados estos alcances evita convertir un benchmark del modelo en una promesa de aplicación.

Figura y control de tiempo

Contrastar tiempo de campaña y latencia solo modelo. Pausa de 6 s. No sumar medidas con alcances distintos.

Transición incluida en el tramo

Omar presentará el ejemplo local y su límite de uso.

18 · Ejemplo local y uso responsable

Omar Salvador Tello Guerra
Límites e impacto · 22:00–23:00 · duración 01:00

Plan de ritmo: 123 palabras habladas, incluida la transición. Promedio bruto 123 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

El notebook guardado ilustra una predicción local de aguadito con puntuación cero coma nueve nueve siete. Es un ejemplo ilustrativo individual y no una nueva medición del rendimiento. No ejecutamos una demostración en vivo durante estos veinticinco minutos. La evaluación que sustenta el resultado sigue siendo la de seiscientas fotografías.

La demostración carga pesos locales y muestra la clase, puntuación y ficha documental. La ejecución fue verificada en Windows con RTX cinco mil noventa. Colab está preparado, pero no se ejecutó ni se probaron descargas. El límite clínico es explícito: esta herramienta no diagnostica, no detecta alérgenos y no certifica ausencia de ingredientes o contacto cruzado. Su utilidad actual es orientar una consulta.

Figura y control de tiempo

Señalar ejemplo individual y luego el límite clínico. Mantener 4 s de observación de la foto.

Transición incluida en el tramo

Alexander cerrará con los hallazgos y la siguiente validación necesaria.

19 · Conclusiones y siguiente validación

Alexander Vladimir Paco Cornejo
Conclusiones · 23:00–24:00 · duración 01:00

Plan de ritmo: 141 palabras habladas, incluida la transición. Promedio bruto 141 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

Nuestro hallazgo más claro es que adaptar toda la red mejora el F1 frente a entrenar solo la capa final en las comparaciones controladas a tasa fija. Con las tasas seleccionadas, aumentar el presupuesto también acompaña mejores medias en las cuatro condiciones.

YOLO completo obtiene la mayor media de validación dentro del espacio evaluado y su checkpoint prefijado alcanza noventa coma cinco por ciento de exactitud en prueba. La pequeña diferencia frente a ResNet no permite afirmar superioridad estadística.

La prioridad siguiente es evaluar con separación por ración y fotografías externas. Después tendría sentido estudiar calibración, rechazo de entradas fuera del dominio y un ajuste gradual del extractor. Son propuestas futuras, no resultados ejecutados. Antes de ampliar el uso necesitamos evidencia de generalización y del tiempo completo de la aplicación.

Figura y control de tiempo

Vincular cada conclusión con su evidencia anterior. Pausa de 4 s antes de trabajo futuro.

Transición incluida en el tramo

Cerramos con una guía breve para interpretar y auditar la entrega.

20 · Qué defender y cómo comprobarlo

Alexander Vladimir Paco Cornejo
Conclusiones · 24:00–25:00 · duración 01:00

Plan de ritmo: 126 palabras habladas, incluida la transición. Promedio bruto 126 palabras/min; incorpora las pausas del visual. Es una estimación, no una medición oral.

Texto hablado

La entrega permite seguir una cadena comprobable: el manifiesto define las imágenes, los historiales y MLflow documentan las corridas, el archivo de selección fija la configuración y las predicciones permiten recalcular prueba. Los dos notebooks separan exploración y demostración. Las figuras provienen de los resultados guardados, sin repetir entrenamiento para construir esta presentación.

Si debemos resumir la contribución, es una comparación propia de transferencia con pocos datos y un análisis de cómo un error de clase modifica una consulta de receta. Si debemos resumir el límite, es que la partición por archivo puede compartir tomas correlacionadas y no acredita rendimiento externo ni seguridad clínica.

Gracias. Estamos disponibles los cinco para explicar cualquier etapa del proyecto. Abrimos los cinco minutos de preguntas.

Figura y control de tiempo

Señalar trazabilidad y límite como dos ideas finales. Reservar los últimos 5 s para cerrar a las 25:00.

Transición incluida en el tramo

Damos paso a sus preguntas.

Defensa · cinco minutos disponibles

Agenda de preparación, no simulación de una defensa realizada. El jurado dirige las preguntas y puede dirigirse a cualquiera. Si una respuesta necesita más tiempo, priorizar la pregunta real y ceder la palabra con una frase breve. No consumir tiempo leyendo las referencias.

Plan de cada minuto

10 s para escuchar la pregunta · 40 s para la respuesta central · 10 s para repregunta o transición. Cinco minutos, cinco responsables de referencia. Los demás pueden complementar sin duplicar la respuesta.

25:00–26:00 · Josué Chilón Cruzado

¿Cómo descartan fuga de datos?

Descartamos repetición del mismo archivo mediante el manifiesto y reservamos prueba fuera de selección. No descartamos fuga por contenido: podrían existir vistas de una misma ración en conjuntos distintos. No tenemos identificadores para verificarlo. Por eso limitamos las conclusiones a esta partición y proponemos una separación por ración y un conjunto externo.

Evidencia: data/manifest.csv; README, Datos; artículo, Discusión.

26:00–27:00 · Miguel Ángel Concepción Tiza

¿Qué demuestra la ablación y qué se congeló?

A igual familia, presupuesto, tasa y semilla, cambiar a ajuste completo mejora el F1 en ocho comparaciones. Capa final significa solo la última capa lineal entrenable, con parámetros y estadísticas de BatchNorm del extractor fijos. La ablación respalda utilidad del ajuste en estas condiciones, pero no prueba qué filtros causaron la mejora ni garantiza que ocurra con otros datos.

Evidencia: results/comparacion_misma_tasa.csv; src/models.py; artículo, III-B y IV-B.

Defensa · respuestas fundamentadas

27:00–28:00 · Enzo Israel Neyra Dianderas

¿Por qué 32 corridas y no 48? ¿YOLO es superior?

Hay dieciséis combinaciones iniciales con dos tasas y semilla 42. Después repetimos solo las ocho tasas elegidas con semillas 43 y 44: dieciséis más. Elegimos por media de validación entre presupuestos de 40 y fijamos semilla 42 antes de prueba. YOLO tiene la mayor media en este espacio, pero tres semillas en una partición no demuestran superioridad estadística.

Evidencia: results/matrix_index.json; results/resumen_validacion.csv; results/winner.json.

28:00–29:00 · Omar Salvador Tello Guerra

¿Las 50 inciertas se excluyeron? ¿0,305 es probabilidad de acierto?

Las 50 se incluyen en los 600 casos, los 543 aciertos y el F1 macro 0,9043. Incierta significa máximo softmax menor que 0,50. La puntuación no está calibrada como probabilidad de acierto. El error ají de gallina a locro tiene puntuación 0,305 y queda marcado, pero esa regla no valida un detector de platos desconocidos.

Evidencia: results/test/predicciones.csv; metricas.json; analisis_errores.json.

Defensa · respuestas fundamentadas

29:00–30:00 · Alexander Vladimir Paco Cornejo

¿Detectan alérgenos y cuánto demora una foto?

La red reconoce platos y después consulta una receta. No detecta ingredientes ni certifica ausencia o contacto cruzado. El ejemplo de ají de gallina cambia la lista documental, no demuestra presencia visual. Los 2,87 ms corresponden solo a la red en RTX 5090, sin lectura ni preprocesamiento. Falta medir el flujo completo y validar uso externo antes de hacer una promesa operativa.

Evidencia: data/ingredients.json, tablas 1-2 de la fuente; results/test/metricas.json.

Preparación cruzada

Responsabilidades reales confirmadas en el artículo

Josué Chilón Cruzado

Preparación y exploración de datos y verificación de partición.

Miguel Ángel Concepción Tiza

Modelos de transferencia y entrenamiento.

Enzo Israel Neyra Dianderas

Matriz experimental, seguimiento MLflow y selección por validación.

Omar Salvador Tello Guerra

Evaluación en prueba, análisis de errores y limitaciones.

Alexander Vladimir Paco Cornejo

Demostración, ficha de ingredientes y reproducción de resultados.

Preparación propuesta, pendiente de realizar

Ensayar una exposición completa con reloj visible. Registrar tiempo real por integrante, cortes y transiciones. Después intercambiar preguntas: cada integrante explica un tramo ajeno apoyándose en el manifiesto, la selección y las predicciones. Ensayar la respuesta corta sobre partición, diferencia estadística, softmax y receta. No presentar esta agenda como ensayo efectuado.

Regla para responder

Dar primero la conclusión. Precisar qué evidencia la respalda y cuál es su límite. Ante un dato no medido, indicarlo y proponer la medición necesaria. No inventar pruebas de Colab, costos, calibración, raciones independientes ni detección de ingredientes.

Reserva de preguntas · conceptos y selección

¿Por qué F1 macro si las clases están equilibradas?

Da igual peso a los 40 platos y combina precisión y exhaustividad por clase. El balance de soporte no elimina errores concentrados. Exactitud complementa el conteo global.

¿Por qué prueba supera validación?

Son fotografías distintas y solo 15 por clase en cada conjunto. Puede existir dependencia entre vistas. Una cifra mayor no demuestra mejor generalización. No se usó prueba para retocar selección o umbral.

¿Se entrenó 200 épocas?

200 fue el techo con paciencia 10. Las 32 corridas oficiales finalizaron entre 15 y 96 épocas por parada temprana. La exploración de 15 épocas no participa en la selección.

¿Cómo se elige una época y se trata un empate?

Se guarda el mayor F1 macro de validación observado. La mejora debe ser estricta. Un empate conserva la primera época máxima y cuenta para paciencia. La tasa empatada favorece 0,0001.

¿Cuál es la originalidad?

La adaptación y evaluación propias en comida peruana: matriz de familias, regímenes y presupuestos, ablación controlada y propagación documental de un error. No proponemos una arquitectura nueva ni creamos PeruFoodNet.

Reserva de preguntas · alcance y costo

¿Se puede ejecutar en Colab o medir en T4?

El código está preparado para Colab, pero solo se verificó ejecución local en Windows y RTX 5090. No se probaron descargas ni se midió T4. No extrapolamos tiempos entre equipos.

¿Qué significa la dispersión de tres semillas?

Desviación estándar muestral de los tres mejores F1 de validación, a tasa seleccionada con semilla 42. No es intervalo de confianza ni variación entre raciones o particiones.

¿Cuántas imágenes se usaron realmente?

400 o 1.600 de entrenamiento, 600 de validación y 600 de prueba. 2.800 es entrenamiento elegible, no el tamaño utilizado en cada corrida. Los presupuestos 10 y 40 son anidados.

¿Cuánto costó monetariamente?

No se midió precio ni electricidad. Se reportan RTX 5090, 55 min 43 s de reloj y 0,886 h aproximadas de suma de corridas, con preparación y registro. No equivalen a ocupación continua de GPU.

Fuentes y lectura de las cifras

Evidencia interna aprobada

Equipo3_Paper.pdf y fuente/paper.tex: artículo aprobado de siete páginas. Marco, método, contribuciones confirmadas, límites y costo.

3.3 Código/data/manifest.csv, counts.csv y classes.json: 4.000 archivos, clases y partición 01–70 / 71–85 / 86–100. Subconjuntos 01–10 y 01–40.

results/comparacion_misma_tasa.csv: diapositiva 10, cuatro valores de validación a tasa 0,0001, semilla 42 y 40 fotos/clase. No son medias de tres semillas.

results/resumen_validacion.csv: diapositivas 11–12, medias y desviaciones muestrales de tres semillas a tasas seleccionadas. La tasa de YOLO capa final con 40 fotos es 0,0003; las redes completas con 40 usan 0,0001.

results/matrix_index.json, corridas.csv e histories/: 32 corridas, rango de épocas 15–96, paradas tempranas y suma de duraciones 3.189,05 s. El artículo documenta 55 min 43 s de reloj de campaña.

results/winner.json: configuración ganadora y checkpoint de semilla 42, fijados antes de prueba. Run d59207e9411549868004183bbf8ee4cd.

results/test/predicciones.csv y metricas.json: 543 aciertos / 600 = 90,5 %, F1 macro 0,9043129 y 50 inciertas incluidas. Evaluación 11,0336 s y latencia solo modelo 2,872686 ms.

results/test/analisis_errores.json y matriz_confusion.csv: los cuatro pares empatados, sus direcciones y el error Aji de Gallina/72_Aji_de_Gallina.jpg a Locro, puntuación 0,3052472. data/ingredients.json: correspondencia documental.

notebooks/02_modelo_final_profesor.ipynb: ejemplo ilustrativo local Aguadito, puntuación redondeada 0,997. No sustituye las métricas de 600 fotos.

Atribución de fotografías

Franchesca Arzola, Alexander Canchari y Edwin Escobedo. PeruFoodNet, versión 3, Mendeley Data, 2024. Licencia CC BY 4.0. https://data.mendeley.com/datasets/hxhbbm497d/3
Fotos utilizadas: 01_Lomo_Saltado.jpg, 01_Aji_de_Gallina.jpg, 40_Aji_de_Gallina.jpg, 72_Aji_de_Gallina.jpg y ejemplo_aguadito.jpg (copia local del ejemplo). Ajuste proporcional de tamaño, sin recorte de contenido. Las fotos del dataset y la licencia se distinguen del artículo que lo documenta.

Referencias de fundamento

[1] Arzola Gutierrez, Canchari Muñoz y Escobedo Cárdenas (2025). PeruFoodNet: A unique dataset of traditional peruvian food for image recognition systems and allergenic ingredient inference. Data in Brief, 60, 111604. Tablas 1 y 2: códigos y asociación por plato. https://doi.org/10.1016/j.dib.2025.111604

[2] Bossard, Guillaumin y Van Gool (2014). Food-101: Mining Discriminative Components with Random Forests. ECCV. https://data.vision.ee.ethz.ch/cvl/datasets_extra/food-101/

[3] He, Zhang, Ren y Sun (2016). Deep Residual Learning for Image Recognition. CVPR. https://arxiv.org/abs/1512.03385

[4] Yosinski, Clune, Bengio y Lipson (2014). How transferable are features in deep neural networks? NeurIPS. https://arxiv.org/abs/1411.1792

[5] Jocher et al. (2026). Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models. Referencia empleada por el artículo aprobado. https://arxiv.org/abs/2606.03748

[6] Loshchilov y Hutter (2019). Decoupled Weight Decay Regularization. ICLR. https://arxiv.org/abs/1711.05101

[7] Guo, Pleiss, Sun y Weinberger (2017). On Calibration of Modern Neural Networks. ICML. https://proceedings.mlr.press/v70/guo17a.html

Correspondencia con las diapositivas

1, 5, 15 y 18: fotos PeruFoodNet. 2 y 15: tablas de recetas de Arzola et al. 3: Food-101, PeruFoodNet, ResNet, transferencia y YOLO26. 4: He, Yosinski y Jocher. 7–8: formulación propia común; AdamW según Loshchilov y Hutter. 13, 15 y 18: puntuaciones operativas sin calibración, límite motivado por Guo et al. 6 y 9–20: resultados y discusión del artículo aprobado, detallados en la página anterior. Las referencias establecen fundamento, sin comparación directa de métricas de otros protocolos.