Detección de fauna con YOLOv8s y monitoreo de actividad en cámaras conocidas y nuevas

Chilón Cruzado Josué
Concepción Tiza Miguel Ángel
Neyra Dianderas Enzo Israel
Tello Guerra Omar Salvador
Alexander Vladimir Paco Cornejo
Universidad Nacional de Ingeniería (UNI)
Unidad de Posgrado
Facultad de Ingeniería Industrial y de Sistemas
Lima, Perú

Abstract

Se ajusta un detector YOLOv8s de Ultralytics sobre el benchmark oficial CCT20, con fotografías marcadas empty tratadas como fondo. El protocolo v6 conserva las 1 000 fotografías vacías añadidas en v2 de ocho cámaras oficiales adicionales de entrenamiento a las 57 864 imágenes originales y verifica las particiones oficiales. La evaluación separa cámaras vistas y nuevas, reporta rendimiento por especie y tamaño relativo, y reserva el análisis de oclusión para una revisión visual explícita. Un módulo propio agrega detecciones por cámara, especie y día. Las noventa fotografías de la muestra de etiquetas cuentan con aprobación humana, incluida la corrección de una tercera ave indicada por el revisor. El entrenamiento científico y la evaluación se ejecutan con el protocolo descrito; la prueba pequeña se conserva como verificación funcional independiente.

1. Motivación y trabajos relacionados

Las cámaras trampa generan imágenes cuyo fondo permanece casi constante. Recognition in Terra Incognita [1] estudia la dificultad de generalizar a ubicaciones nuevas. El objetivo combina detección de animales y resumen de actividad sin equiparar detecciones con individuos.

YOLO propone detección mediante una red que predice localización y clase [4]. Se utiliza YOLOv8s de Ultralytics [6], una implementación posterior con diferencias respecto de la arquitectura del artículo original; no se atribuye a ese artículo la configuración de YOLOv8. La evaluación sigue la interpolación de AP y múltiples IoU de COCO [2], con límites de detecciones explicitados. Grad-CAM [5] permite inspeccionar sensibilidad en el backbone, aunque no demuestra por sí solo que el modelo memorice el fondo. AdamW [3] define la optimización del ajuste fino.

2. Benchmark y depuración

Se utiliza CCT20 ECCV, las imágenes reducidas del benchmark oficial y sus cinco archivos train, cis_val, cis_test, trans_val y trans_test. Esta selección no equivale a la colección completa de 243 100 imágenes y 140 ubicaciones. Las categorías se leen de las anotaciones; el benchmark contiene catorce categorías animales además de empty y car, que no son clases animales del detector. Se conserva el mapeo entre identificador original y clase YOLO.

Preprint.

Las imágenes explícitamente vacías generan un archivo de etiquetas vacío y participan como fondo. El archivo train oficial no incluye anotaciones empty. Las 2 130 fotos vacías de esas diez cámaras en la colección completa ya pertenecen a imágenes y secuencias reservadas del benchmark. El protocolo v2 añade 1 000 fotos empty de ocho cámaras del train oficial de la colección completa, fuera de las veinte cámaras ECCV: 125 secuencias distintas por cámara, un fotograma por secuencia. La selección usa solo metadatos y la semilla 42; excluye todos los IDs y secuencias ECCV originales, incluso los descartados de la evaluación. No se trasladan fotografías de validación o prueba. Se conservan los archivos descargados y sus hashes, dimensiones, URL y comprobación MD5 del proveedor. Estos negativos tienen resolución original; las fotos positivas proceden de la versión reducida. El detector redimensiona ambos grupos a 640. La asociación entre cámaras adicionales y negativos, así como la diferencia de resolución de origen, limita la interpretación de la generalización. Se excluyen imágenes de vehículos sin animales y cualquier fotografía con una anotación animal sin caja completa, para evitar tratar animales sin supervisión de localización como negativos. Se registran por partición todas las exclusiones y cajas inválidas. Las cajas se convierten a coordenadas normalizadas usando las dimensiones originales de metadatos; esto conserva su posición al usar las imágenes reducidas. Se registra la unidad resuelta y se comprueban límites sin recortar errores silenciosamente.

Las secuencias compartidas entre train y cis_val se eliminan de validación. Se comprueba independencia de imágenes y secuencias frente a entrenamiento. Las cámaras trans deben ser disjuntas de train. La auditoría v2 deja 12 399 fotos en train (11 399 originales y 1 000 fondos), 2 543 en cis_val, 13 073 en cis_test, 1 592 en trans_val y 18 647 en trans_test. Train contiene cinco cajas de fox y nueve de badger, frente a 2 514 de opossum. cis_val carece de cajas de deer y fox, y trans_test carece de deer. Las métricas indefinidas de esas clases se conservarán como tales. Las listas de imágenes elegibles controlan el dataset derivado y evitan incorporar archivos antiguos fuera del manifiesto. Cada original se decodifica por completo y conserva un SHA-256. La caché se invalida si cambia su tamaño o fecha; el montaje de origen es de solo lectura. Las cajas normalizadas se revisan en una galería de cinco ejemplos por clase disponible y veinte fondos antes del ajuste completo.

La versión v5 conserva las dos cajas de v3 y corrige la tercera caja incorrecta de v4 según el recuadro rojo proporcionado por el revisor para el ave entre las rocas. La referencia de 960 por 700 píxeles fija los límites $(681, 333, 707, 381)$; su hash se conserva junto con el registro de correcciones. El CSV humano aprueba las noventa fotografías, incluida la modificada; se conservan las decisiones de las 89 fotos sin cambios, la revisión histórica completa y los hashes de la corrección. Las 89 decisiones sobre fotografías sin cambios se confirman globalmente por el revisor; las notas por fotografía correcta son opcionales. La auditoría contrasta cada registro con la versión padre y permite únicamente las cajas de train declaradas; los holdouts y los fotogramas de monitoreo permanecen idénticos.

La versión v6 conserva todas esas cajas y revisiones. Algunos JPEG incluyen espacios después del marcador final; el comprobador de Ultralytics intenta reescribirlos y los originales de solo lectura impedirían su uso. Para esos archivos se generan copias de trabajo que eliminan únicamente espacios, tabulaciones y saltos de línea posteriores a un marcador final existente, sin recomprimir. Se verifica igualdad exacta de los píxeles decodificados y se conservan hashes de originales, copias y píxeles. Marcadores ausentes o contenidos finales distintos detienen la preparación. Antes de entrenar, el comprobador instalado verifica todas las imágenes y etiquetas y exige que no se omitan fotografías ni cajas. Los originales no se modifican.

3. Detector y entrenamiento

Se ajusta YOLOv8s con pesos preentrenados descargados explícitamente y catorce categorías reales. La resolución es 640, batch 16, semilla 42, hasta 50 épocas y paciencia 10. Se usa AdamW, tasa inicial $3 \times 10{-}4$ y weight decay $10{-}4$. Mosaic tiene probabilidad 1, el giro horizontal 0.5 y no se aplica giro vertical; mosaic se desactiva en las diez últimas épocas configuradas. Se documentan también los argumentos efectivos que Ultralytics guarda con cada entrenamiento. La parada y selección de checkpoint utilizan cis_val depurado, sin optimizar sobre trans_test.

La arquitectura principal del detector procede de Ultralytics. El alcance definido por el usuario conserva ese detector existente y adapta sus pesos a las categorías del benchmark. La conversión de datos, la evaluación, Grad-CAM y el monitoreo son módulos propios. Se distingue expresamente el código de esos módulos de la implementación de la red utilizada.

El tratamiento del desbalance conserva vacíos y reporta soporte por especie. No se presupone que mosaic elimine el problema de especies raras. Las clases con pocos ejemplos deben interpretarse con mayor incertidumbre y propuestas de muestreo o ampliación futuras deberán evaluarse en otro experimento controlado.

4. Evaluación y generalización

Se calcula mAP@0.5 y mAP@0.5:0.95 en cis_test y trans_test, con desglose de soporte y AP por especie. La inferencia para AP conserva detecciones con confianza $\geq 0{,}001$ y aplica NMS IoU 0.7, con máximo 300 detecciones por imagen. Las categorías sin referencia tienen AP indefinida. La brecha se define como $\mathrm{mAP}_{cis} - \mathrm{mAP}_{trans}$.

Para estratificar tamaño se utiliza área de caja dividida por área de imagen: pequeño $< 1\ \%$, mediano entre 1 y 5 %, grande $> 5\ \%$. Se transforma cada imagen a un sistema virtual de 1000×1000, preservando IoU, y se aplica evaluación COCO por área relativa. No se confunden estos intervalos con las categorías COCO de área absoluta.

Las anotaciones oficiales no incluyen niveles fiables de oclusión. Se prepara la cohorte completa de objetos elegibles de trans_test y una galería paginada para revisión. Un evaluador humano asignará low, medium, high o ambiguous con evidencia visual. Los truncamientos o casos de visibilidad incierta se registran explícitamente como ambiguous. Se requiere revisión de todos los objetos y al menos 30 ejemplos por nivel para cerrar el análisis previsto. Objetos ambiguos o de otro nivel se marcan como regiones ignoradas de tipo crowd al evaluar un grupo. Este procedimiento conservador evita penalizar detecciones correctas de otros grupos, Se publicará la cobertura y se mantendrá el análisis pendiente mientras haya objetos sin revisar. Además de las medias globales se compara el conjunto de clases con soporte en ambos tests, para explicitar la diferencia de cobertura taxonómica. Se calculan intervalos percentiles del 95 % con 200 remuestreos de secuencias completas y semilla 42 para mAP50 y mAP50:95, tamaño relativo y oclusión revisada. El modelo permanece fijo. Estos intervalos son condicionales a las cámaras observadas y no estiman variación entre semillas ni regiones nuevas.

5. Resultados e interpretabilidad

Tabla 1: Resultados de las ejecuciones registradas. ND: métrica no definida.

Experimento	mAP cámaras vistas	mAP cámaras nuevas	Brecha
yolov8s	0.4358	0.2625	0.1733

Tabla 2: Inventario efectivo después de depurar anotaciones y secuencias. Train oficial no contiene imágenes empty. V2 añade 1.000 fondos de ocho cámaras oficiales adicionales de entrenamiento.

Partición	Fotos	Fondos	Cámaras	Secuencias
train	12399	1000	18	5733
val	2543	995	10	980
cis_test	13073	1180	10	5378
trans_val	1592	61	1	589
trans_test	18647	1778	9	7438

Tabla 3: Evaluación COCO global con el mismo checkpoint, 101 puntos de recall y máximo 300 detecciones por imagen.

Partición	Clases con soporte	mAP50	mAP50:95
cis_test	14	0.6878	0.4358
trans_test	13	0.4231	0.2625

Cobertura visual: 0/17620 objetos; ambiguos: 0; sin revisar: 17620.

Tabla 4: Rendimiento por especie: cis_test. ND indica ausencia de referencia.

Especie	Cajas	AP50	AP50:95
opossum	4008	0.8844	0.4932
raccoon	980	0.8970	0.5917
squirrel	510	0.7037	0.3696
bobcat	772	0.8561	0.6084
skunk	161	0.9355	0.6175
dog	723	0.6932	0.4858
coyote	1180	0.9035	0.6901
rabbit	1556	0.8874	0.5534
bird	752	0.6435	0.3334
cat	1528	0.8749	0.5866
badger	4	0.0112	0.0056
deer	139	0.5146	0.3383
fox	2	0.0000	0.0000
rodent	146	0.8236	0.4269

Tabla 5: Rendimiento por especie: trans_test. ND indica ausencia de referencia.

Especie	Cajas	AP50	AP50:95
opossum	4659	0.8826	0.4590
raccoon	4769	0.7549	0.4959
squirrel	777	0.3644	0.1957
bobcat	1974	0.6268	0.4176
skunk	273	0.4402	0.2840
dog	958	0.7377	0.4994
coyote	1901	0.6746	0.4788
rabbit	722	0.5912	0.2994
bird	179	0.0687	0.0383
cat	1366	0.2829	0.1842
badger	15	0.0736	0.0583
deer	0	ND	ND
fox	1	0.0000	0.0000
rodent	26	0.0021	0.0016

Pendiente de evidencia. El análisis de oclusión no cumple la cobertura y los mínimos de revisión humana previstos. Grad-CAM usa el score diferenciable de una clase antes de NMS y una capa del backbone fijada en configuración. La visualización debe compararse con el animal y con elementos persistentes del fondo. La inspección de un mapa es exploratoria; hacen falta intervenciones sobre fondo o una muestra sistemática para sostener conclusiones causales sobre memorización. Se reservan seis casos por test: aciertos a IoU $\geq 0{,}5$, omisión o clase incorrecta y falsos positivos en fotos sin animales, cuando haya ejemplos disponibles. La selección reproducible prioriza especies raras y frecuentes y horarios diurno/nocturno; usa alternativas deterministas si falta un tipo de caso. La hora de captura aproxima el periodo de iluminación y se verifica visualmente. La propuesta explicada se fija antes de propagar gradientes y el mapa conserva el letterbox de entrada.

6. Monitoreo ecológico

El módulo propio agrega fotografías y detecciones con confianza $\geq 0{,}25$. Por cámara y día informa total de fotos, fotos con fauna, tasa de fotos sin detecciones y especies distintas. Por especie y periodo informa detecciones y fotografías con la especie, evitando duplicar una foto cuando hay varias cajas de la misma especie. Los nombres son categorías del benchmark: bird y rodent agrupan taxones y no identifican una especie biológica única. La diversidad informada es un conteo de categorías detectadas. La tasa de vacíos es una tasa predicha, no una medición humana del vacío real. Fechas inválidas se registran como unknown y no se inventan. La demostración toma todos los fotogramas oficiales de una cámara trans elegida por ID, incluidos los excluidos de la evaluación de cajas. Exige fechas válidas y una secuencia completa de al menos dos fotogramas; se conserva la zona horaria

Tabla 6: Comparación con el mismo conjunto de clases con soporte en ambos tests: opossum, raccoon, squirrel, bobcat, skunk, dog, coyote, rabbit, bird, cat, badger, fox, rodent.

Partición	mAP50	mAP50:95
cis_test	0.7011	0.4432
trans_test	0.4231	0.2625

Tabla 7: Intervalos percentiles de mAP50:95 mediante remuestreo de secuencias completas, modelo fijo. No cuantifican variación entre semillas ni entre nuevas regiones.

Grupo	IC95 inferior	IC95 superior	Réplicas
cis_test: Global	0.4288	0.4785	200
trans_test: Global	0.2538	0.3023	200
cis_test: small_lt_1pct	0.2452	0.3377	200
cis_test: medium_1_to_5pct	0.4516	0.5232	200
cis_test: large_gt_5pct	0.5312	0.5720	200
trans_test: small_lt_1pct	0.1430	0.1942	200
trans_test: medium_1_to_5pct	0.3085	0.3440	200
trans_test: large_gt_5pct	0.2572	0.3597	200

sin especificar de los metadatos. Los resultados incluyen resúmenes por día, especie y una ráfaga completa con identificadores auditables.

7. Discusión y uso responsable

Pendiente de evidencia. Completar con la brecha observada, especies raras, mapas y resultados de oclusión. La ampliación v2 incorpora solo negativos en ocho cámaras adicionales; no agrega animales de esas cámaras. El fondo puede entonces ayudar a distinguir la procedencia de los negativos. La resolución original de esa cohorte también difiere de las imágenes ECCV reducidas. El resultado deberá describirse como entrenamiento ampliado y no como reproducción estricta del train ECCV. Una comparación futura necesitaría otra ejecución controlada, conservando los mismos tests y sin ajustar a sus resultados. Un falso negativo de una especie amenazada puede invisibilizar su presencia en decisiones de manejo, mientras que un falso positivo consume tiempo de revisión y puede crear registros de distribución incorrectos. El umbral 0.25 de la demostración no se considera óptimo para todas las especies ni para una decisión de conservación.

Debe mantenerse revisión profesional de observaciones sensibles, documentar esfuerzo de muestreo y validar en cámaras y hábitats del destino. Una tasa baja de detecciones también puede reflejar fallos del sensor o cambio de iluminación. Los conteos de imágenes no estiman población ni individuos. La separación entre cámaras ayuda a evaluar generalización, pero el entrenamiento en Estados Unidos no justifica despliegue en Amazonía o Andes sin validación local.

La decisión de revisar una fotografía debe considerar el costo de omitir una observación, el costo de una identificación incorrecta y la capacidad del equipo de campo para verificarla. Un umbral global puede facilitar una demostración operativa, pero no sustituye un protocolo por especie. Para registros sensibles conviene conservar la fotografía original, la caja, la confianza y la decisión del experto, evitando que una etiqueta automática se convierta sin revisión en un registro confirmado. El procesamiento debe poder repetirse si cambian el modelo o el criterio de revisión.

La concentración de ejemplos en especies frecuentes puede ocultar un rendimiento insuficiente en especies raras aun cuando la mAP global resulte favorable. Los soportes reales, las categorías sin referencia y las exclusiones deben acompañar cada comparación; una AP indefinida no es evidencia de ausencia biológica. La revisión de casos nocturnos, objetos pequeños y cuerpos parcialmente visibles ayuda a priorizar nuevas muestras, pero una galería exploratoria no mide por sí sola la frecuencia de esos errores. Para una aplicación de conservación se necesitarían muestreo temporal representativo, control del esfuerzo por cámara y evaluación en el hábitat de destino. Cualquier decisión de manejo conserva responsabilidad humana y debe admitir corrección cuando aparezcan evidencias adicionales. Las exclusiones por cajas incompletas pueden cambiar la distribución de dificultad. Los resultados corresponden al benchmark elegido, no a todas las cámaras de Caltech ni a

Tabla 8: Robustez por área relativa en cis_test: menor de 1 %, 1–5 %, mayor de 5 %.

Tamaño relativo	Cajas	AP50	AP50:95
Pequeño	1149	0.5631	0.2792
Mediano	8925	0.7516	0.4683
Grande	2387	0.7583	0.5480

Tabla 9: Robustez por área relativa en trans_test: menor de 1 %, 1–5 %, mayor de 5 %.

Tamaño relativo	Cajas	AP50	AP50:95
Pequeño	1922	0.3216	0.1619
Mediano	12169	0.5272	0.3220
Grande	3529	0.4024	0.2870

fauna peruana. La subjetividad de la oclusión manual y una sola semilla limitan la generalización de sus conclusiones.

8. Reproducibilidad y pendientes

Se registran manifiestos, clases, exclusiones, argumentos de entrenamiento, pesos, predicciones, métricas y reportes de actividad. Las dependencias directas están fijadas, se conserva el inventario completo instalado y se verifica CUDA, gradientes, NMS y AMP en RTX 5090. Una interrupción controlada demuestra la restauración de época, estados del optimizador y paciencia de YOLO; un archivo auxiliar se liga al hash de last.pt para restaurar la parada temprana. No se afirma equivalencia bit a bit. La ejecución científica y la prueba pequeña tienen carpetas y volúmenes derivados distintos. Código fuente: https://github.com/miguelsff/maestria-ia-uni-ciclo-2-redes-neuronales.
Antes de entregar se completarán revisión de oclusión, discusión ligada a cifras reales, demostración ecológica, autores, enlace del repositorio y revisión visual de 6–10 páginas.

Referencias

[1] Sara Beery, Grant Van Horn, and Pietro Perona. Recognition in terra incognita. In *ECCV*, 2018. https://arxiv.org/abs/1807.04975.

[2] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft coco: Common objects in context. In *ECCV*, 2014. https://arxiv.org/abs/1405.0312.

[3] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *ICLR*, 2019. https://arxiv.org/abs/1711.05101.

[4] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *CVPR*, 2016. https://arxiv.org/abs/1506.02640.

[5] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *ICCV*, 2017. https://arxiv.org/abs/1610.02391.

[6] Ultralytics. Ultralytics yolov8: Model documentation. https://docs.ultralytics.com/models/yolov8/, 2026.

Tabla 10: Cohorte completa de oclusión visual en trans_test; mínimo requerido: 30 objetos por nivel.

Oclusión	Revisados	AP50	AP50:95
Baja	0	ND	ND
Media	0	ND	ND
Alta	0	ND	ND

Tabla 11: Actividad predicha de la cámara 7: primeros diez días de la cohorte completa de esa cámara.

Día	Fotos	Con fauna	Especies	Vacías
2011-05-07	1	0	0	1.0000
2011-05-08	9	2	1	0.7778
2011-05-10	3	1	1	0.6667
2011-05-20	3	3	1	0.0000
2011-05-25	2	1	1	0.5000
2011-06-03	3	1	2	0.6667
2011-06-05	3	3	1	0.0000
2011-06-17	2	1	1	0.5000
2011-06-19	6	3	2	0.5000
2011-06-20	15	14	2	0.0667

Tabla 12: Resumen de todos los días de la cámara de demostración. Las detecciones no representan individuos únicos.

Especie	Detecciones	Fotos con especie
bird	92	91
bobcat	49	49
cat	45	43
coyote	477	449
deer	1	1
dog	33	32
opossum	649	643
rabbit	81	80
raccoon	90	85
skunk	10	10
squirrel	38	34

Tabla 13: Secuencia completa con fecha de captura válida. Identificadores completos disponibles en activity_sequence.csv.

Fotograma	Captura	Detecciones	Especies
1	2011-05-08 11:39:22	0	ND
2	2011-05-08 11:39:23	0	ND
3	2011-05-08 11:39:24	1	opossum

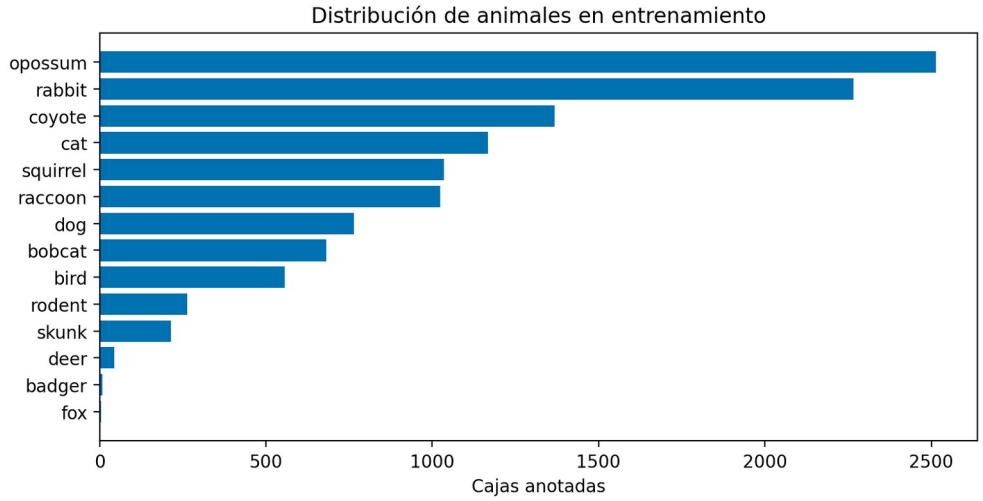


Figura 1: Desbalance de cajas anotadas en entrenamiento.

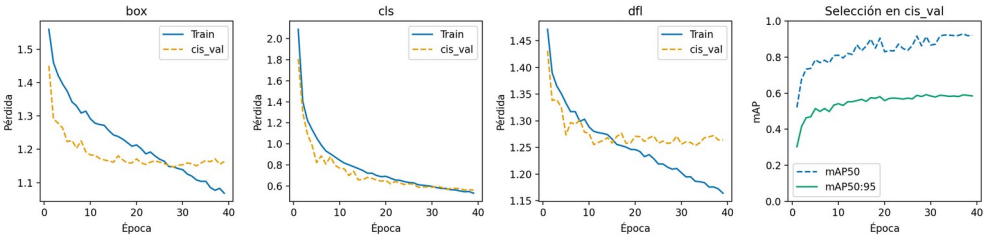


Figura 2: Pérdidas por componente y mAP en cis_val. Las curvas de selección no usan los conjuntos de prueba.

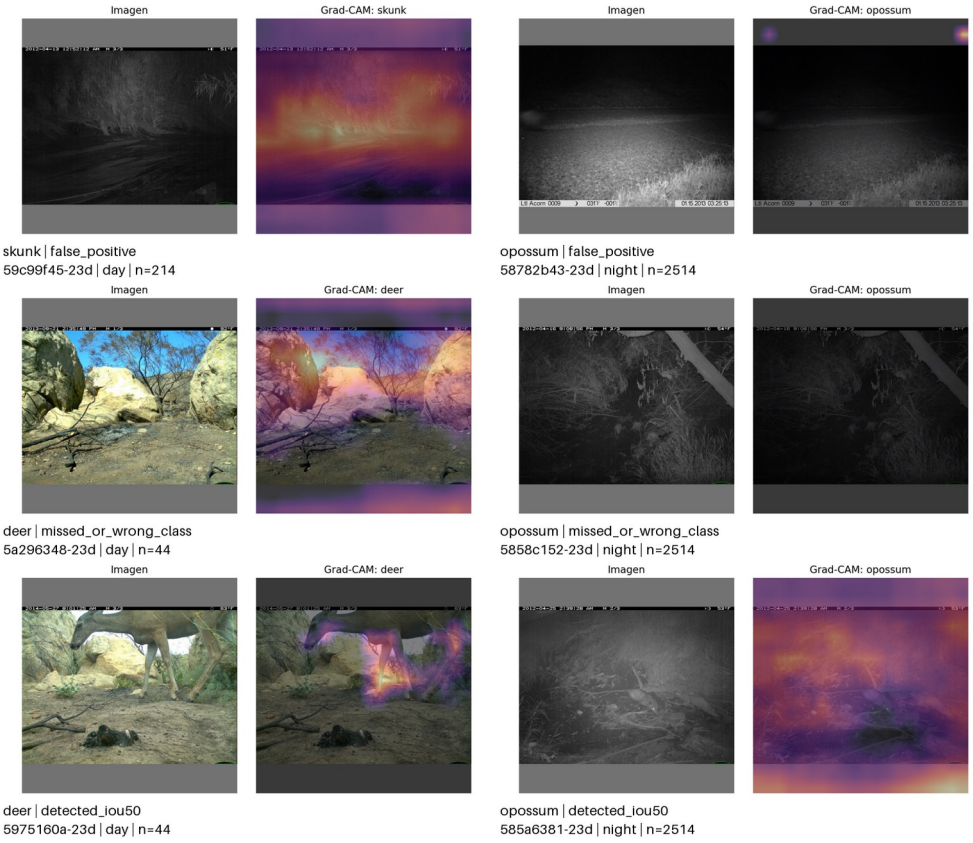


Figura 3: Seis casos Grad-CAM en cámaras vistas: aciertos, errores y fondos. Día/noche se deriva de la hora de captura y requiere inspección visual.

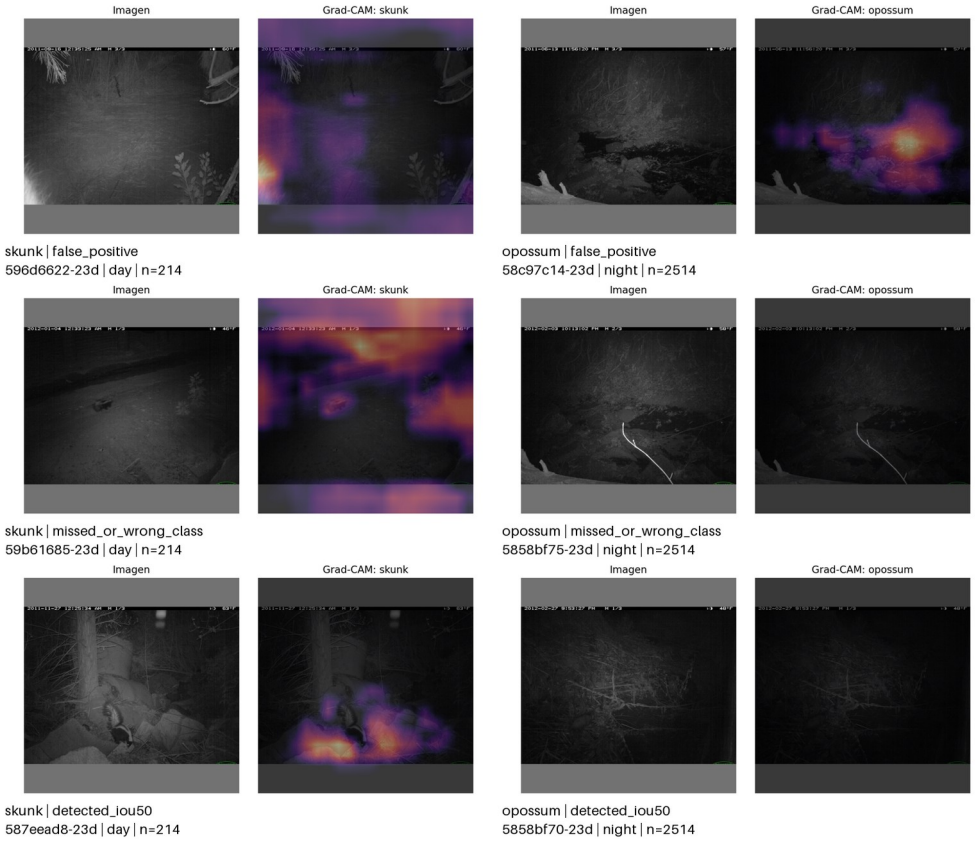


Figura 4: Seis casos Grad-CAM en cámaras nuevas, con soporte de entrenamiento por especie. Los mapas no demuestran causalidad.