Segmentación de agua en Sentinel-1: U-Net propia, supervisión débil y generalización a Bolivia

Grupo de cinco estudiantes: completar nombres y correos
Universidad Nacional de Ingeniería
Lima, Perú

Abstract

Se compara una U-Net implementada directamente en PyTorch sobre los canales VV/VH de Sen1Floods11. El protocolo cruza etiquetas manuales y manuales más débiles con las pérdidas BCE, Dice y su suma; conserva la validación manual y reserva Bolivia exclusivamente para evaluación externa. La auditoría verifica 9 216 archivos y excluye 16 chips sin píxeles válidos. Se reportan IoU promedio por chip, métricas agrupadas por píxel y una convención adicional compatible con el tratamiento de unión vacía de la referencia oficial. Las seis corridas obtienen IoU por chip entre 0.3251 y 0.4100 en ID y entre 0.2690 y 0.4790 en Bolivia. El efecto de agregar supervisión débil se compara dentro de cada pérdida; la diferencia de pasos y una única semilla limitan su interpretación causal.

1. Problema y trabajos relacionados

El objetivo es asignar una probabilidad de agua a cada píxel válido de una observación SAR. Las observaciones de radar permiten estudiar eventos bajo nubosidad, pero su interpretación depende de geometría, rugosidad y propiedades dieléctricas de la superficie [2]. La clase positiva de Sen1Floods11 incluye agua observada y no diferencia por sí sola inundación nueva de agua permanente [1]. Por ello, este trabajo evalúa segmentación de agua y no estima daño, profundidad ni extensión temporal de inundación.

U-Net combina un encoder contextual con conexiones de salto que conservan detalle espacial [6]. Se implementan sus bloques sin descargar una arquitectura o pesos preentrenados. Dice permite optimizar solapamiento [4]; aquí se utiliza una variante bidimensional con sumas de probabilidades, distinta del denominador cuadrático de V-Net. La supervisión débil aumenta cobertura, pero puede introducir errores sistemáticos de etiquetado [5]. AdamW separa adaptación y decaimiento de pesos [3]. GroupNorm calcula estadísticas por grupos de canales y resulta independiente del tamaño del batch [7]. Estas decisiones permiten estudiar fuente de supervisión y pérdida manteniendo constante el modelo.

2. Datos y auditoría reproducible

Se utiliza v1.1, con chips GeoTIFF de 512×512 píxeles, dos bandas VV/VH en dB y etiquetas manuales o débiles de Sentinel-1. Se conservan los CSV oficiales de entrenamiento, validación, prueba y Bolivia. Los 446 chips manuales se reparten originalmente en 252/89/90/15; nunca se incorporan todos al entrenamiento.

Los originales locales contienen 4 160 pares débiles fuera de Bolivia. El inventario remoto consultado el 3 de octubre de 2026 contiene 4 384 pares, de los cuales 224 son de Bolivia; la documentación menciona 4 385. Se registra esa discrepancia de una unidad y no se supone que un archivo inexistente deba descargarse. Los 4 160 pares admisibles coinciden con los nombres y tamaños del inventario

remoto. No hay solapamientos con identificadores manuales. La verificación local de tamaño y MD5 de los 9 216 archivos seleccionados pasó sin fallos; las huellas SHA-256 de imágenes, etiquetas y CSV quedan en el manifiesto.

Se comprueba correspondencia imagen/máscara, dos bandas SAR, una banda de etiqueta, dimensiones, CRS y transformación afín. Se acepta únicamente redondeo numérico absoluto menor o igual a 10^{-12} en sus coeficientes; no se remuestrea ninguna máscara. Los valores válidos son 0 y 1. Se excluyen -1, nodata del raster e intensidades no finitas en cualquiera de las dos bandas. La auditoría encontró 16 chips totalmente inválidos: uno de entrenamiento, tres de validación, dos de prueba y diez débiles; ninguno de Bolivia. Los IDs excluidos quedan persistidos para poder reproducir los conteos efectivos.

Tabla 1: Inventario efectivo después de excluir nodata.

Partición	Chips	Píxeles válidos	Fracción agua
train	251	57017597	0.0955
val	86	20274154	0.1101
test	88	20443959	0.1230
bolivia	15	2824434	0.1600
weak	4150	1069346608	0.1683

Las estadísticas se calculan únicamente sobre píxeles válidos del entrenamiento manual, después de recortar intensidades al intervalo fijo $[-50, 10]$ dB. Las medias VV/VH son $-10{,}4551 / -17{,}3253$ dB y las desviaciones $4{,}0661 / 4{,}7918$ dB. Se aplican las mismas estadísticas a todas las fuentes y particiones. El clipping limita valores extremos, pero puede saturar señales informativas. En el tensor de entrada, los píxeles inválidos se reemplazan por cero normalizado; siguen excluidos de pérdidas y métricas. La proporción positiva válida es 9.55 % en entrenamiento y 16.00 % en Bolivia. Esta diferencia de prevalencia puede afectar precisión y métricas agregadas.

Los originales se montan en solo lectura. Una caché independiente en un volumen Linux se copia y vuelve a verificar contra MD5 para evitar el coste de acceso repetido desde Windows. Contiene los mismos archivos, sin convertir valores, modificar geometría ni agregar observaciones. Sentinel-2 queda fuera del alcance de este experimento.

3. U-Net personalizada

La entrada tiene forma $B \times 2 \times H \times W$ y la salida un logit por píxel. Cada bloque contiene dos convoluciones 3×3 sin sesgo, GroupNorm de ocho grupos y ReLU. El encoder usa 32, 64, 128 y 256 canales, con max-pooling 2×2; el bottleneck tiene 512. Cada etapa del decoder aplica convolución transpuesta 2×2, concatena el salto del encoder y refina con otro bloque. Una convolución 1×1 produce la salida. Se interpola a la dimensión del salto si las formas difieren, comportamiento verificado también para tamaños impares. Las imágenes reales mantienen su resolución de 512×512. El modelo tiene 7 762 753 parámetros.

La arquitectura se inicializa desde cero. GroupNorm evita estimar estadísticas a partir de cuatro ejemplos; no elimina los otros efectos del batch sobre la optimización. Las aumentaciones son flips horizontales y verticales sincronizados entre bandas y máscara, con probabilidad 0.5 por eje. No se inventan intensidades ópticas ni se rotan canales.

4. Pérdidas y confianza de supervisión

Para el conjunto de píxeles válidos V_k del chip k y $p_i = \sigma(z_i)$:

$$\mathrm{L}_{BCE,k} = \frac{-1}{|V_k|} \sum_{i \in V_k} \left[y_i \log p_i + (1 - y_i) \log (1 - p_i) \right] \tag{1}$$

Se evalúa de forma estable directamente sobre logits. La variante Dice es

$$\mathrm{L}_{Dice,k} = 1 - \frac{2 \sum_{i \in V_k} p_i y_i + \epsilon}{\sum_{i \in V_k} p_i + \sum_{i \in V_k} y_i + \epsilon}, \quad \epsilon = 10^{-6} \tag{2}$$

La pérdida combinada suma ambos términos sin un coeficiente adicional. Para K chips válidos del batch se optimiza $K^{-1}\sum_k w_k \mathrm{L}_k$, con $w_k = 1$ para etiquetas manuales y $w_k = 0{,}3$ para débiles. Dividir por K, en vez de por la suma de pesos, conserva la atenuación 0.3 incluso en batches enteramente débiles. Las reducciones se calculan en FP32 dentro del entrenamiento con precisión mixta.

Cada chip aporta un término antes del promedio, independientemente del número de píxeles válidos; no se confunde esta ponderación con un promedio global por píxel. No se balancea el número de chips por fuente. En la condición mixta, 4 150 débiles y 251 manuales implican que 83.2 % de la masa nominal de pesos corresponde a supervisión débil. Ese cálculo describe el muestreo, no la contribución efectiva de cada gradiente.

5. Diseño experimental y evaluación

Se ejecutan seis configuraciones con semilla 42: gold y gold_weak, cada una con BCE, Dice y su suma. Los parámetros comunes son batch 4, AdamW, tasa 3×10^{-4}, decaimiento 10^{-4}, clipping de norma de gradiente a 1, hasta 50 épocas y paciencia 10 sobre pérdida de validación manual. Se restaura el checkpoint de mínima pérdida de validación de cada corrida. El umbral 0.5 se fija antes de evaluar y Bolivia no participa en normalización, entrenamiento o selección. La ejecución habilita semillas y algoritmos deterministas con avisos; no se afirma identidad numérica garantizada entre hardware o versiones diferentes.

La comparación controla arquitectura e hiperparámetros, pero no presupuesto de actualizaciones: una época manual tiene 63 pasos y una mixta 1 101. La supervisión y el número de pasos cambian conjuntamente. Además, las escalas BCE/Dice/combinada difieren; no se comparan sus valores absolutos de pérdida como medida de calidad entre configuraciones.

La métrica principal es el promedio no ponderado de IoU por chip con unión no vacía: $\mathrm{IoU}_k = TP_k/(TP_k + FP_k + FN_k)$. Una unión vacía es indefinida y se informa como tal, con el número de chips excluidos. Se presenta también $(TP_k + 10^{-7})/(TP_k + FP_k + FN_k + 10^{-7})$, que asigna uno a la unión vacía, siguiendo el tratamiento del notebook oficial; esto no convierte todo el protocolo en una réplica de su modelo. Ambas convenciones se mantienen visibles.

Para los conteos acumulados en píxeles válidos se reportan IoU, precisión $TP/(TP + FP)$, recall $TP/(TP + FN)$, F1, omisión $1 - \mathrm{recall}$ y comisión $1 - \mathrm{precision}$. Un denominador nulo queda como no definido. La IoU global pondera indirectamente chips por área de unión, por lo que no equivale al promedio por chip. La brecha geográfica es $\mathrm{IoU}_{ID} - \mathrm{IoU}_{Bolivia}$; puede ser negativa. Se evalúan los 88 chips ID y 15 de Bolivia para cada configuración.

6. Resultados

Tabla 2: IoU promedio sobre chips con unión no vacía. Brecha: ID menos Bolivia.

Experimento	IoU ID	IoU Bolivia	Brecha
gold_bce	0.3939	0.4555	-0.0616
gold_dice	0.4100	0.4463	-0.0364
gold_combined	0.4068	0.4057	0.0010
gold_weak_bce	0.3251	0.2690	0.0560
gold_weak_dice	0.3487	0.4790	-0.1302
gold_weak_combined	0.3593	0.4511	-0.0918

Tabla 3: Métricas agrupadas por píxel en prueba en distribución.

Experimento	IoU global	F1	Prec.	Recall	Omisión	Comisión
gold_bce	0.6642	0.7982	0.8538	0.7495	0.2505	0.1462
gold_dice	0.6473	0.7859	0.7810	0.7908	0.2092	0.2190
gold_combined	0.6611	0.7960	0.8256	0.7684	0.2316	0.1744
gold_weak_bce	0.6099	0.7577	0.7955	0.7233	0.2767	0.2045
gold_weak_dice	0.5902	0.7423	0.7262	0.7591	0.2409	0.2738
gold_weak_combined	0.6102	0.7579	0.7464	0.7698	0.2302	0.2536

Tabla 4: Métricas agrupadas por píxel en Bolivia.

Experimento	IoU global	F1	Prec.	Recall	Omisión	Comisión
gold_bce	0.6779	0.8081	0.8573	0.7642	0.2358	0.1427
gold_dice	0.6385	0.7794	0.8104	0.7507	0.2493	0.1896
gold_combined	0.5844	0.7377	0.8372	0.6593	0.3407	0.1628
gold_weak_bce	0.4807	0.6493	0.9185	0.5021	0.4979	0.0815
gold_weak_dice	0.7183	0.8361	0.8295	0.8428	0.1572	0.1705
gold_weak_combined	0.6942	0.8195	0.8826	0.7647	0.2353	0.1174

Tabla 5: Compatibilidad con la referencia oficial: epsilon de 10^{-7} y unión vacía igual a uno.

Experimento	Partición	Definidos	Unión vacía	IoU referencia
gold_bce	test	86	2	0.4077
gold_bce	bolivia	15	0	0.4555
gold_dice	test	88	0	0.4100
gold_dice	bolivia	15	0	0.4463
gold_combined	test	88	0	0.4068
gold_combined	bolivia	15	0	0.4057
gold_weak_bce	test	84	4	0.3557
gold_weak_bce	bolivia	15	0	0.2690
gold_weak_dice	test	87	1	0.3561
gold_weak_dice	bolivia	15	0	0.4790
gold_weak_combined	test	86	2	0.3739
gold_weak_combined	bolivia	15	0	0.4511

La IoU principal varía de 0.3251 a 0.4100 en ID y de 0.2690 a 0.4790 en Bolivia. Las diferencias manual+débil menos manual, manteniendo la pérdida, son: bce, ID -0.0689 y Bolivia -0.1864; dice, ID -0.0612 y Bolivia +0.0326; combined, ID -0.0474 y Bolivia +0.0454. No se atribuyen únicamente a calidad de etiquetas, porque también aumenta el presupuesto de pasos.

En el baseline manual+BCE, IoU por chip y global por píxel son 0.3939/0.6642 en ID y 0.4555/0.6779 en Bolivia. Esta diferencia confirma que la agregación cambia la pregunta evaluada: los chips pequeños de agua pesan igual en el promedio y menos en el cociente global. Hay 2 uniones vacías en ID y 0 en Bolivia; ambas convenciones están en la tabla de referencia.

En las matrices del baseline, normalizadas por clase real, ID omite 25.1 % del agua de referencia y marca como agua 1.8 % de los píxeles no acuáticos. Bolivia omite 23.6 % del agua de referencia y marca como agua 2.4 % de los píxeles no acuáticos. El predominio de verdaderos negativos refleja el desbalance; una tasa baja de falsos positivos sobre no agua puede coexistir con omisiones relevantes de agua. Esta normalización por clase real no equivale a la comisión, cuyo denominador son las predicciones de agua.

Tabla 6: Presupuesto de entrenamiento y memoria CUDA asignada máxima; el límite del contenedor es 12 GiB de RAM.

Experimento	Épocas	Mejor época	Pasos/época	Minutos	VRAM GiB
gold_bce	50	47	63	3.2687	3.1457
gold_dice	41	31	63	2.6903	3.1457
gold_combined	50	49	63	3.3012	3.1457
gold_weak_bce	38	28	1101	28.5600	3.1467
gold_weak_dice	11	1	1101	8.2623	3.1457
gold_weak_combined	22	12	1101	16.5983	3.1467

Los tiempos corresponden al entrenamiento; preparación, evaluación, exportación y compilación son etapas adicionales. La memoria CUDA asignada máxima se distingue de la memoria reservada y del consumo total mostrado por el driver. El contenedor tiene límites de ocho CPU, 12 GiB de RAM y 2 GiB de memoria compartida, que no representan consumos medidos.

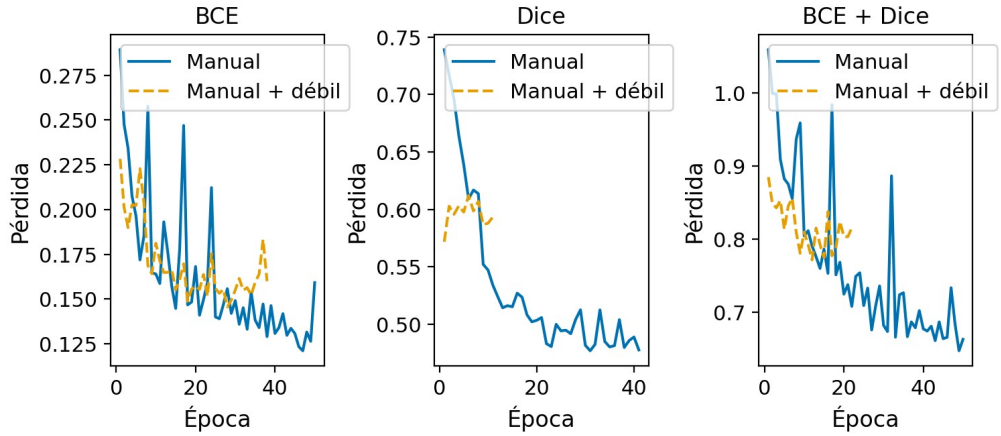


Figura 1: Validación manual por pérdida y fuente de supervisión.

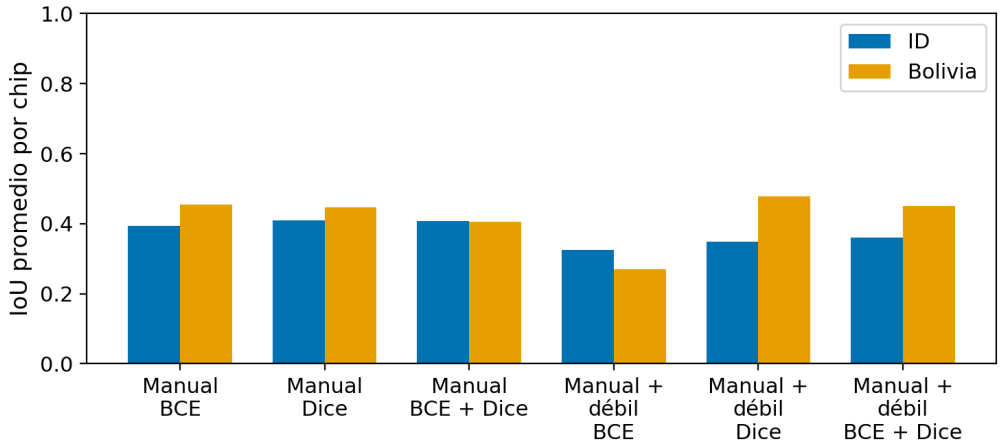


Figura 2: Comparación de las seis configuraciones en ID y Bolivia.

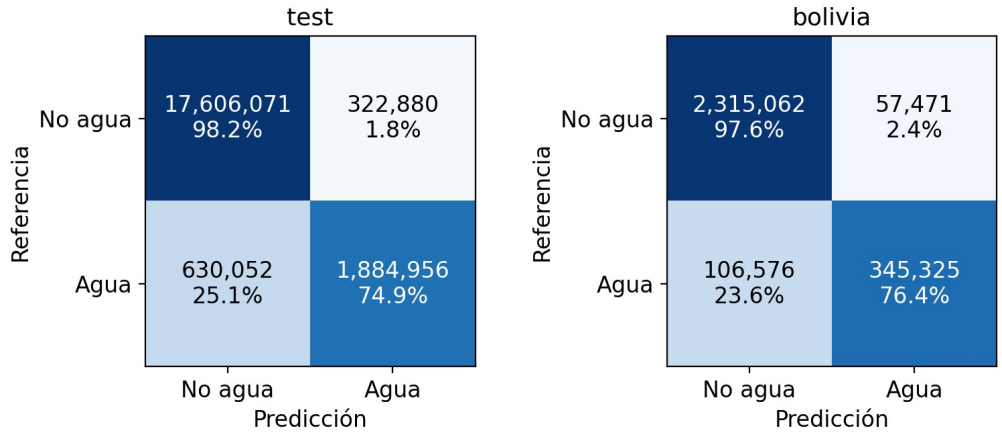


Figura 3: Baseline gold+BCE: conteos y porcentajes normalizados por clase real.

7. Errores SAR y generalización

7.1. Tres patrones observados en el baseline

Falsos positivos de baja retrodispersión. En Pakistan_70625, las manchas oscuras a la izquierda y arriba reciben alta probabilidad aunque la referencia solo marca cauces estrechos. Hay 28 116 FP y 3 330 FN; la IoU es 0.0408. La mediana VV/VH de los FP es $-17{,}84 / -25{,}82$ dB, frente a $-9{,}07 / -17{,}93$ dB en verdaderos negativos. La señal de los FP se parece a la del agua correctamente detectada ($-18{,}01 / -26{,}03$ dB). Esto evidencia ambigüedad radiométrica en el chip. Superficies lisas o sombra de radar son explicaciones físicas posibles [2], pero aquí no se demuestra cuál opera: faltan cobertura, topografía y una referencia óptica independiente.

Omisión de agua con respuesta más alta. En Pakistan_849790, la referencia marca gran parte del chip como agua, mientras la predicción retiene principalmente las regiones oscuras. Hay 138 480 FN y 793 FP, con recall 0.1945 e IoU 0.1936. La mediana VV/VH de los FN es $-9{,}09 / -17{,}90$ dB; la de los TP, $-16{,}31 / -24{,}80$ dB. El modelo omite agua etiquetada cuya respuesta difiere de la del agua oscura. Vegetación inundada, rugosidad o doble rebote pueden cambiar la respuesta SAR [2]; no se identifican esos mecanismos únicamente por VV/VH. También deben considerarse incertidumbre de anotación y adquisición.

Fragmentación y bordes de cauces estrechos. En Bolivia_379434, el cauce sinuoso derecho presenta bandas próximas de FP y FN y tramos discontinuos. Se omite además una mancha central de agua. El chip tiene 5 588 FP, 6 528 FN e IoU 0.2602. El 81.25 % de los 12 116 errores cae en una banda de borde definida por dilatación/erosión binaria de la referencia con tres iteraciones. Esa concentración apoya un problema de detalle espacial; no demuestra un desplazamiento global de registro. Las transformaciones imagen/máscara fueron verificadas y se exportó sin remuestrear. Resolución efectiva, contexto del encoder y definición del límite son hipótesis adicionales, que deberían contrastarse con recortes y referencias independientes.

Los tres casos fueron inspeccionados técnicamente y registrados en qualitative_cases.csv; requieren revisión editorial del grupo. Los patrones pueden coexistir y sus conteos no representan categorías causales mutuamente excluyentes. No se afirma que una imagen oscura sea necesariamente agua o sombra.

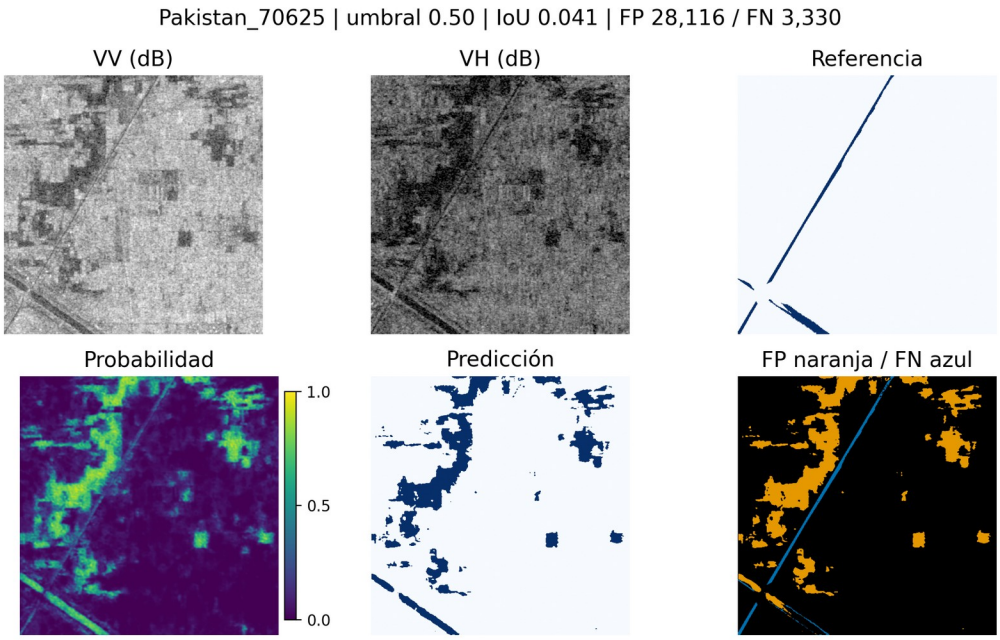


Figura 4: Pakistan_70625 (test): Se predicen manchas extensas en zonas oscuras sin agua en la referencia; el cauce diagonal fino queda parcialmente omitido.

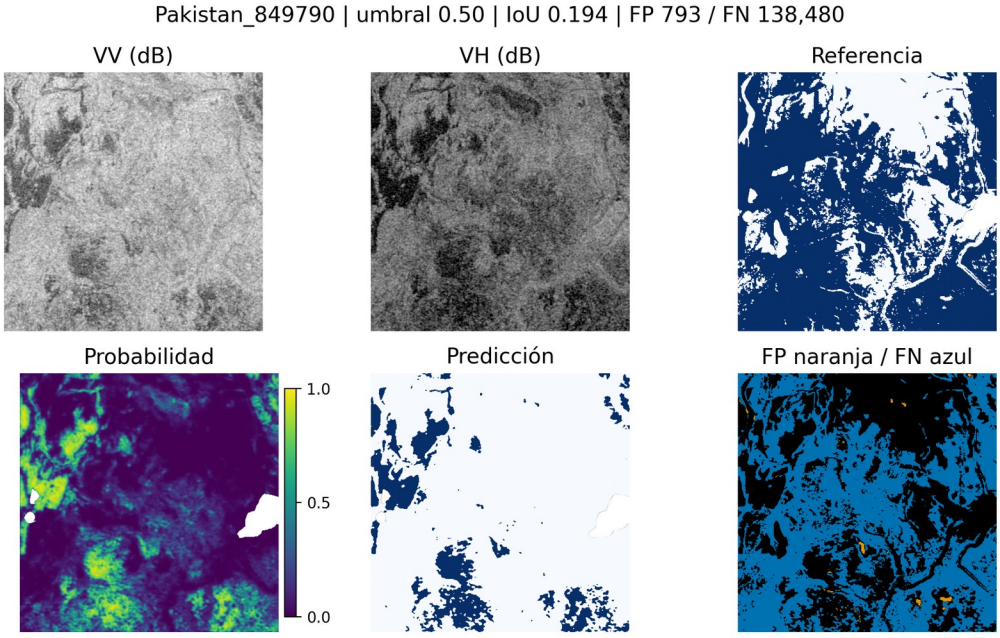


Figura 5: Pakistan_849790 (test): La referencia cubre gran parte del chip pero la predicción retiene pocas zonas oscuras; predominan falsos negativos en superficies de respuesta más alta.

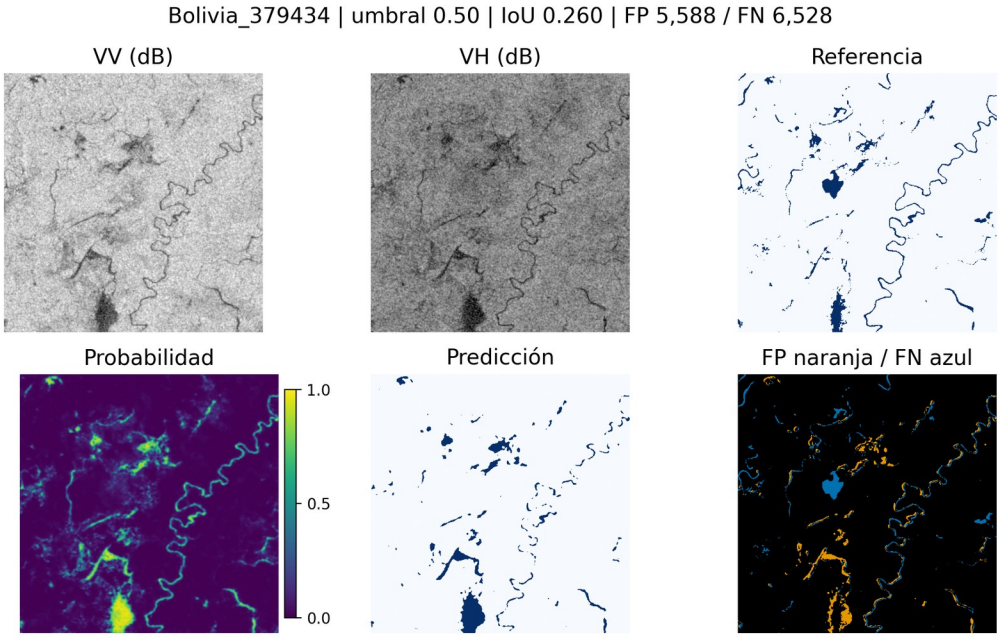


Figura 6: Bolivia_379434 (bolivia): En el cauce sinuoso derecho aparecen bandas cercanas de FP y FN y tramos fragmentados; también se omite una mancha central de agua.

7.2. Dos hipótesis de generalización

H1: cambia la distribución de apariencia y prevalencia del agua. Bolivia tiene 16.00 % de agua válida, frente a 12.30 % en prueba ID y 9.55 % en entrenamiento. Diferentes proporciones de agua abierta, canales y agua de respuesta alta pueden cambiar precisión, recall e IoU. Los ejemplos muestran que la respuesta del agua no es uniforme. Un test de esta hipótesis separaría resultados por cobertura, amplitud VV/VH y tamaño de regiones, usando anotaciones independientes. La prevalencia medida es evidencia descriptiva; no demuestra por sí sola una causa de la brecha.

H2: cambian adquisición y sesgo de etiquetas débiles. Los metadatos oficiales ubican Bolivia en órbita descendente relativa 156, el 15 de febrero de 2018. También hay adquisiciones descendentes en entrenamiento, por ejemplo India, Pakistán y Paraguay; por ello, la dirección descendente no explica por sí sola una diferencia externa. El número de órbita relativo y la geometría local podrían modificar la señal, pero no se dispone del ángulo de incidencia por chip. Además, las etiquetas débiles derivadas de umbralización SAR pueden reforzar la asociación entre agua y baja retrodispersión. Para contrastarlo se necesitarían geometría/incidencia, cobertura y una comparación con presupuesto igual de pasos, múltiples semillas y máscaras manuales adicionales. Bolivia representa un evento externo pequeño; una brecha positiva o negativa no aísla un efecto geográfico y no permite generalizar a todos los países. El baseline cualitativo es gold_bce, fijado antes de observar prueba o Bolivia.
Se inspeccionan candidatos de menor IoU y, cuando hace falta, casos con falsos positivos, falsos negativos o límites estrechos. Esta selección es intencional y no estima la frecuencia de causas en la población. Cada panel conserva el mismo rango VV/VH (-30 a 0 dB), probabilidad de 0 a 1 y el umbral fijo. Los mapas GeoTIFF exportados mantienen CRS y transformación original, con nodata -1.

8. Limitaciones, conclusiones y reproducción

La supervisión débil mejora la IoU principal en 0 de tres pérdidas en ID y en 2 de tres en Bolivia. La matriz permite observar sensibilidad a la pérdida y a la fuente de etiquetas, sin demostrar una mejora universal ni aislar el efecto de las etiquetas del número de actualizaciones. Los casos cualitativos muestran ambigüedad radiométrica, omisión de agua de respuesta alta y errores de detalle espacial. La evaluación externa debe conservar la agregación y el signo real de la brecha.

Una única semilla y quince chips externos no permiten afirmar significancia estadística ni estimar incertidumbre entre eventos independientes. Los chips pueden compartir evento y vecindad espacial; respetar los CSV oficiales no garantiza independencia por evento. La validación manual contiene menos de cien chips y orienta tanto selección como parada. La ponderación débil y el clipping son decisiones heurísticas fijadas previamente; el experimento no busca umbrales, profundidades o pesos óptimos. Para aislar el efecto de etiquetas débiles sería necesario igualar actualizaciones y repetir varias semillas.

La reproducción local usa parcial/scripts/run_flood.ps1, con Docker Desktop, WSL2 y GPU compatible con CUDA 12.8. El script construye el entorno, verifica la caché, ejecuta controles, prueba corta, seis experimentos, notebook e informe. La opción -Resume recupera el checkpoint de la última época terminada y rechaza cambios de firma de datos o configuración. Si aparece el entrenamiento del ejercicio 3, preserva el estado de inundaciones, espera y retoma. No detiene procesos ajenos. Las salidas quedan en E:/Kaggle/exam-output-flood; datos y resultados no se incluyen en Git.

El entorno usa Python 3.12, PyTorch 2.10.0, CUDA 12.8 y Rasterio 1.4.3. Los manifiestos, configuración congelada, hashes de fuente, historial, checkpoints, conteos por chip y metadatos de ejecución permiten rastrear cada cifra. Las pruebas cortas se guardan en otra carpeta y quedan excluidas del informe científico. El repositorio configurado es https://github.com/miguelsff/maestria-ia-uni-ciclo-2-redes-neuronales; las modificaciones locales requieren publicarse para que otra persona pueda reproducir esta revisión desde GitHub. La autoría real del grupo está pendiente de completar.

Referencias

[1] Derrick Bonafilia, Beth Tellman, Tyler Anderson, and Erica Issenberg. Sen1floods11: A georeferenced dataset to train and test deep learning flood algorithms for sentinel-1. In *CVPR Workshops*, 2020. https://github.com/cloudtostreet/Sen1Floods11.

[2] Africa Ixmuca Flores-Anderson, Kelsey E. Herndon, Rajesh Bahadur Thapa, and Emil Cherrington. *The SAR Handbook: Comprehensive Methodologies for Forest Monitoring and Biomass Estimation*. NASA SERVIR, 2019. https://ntrs.nasa.gov/citations/20190002563.

[3] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *ICLR*, 2019. https://arxiv.org/abs/1711.05101.

[4] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. V-net: Fully convolutional neural networks for volumetric medical image segmentation, 2016. https://arxiv.org/abs/1606.04797.

[5] Alexander Ratner, Stephen H. Bach, Henry Ehrenberg, Jason Fries, Sen Wu, and Christopher Ré. Snorkel: Rapid training data creation with weak supervision, 2017. https://arxiv.org/abs/1711.10160.

[6] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *MICCAI*, 2015. https://arxiv.org/abs/1505.04597.

[7] Yuxin Wu and Kaiming He. Group normalization. In *ECCV*, 2018. https://arxiv.org/abs/1803.08494.