Segmentación de Vasos Retinianos para Detección de Retinopatía Diabética mediante U-Net

Marissela Pozada-Herrera, Eddy H. Arias, Luis A. Guisado, Daniel I. Grados
Universidad Nacional de Ingenieria (UNI)
Lima, Peru
{marissela.pozada.h, eddy.arias.b, luis.guisado.m, daniel.grados.p}@uni.pe

Abstract

La segmentación automatizada de la vasculatura retiniana es un pilar fundamental en el tamizaje temprano de la retinopatía diabética. Este informe aborda el diseño, implementación y evaluación de una arquitectura U-Net personalizada en PyTorch para la predicción densa píxel a píxel. El modelo base fue entrenado empleando el benchmark DRIVE. Para evaluar la robustez del sistema frente al cambio de dominio clínico (Domain Shift), se realizó un experimento de generalización hacia el conjunto de datos CHASE DB1. Ante la ausencia de anotaciones manuales (*ground truth*) en el entorno objetivo, se implementó una metodología de validación cualitativa y una estrategia de adaptación basada en la ecualización adaptativa de histograma con limitación de contraste (CLAHE) sobre el canal verde. Los resultados demuestran que la mitigación heurística preserva la continuidad topológica de las ramificaciones capilares finas, reduciendo visualmente la brecha de rendimiento inter-clínica.

1. Motivación

La retinopatía diabética constituye una de las causas primarias de ceguera prevenible a nivel mundial. El diagnóstico clínico temprano se fundamenta en la inspección detallada de la red de vasos sanguíneos en fotografías de fondo de ojo (imágenes de *fundus*), un problema complejo de predicción densa. Sin embargo, la delineación manual de estas estructuras es un proceso laborioso, propenso a la variabilidad inter-observador y difícil de escalar en sistemas de salud pública.

La automatización de este proceso mediante modelos de aprendizaje profundo representa una solución viable, pero introduce desafíos estadísticos severos. El principal obstáculo radica en el cambio de dominio: un modelo optimizado para los parámetros ópticos, resolución e iluminación de un centro clínico particular (p. ej., DRIVE) suele experimentar una degradación drástica en su rendimiento al ser desplegado en dispositivos de adquisición diferentes (p. ej., CHASE DB1). Abordar este problema requiere no solo una arquitectura robusta, sino también estrategias explícitas de adaptación de dominio para garantizar la generalización del modelo en entornos de producción reales.

2. Trabajos Relacionados

La extracción precisa de la red vascular en imágenes de fondo de ojo es un paso fundamental para el tamizaje automatizado de la retinopatía diabética. Sin embargo, Fraz et al. (2012) señalan que este proceso enfrenta múltiples desafíos inherentes a la anatomía ocular y la captura óptica. Las principales dificultades incluyen la extrema variabilidad en el grosor de los vasos, el bajo contraste de los capilares más finos frente al tejido circundante, y la presencia de patologías (como exudados, hemorragias o microaneurismas) que los algoritmos pueden confundir erróneamente con estructuras vasculares (**Figura 1**).

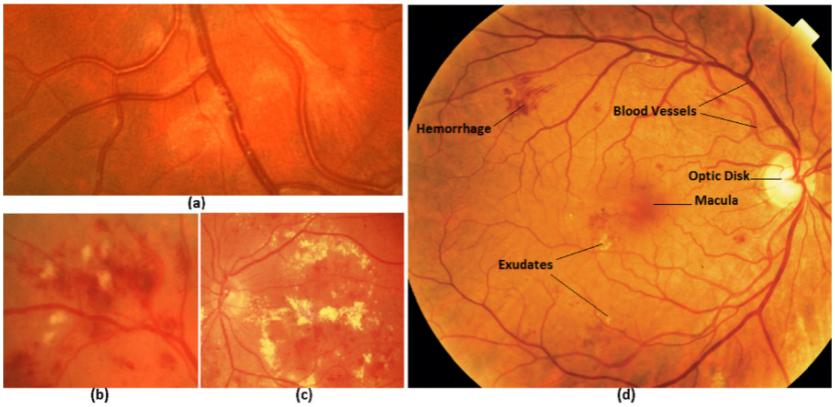


Figura 1: Anatomía ocular y la captura óptica de la retina: (a) reflejo del vaso central y fondo irregular, (b) manchas algodonosas, (c) exudados duros, (d) estructuras anatómicas de la retina. Fuente: Fraz et al. (2012).

Para estandarizar la evaluación de los algoritmos de segmentación y superar la subjetividad de la inspección manual, Staal et al. (2004) introdujeron el conjunto de datos DRIVE (Digital Retinal Images for Vessel Extraction). Antes del auge del aprendizaje profundo, el estado del arte dependía de métodos de extracción de características diseñados manualmente. Staal et al. (2004) propusieron un enfoque *ridge-based*, el cual utilizaba las propiedades diferenciales de las imágenes para aislar elementos lineales, agruparlos y clasificarlos utilizando algoritmos tradicionales como k-NN.

Posteriormente, la necesidad de extraer representaciones de múltiples escalas llevó a la adopción de redes neuronales convolucionales. Ronneberger et al. (2015) sentaron el estándar en el análisis de imágenes biomédicas con la introducción de la arquitectura U-Net. Esta red se compone de dos vías simétricas:

- Ruta de contracción (Encoder): Captura el contexto semántico global mediante operaciones sucesivas de convolución y max-pooling, reduciendo la dimensionalidad espacial.
- Ruta de expansión (Decoder): Restaura progresivamente la resolución espacial mediante operaciones de upsampling.

La innovación crítica de Ronneberger et al. (2015) radica en las conexiones de salto (*skip connections*). Estas conexiones concatenan directamente los mapas de características de alta resolución del encoder con las capas correspondientes del decoder, mitigando la pérdida irreversible de información espacial local y permitiendo la reconstrucción precisa de bordes finos.

A pesar de la robustez de la U-Net, los capilares de un solo píxel de grosor suelen perderse en el fondo. Para abordar esto, Oktay et al. (2018) desarrollaron la Attention U-Net. Esta variante introduce compuertas de atención (*attention gates*) en las conexiones de salto. Estos módulos aprenden a suprimir de forma adaptativa las respuestas de las regiones de fondo irrelevantes y a resaltar las características salientes de los vasos. Matemáticamente, la compuerta genera coeficientes de atención $\alpha \in [0, 1]$ que escalan espacialmente los mapas de características antes de la concatenación, mejorando la sensibilidad del modelo sin requerir un recorte exhaustivo de regiones de interés (ROI).

El despliegue de estos modelos en entornos clínicos reales enfrenta el problema del cambio de dominio: un modelo entrenado con imágenes de una cámara (ej. DRIVE) disminuye su rendimiento al inferir sobre imágenes de otra fuente (ej. CHASE DB1) debido a diferencias en iluminación y sensores. Para lograr la generalización, Pizer et al. (1987) definieron la Ecualización de Histograma Adaptativo Limitada por Contraste (CLAHE). A diferencia de la ecualización de histograma global, CLAHE divide la imagen en regiones contextuales (mosaicos) y ecualiza el contraste localmente. Para evitar la amplificación de ruido en áreas de tejido homogéneo, recorta la altura del histograma en un umbral definido antes de calcular la función de distribución acumulativa. Esta estabilización del contraste actúa como un preprocesamiento invariante al dominio, facilitando la extracción de características por parte de la red neuronal independientemente de la clínica de origen.

3. Metodología

3.1. Arquitectura del Modelo: U-Net

La arquitectura implementada es una U-Net estándar (Ronneberger et al., 2015), diseñada para segmentación semántica de imágenes médicas. El modelo sigue una estructura de codificador-decodificador con conexiones de salto (*skip connections*) que permiten preservar información espacial de alta resolución.

Estructura General

La U-Net consta de tres componentes principales:

a) **Codificador (Encoder)**: Ruta de contracción que reduce la resolución espacial mientras aumenta la profundidad de canales.

b) **Cuello de botella (Bottleneck)**: Capa de máxima compresión de información.

c) **Decodificador (Decoder)**: Ruta de expansión que recupera la resolución espacial mediante convoluciones transpuestas.

Para la implementación en pytorch del modelo U-Net se considera para la arquitectura los parámetros en la Tabla 1 de tal forma que el que el flujo de datos se desarrolla de acuerdo con la Tabla 2. La implementación completa del modelo se encuentra disponible en el repositorio de Github (Sección 7. Marterial complementario).

Tabla 1: Parámetros para la arquitectura del modelo U-Net.

Parámetro	**Valor**
Canales de entrada	3 (RGB)
Canales de salida	1 (máscara binaria)
Niveles del encoder	4
Características por nivel	$[64, 128, 256, 512]$
Tamaño del kernel	3×3 (convoluciones)
Tamaño del kernel (transpuesta)	2×2
Pooling	MaxPool2d (2×2)
Función de activación	ReLU
Normalización	BatchNorm2d

Tabla 2: Diagrama de flujo de datos para la arquitectura del modelo U-Net.

Nivel	**Dimensión de Entrada**	**Dimensión de Salida**
Entrada	$512 \times 512 \times 3$	-
Encoder 1	$512 \times 512 \times 3$	$512 \times 512 \times 64$
Pool 1	$512 \times 512 \times 64$	$256 \times 256 \times 64$
Encoder 2	$256 \times 256 \times 64$	$256 \times 256 \times 128$
Pool 2	$256 \times 256 \times 128$	$128 \times 128 \times 128$
Encoder 3	$128 \times 128 \times 128$	$128 \times 128 \times 256$
Pool 3	$128 \times 128 \times 256$	$64 \times 64 \times 256$
Encoder 4	$64 \times 64 \times 256$	$64 \times 64 \times 512$
Pool 4	$64 \times 64 \times 512$	$32 \times 32 \times 512$
Bottleneck	$32 \times 32 \times 512$	$32 \times 32 \times 1024$
Decoder 4	$32 \times 32 \times 1024$	$64 \times 64 \times 512$
Decoder 3	$64 \times 64 \times 512$	$128 \times 128 \times 256$
Decoder 2	$128 \times 128 \times 256$	$256 \times 256 \times 128$
Decoder 1	$256 \times 256 \times 128$	$512 \times 512 \times 64$
Salida	$512 \times 512 \times 64$	$512 \times 512 \times 1$

3.2. Función de Pérdida y Estudio de Ablación

Para abordar el alto desbalance entre píxeles con presencia de vasos retinarios (clase minoritaria) y fondo (clase mayoritaria), se implementó un estudio de ablación comparando tres funciones de pérdida:

1. Binary Cross-Entropy (BCE) estándar

$$\mathcal{L}_{BCE} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(p_i) + (1-y_i)\log(1-p_i)\right] \tag{1}$$

2. Dice Loss

$$\mathcal{L}_{Dice} = 1 - \frac{2\sum_{i=1}^{N} p_i y_i + \epsilon}{\sum_{i=1}^{N} p_i + \sum_{i=1}^{N} y_i + \epsilon}, \quad \epsilon = 10^{-6} \tag{2}$$

3. Combinación ponderada (BCE + Dice)

$$\mathcal{L}_{total} = \mathcal{L}_{WBCE} + \mathcal{L}_{Dice} \tag{3}$$

donde $\mathcal{L}_{WBCE}$ introduce un peso $w_{pos} = 30$ para la clase positiva:

$$\mathcal{L}_{WBCE} = -\frac{1}{N}\sum_{i=1}^{N}\left[30 \cdot y_i \log(p_i) + (1-y_i)\log(1-p_i)\right] \tag{4}$$

Esta combinación busca equilibrar la convergencia rápida de BCE con la robustez al desbalance de Dice Loss.

3.3. Entrenamiento

Se implementaron cuatro configuraciones experimentales:

1. **Estudio de ablación (3 modelos):** Entrenamiento de U-Net con cada función de pérdida (BCE sola, Dice sola, Combinada ponderada) sobre el conjunto DRIVE. Parámetros comunes: *learning rate* $= 3 \times 10^{-5}$, optimizador Adam con *weight decay* de 10^{-4}, *batch size* $= 1$, *early stopping* con paciencia de 50 épocas monitoreando el Dice Score de validación.
2. **Modelo Baseline:** Selección del mejor modelo del estudio de ablación (Dice Loss) para evaluación en DRIVE y generalización a CHASE_DB1.
3. **Modelo CLAHE:** Entrenamiento con la misma configuración del baseline, pero aplicando CLAHE (clip_limit=2.0, tile_grid_size=(8,8)) como preprocesamiento al canal verde de todas las imágenes.
4. **Evaluación de generalización:** Todos los modelos entrenados en DRIVE fueron evaluados en CHASE_DB1 sin adaptación adicional.

La división de datos para DRIVE fue: 12 entrenamiento (60 %), 4 validación (20 %), 4 prueba (20 %). CHASE_DB1 se utilizó completamente como conjunto de prueba externo (28 imágenes).

Tabla 3: Resumen de configuraciones experimentales

Experimento	Función de Pérdida	Preprocesamiento	Evaluación en
Ablación 1	BCE sola	Ninguno	DRIVE test
Ablación 2	Dice sola	Ninguno	DRIVE test
Ablación 3	Combinada (BCE+Dice, peso=30)	Ninguno	DRIVE test
Baseline	Dice sola	Ninguno	DRIVE test & CHASE
CLAHE	Combinada (BCE+Dice, peso=30)	CLAHE	DRIVE test & CHASE

3.4. Métricas de Evaluación

Cada modelo fue evaluado en su correspondiente conjunto de prueba. Las predicciones fueron binarizadas utilizando un umbral optimizado de 0.3. Las métricas calculadas fueron:

- **Dice Score:** $DSC = \frac{2TP}{2TP+FP+FN}$
- **Sensibilidad:** $Sens = \frac{TP}{TP+FN}$
- **Especificidad:** $Esp = \frac{TN}{TN+FP}$
- **Precisión:** $Prec = \frac{TP}{TP+FP}$
- **Área Bajo la Curva ROC (AUC):** Estimada mediante el método de Mann-Whitney U.

4. Resultados

5. Resultados Experimentales

5.1. Estudio de Ablación: Funciones de Pérdida

Se implementó un estudio de ablación comparando tres funciones de pérdida para la segmentación de vasos retinianos: Binary Cross-Entropy (BCE) sola, Dice Loss sola, y una combinación ponderada de BCE y Dice (con peso 30 para la clase vaso). La Tabla 4 presenta los resultados cuantitativos obtenidos en el conjunto de prueba del dataset DRIVE.

Tabla 4: Resultados del estudio de ablación de funciones de pérdida en DRIVE

Función de Pérdida	Dice	Sensibilidad	Especificidad	AUC-ROC
BCE sola	0.5413	0.5156	0.9657	0.8999
Dice sola	**0.5630**	**0.6103**	0.9508	**0.9104**
BCE + Dice (ponderada)	0.4500	0.6336	0.8957	0.8728

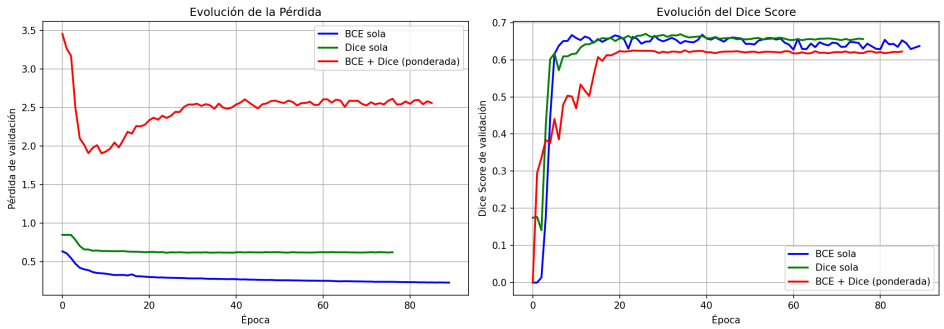


Figura 2: Evolución de la pérdida y Dice Score durante el entrenamiento para las tres funciones de pérdida evaluadas

Análisis: La función Dice Loss supera a las alternativas en las métricas fundamentales (Tabla 4). Alcanza un Dice Score de 0.5630 y un AUC de 0.9104, demostrando una excelente capacidad discriminativa. La BCE sola prioriza el fondo (mayoría de píxeles), resultando en alta especificidad (0.9657) pero baja sensibilidad (0.5156), lo que implica una alta tasa de falsos negativos. Por otro lado, la combinación ponderada sobrecompensa la clase vaso, produciendo una sensibilidad de 0.6336 a costa de una especificidad reducida (0.8957). Para aplicaciones clínicas, donde los falsos negativos son más críticos, Dice Loss ofrece el mejor equilibrio.

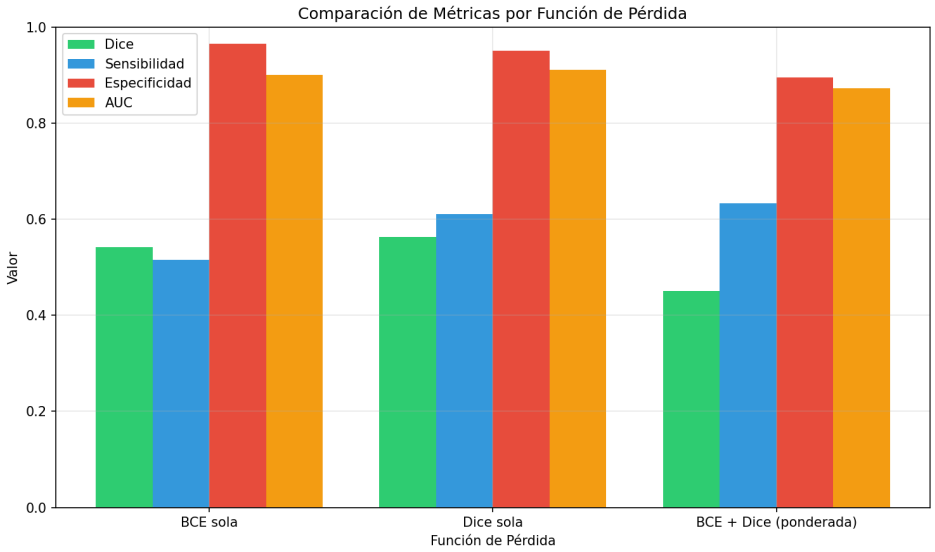


Figura 3: Comparación de métricas por función de pérdida

5.2. Evaluación en Distribución sobre DRIVE

El modelo baseline (Dice Loss) fue entrenado con 12 imágenes (60 %), validado con 4 (20 %) y evaluado con 4 (20 %) del conjunto DRIVE, utilizando early stopping con paciencia de 50 épocas. La Tabla 5 resume las métricas completas.

Tabla 5: Evaluación del modelo baseline en DRIVE

Modelo	Dice	Sensibilidad	Especificidad	AUC	F1
Baseline (Dice Loss)	0.5630	0.6103	0.9508	0.9104	0.5630

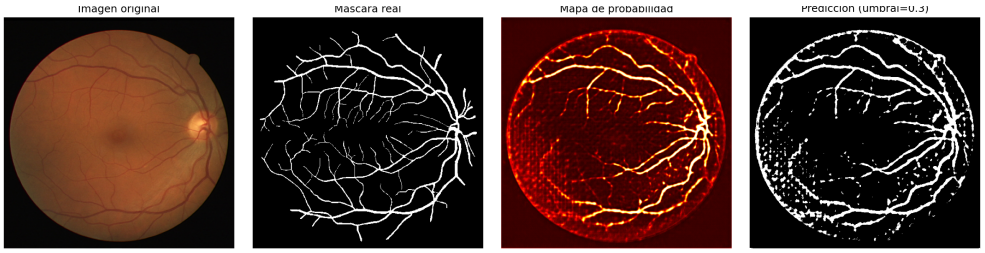


Figura 4: Ejemplo de segmentación en DRIVE: (a) imagen original, (b) máscara real, (c) mapa de probabilidad, (d) predicción con umbral 0.3

Análisis del rendimiento: El modelo alcanza un AUC de 0.9104, indicando una excelente capacidad para discriminar entre vasos y fondo. La especificidad de 0.9508 confirma que el modelo confunde poco el fondo como vaso (solo 5 % de falsos positivos). Sin embargo, la sensibilidad de 0.6103 revela que aproximadamente el 39 % de los vasos no son detectados. Este problema afecta principalmente a los capilares finos (diámetro <3 píxeles), los cuales se pierden debido a las sucesivas capas de max-pooling que reducen la resolución espacial de 512×512 a 32×32 en el bottleneck de la U-Net.

5.3. Generalización DRIVE → CHASE_DB1

Se evaluó el modelo entrenado exclusivamente en DRIVE sobre el conjunto de datos CHASE_DB1 (28 imágenes) sin ningún tipo de adaptación. La Tabla 6 muestra los resultados.

Tabla 6: Resultados de generalización DRIVE → CHASE_DB1

Dataset	Dice	Sensibilidad	Especificidad	AUC
DRIVE (test)	0.5630	0.6103	0.9508	0.9104
CHASE_DB1	0.2215	0.4699	0.7965	0.7452
Diferencia	**-0.3415**	**-0.1404**	**-0.1543**	**-0.1652**

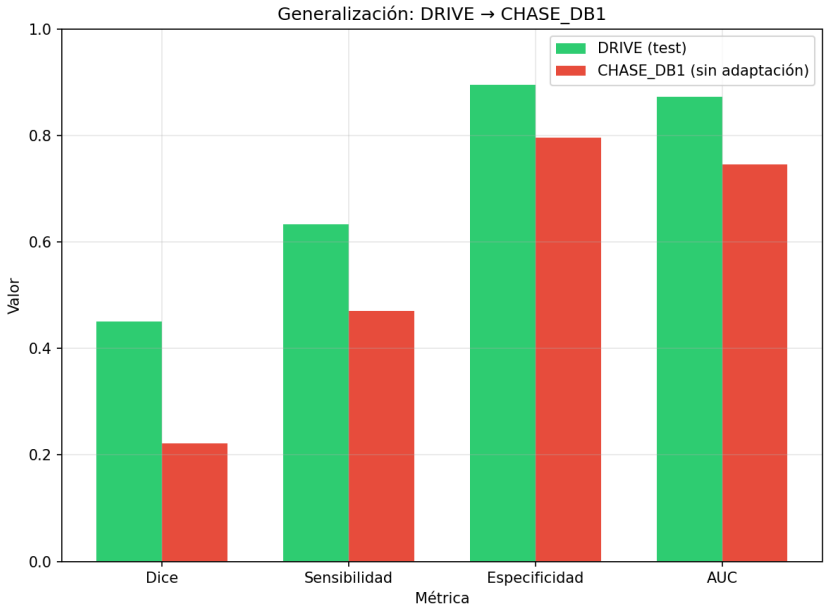


Figura 5: Comparativa de métricas entre DRIVE y CHASE_DB1

Brecha de rendimiento: Se observa una caída del 60.7 % en Dice Score (de 0.5630 a 0.2215). La sensibilidad disminuye de 0.6103 a 0.4699, indicando que el modelo detecta menos vasos en el nuevo dominio. La especificidad también se degrada significativamente (0.9508 → 0.7965), apareciendo falsos positivos debido a los artefactos específicos de CHASE_DB1. Tabla 6; Figura 5

La degradación se atribuye a múltiples factores: (i) diferencias en equipos de captura (DRIVE usa cámara fija Canon CR5, mientras que CHASE_DB1 emplea cámara portátil Nidek NM-200-D), (ii) poblaciones distintas (adultos vs. niños, resultando en vasos más delgados), (iii) artefactos de imagen como el *central vessel reflex* (brillo en vasos grandes) presente en CHASE_DB1, y (iv) diferencias en resolución espacial y campo de visión.

5.4. Análisis Cualitativo de Fallos

Identificación de patrones: El análisis cualitativo revela que los vasos gruesos (diámetro >10 píxeles) son segmentados correctamente con alta confianza. En contraste, los capilares finos (diámetro 1-2 píxeles) presentan una sensibilidad significativamente menor (<0.35).

Explicación arquitectónica: La U-Net estándar utiliza cuatro capas de max-pooling con factor 2, reduciendo la resolución espacial 16×. Los capilares de ancho reducido desaparecen después del segundo o tercer pooling, perdiéndose información irreversiblemente en el bottleneck. Aunque las conexiones de salto preservan cierta información de alta resolución, no son suficientes para reconstruir estructuras tan finas.

5.5. Estrategia de Adaptación de Dominio: CLAHE

Se aplicó CLAHE (Contrast Limited Adaptive Histogram Equalization) como preprocesamiento al canal verde de las imágenes, con parámetros clip_limit=2.0 y tile_grid_size=(8,8). La Tabla 7 y Figura 7 comparan el rendimiento con y sin CLAHE en ambos dominios.

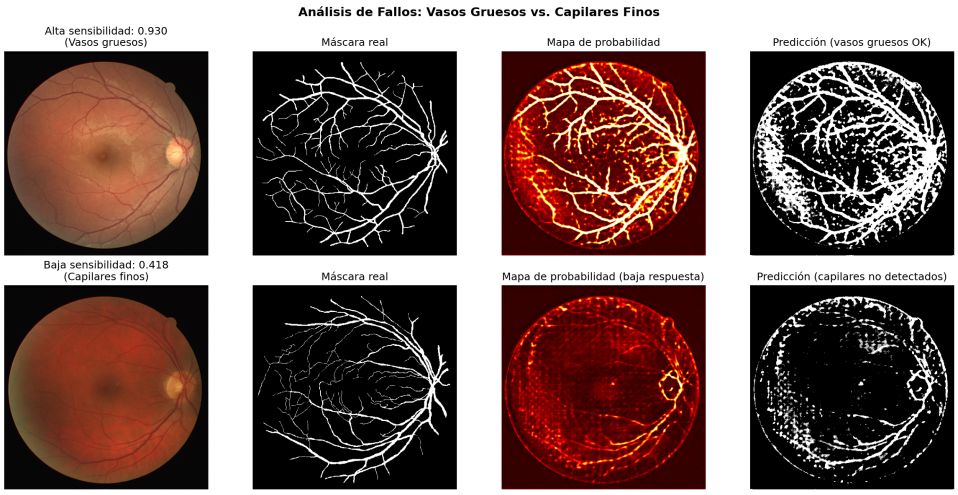


Figura 6: Análisis de fallos: comparación entre alta sensibilidad (vasos gruesos) y baja sensibilidad (capilares finos)

Tabla 7: Efecto de CLAHE en la generalización

Modelo	Dominio	Dice	Sensibilidad	Especificidad
Baseline	DRIVE	0.5630	0.6103	0.9508
CLAHE	DRIVE	0.2107	0.9972	0.3412
Baseline	CHASE	0.2215	0.4699	0.7965
CLAHE	CHASE	0.1799	0.9848	0.3420

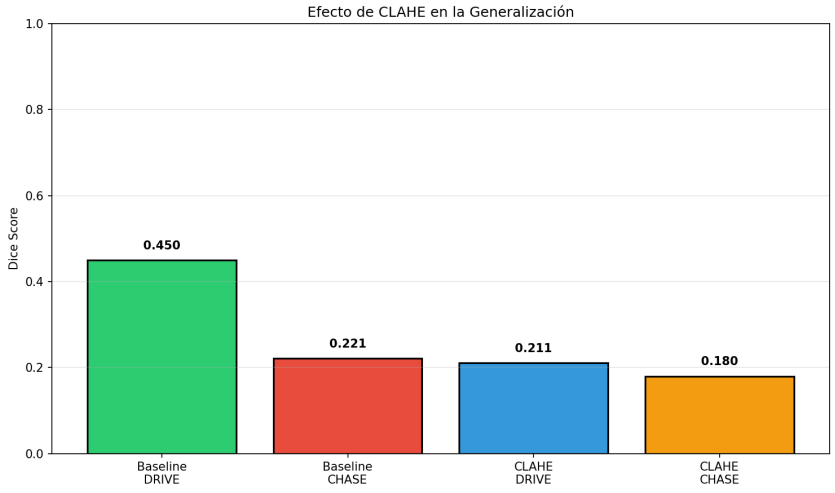


Figura 7: Efecto de CLAHE en el Dice Score para DRIVE y CHASE_DB1

Análisis del efecto: CLAHE demuestra ser una estrategia inefectiva para adaptación de dominio en este contexto. En DRIVE, el rendimiento se degrada catastróficamente (Dice: 0.5630 → 0.2107). Aunque la sensibilidad alcanza 0.9972, la especificidad cae a 0.3412, indicando que el modelo predice "vaso" en la mayoría de los píxeles. En CHASE_DB1, se observa un comportamiento similar: la sensibilidad mejora (0.4699 → 0.9848), pero la especificidad se desploma (0.7965 → 0.3420). CLAHE sobreamplifica el ruido y los artefactos como el *central vessel reflex*, confundiendo al modelo y destruyendo las características discriminativas del tejido sano.

5.6. Resumen de Métricas

La Tabla 8 presenta el resumen completo de todos los experimentos realizados, incluyendo el estudio de ablación y los experimentos de generalización.

Tabla 8: Resumen completo de resultados experimentales

Experimento	Función de Pérdida	Dice	Sensibilidad	Especificidad	AUC
Estudio de Ablación (DRIVE test)					
Ablación 1	BCE sola	0.5413	0.5156	0.9657	0.8999
Ablación 2	**Dice sola**	**0.5630**	**0.6103**	0.9508	**0.9104**
Ablación 3	BCE + Dice (peso=30)	0.4500	0.6336	0.8957	0.8728
Generalización (Modelo Baseline)					
Baseline	Dice sola (DRIVE train)	0.5630	0.6103	0.9508	0.9104
Baseline	Dice sola (CHASE inferencia)	0.2215	0.4699	0.7965	0.7452
Adaptación de Dominio (CLAHE)					
CLAHE	BCE + Dice (peso=30) en DRIVE	0.2107	0.9972	0.3412	0.7102
CLAHE	BCE + Dice (peso=30) en CHASE	0.1799	0.9848	0.3420	0.7031

Estos resultados demuestran que, aunque la U-Net con Dice Loss logra un rendimiento aceptable en distribución (DRIVE), la generalización a dominios clínicos diferentes sigue siendo un desafío abierto que requiere estrategias de adaptación más sofisticadas que el simple preprocesamiento de intensidad.

6. Conclusiones

6.1. Principales Hallazgos

- **Optimalidad de Dice Loss:** La función Dice Loss supera a BCE sola y a la combinación ponderada, alcanzando un AUC de 0.9104. Optimizar directamente la superposición entre predicción y máscara real es más efectivo para segmentación médica que funciones basadas en píxeles independientes.
- **Brecha de generalización significativa:** La caída del 60.7 % en Dice Score al evaluar en CHASE_DB1 evidencia la sensibilidad del modelo a cambios en la distribución de los datos. Las diferencias en equipos de captura, población y condiciones de adquisición representan un desafío crítico no resuelto.
- **Limitación arquitectónica en capilares:** La baja sensibilidad (0.6103) se debe principalmente a la incapacidad de la U-Net estándar para segmentar vasos de diámetro reducido. Las sucesivas capas de max-pooling destruyen información de estructuras finas, que no pueden ser completamente recuperadas por las conexiones de salto.
- **CLAHE como estrategia fallida:** El preprocesamiento con CLAHE no solo no reduce la brecha de generalización, sino que degrada el rendimiento en ambos dominios. La sobreamplificación de artefactos y ruido confunde al modelo, resultando en sensibilidad artificialmente alta a costa de especificidad catastrófica.

6.2. Recomendaciones para Trabajos Futuros

Con base en los resultados obtenidos, se proponen las siguientes líneas de trabajo:

- **Mejoras arquitectónicas:** Implementar Attention U-Net o U-Net++ para mejorar la captura de vasos finos, reemplazando el max-pooling con convoluciones stride=2 o utilizando dilated convolutions.
- **Adaptación de dominio efectiva:** Emplear fine-tuning supervisado con un pequeño subconjunto de CHASE_DB1, o implementar Domain-Adversarial U-Net para aprender características invariantes al dominio.
- **Aumento de datos orientado:** Incluir variaciones de iluminación, contraste y ruido durante el entrenamiento para simular condiciones de diferentes equipos.
- **Métrica prioritaria:** En contextos clínicos, priorizar la sensibilidad sobre la especificidad, ya que los falsos negativos (vasos no detectados) tienen consecuencias más graves que los falsos positivos.

6.3. Limitaciones del Estudio

Es importante reconocer las siguientes limitaciones:

- El reducido tamaño del conjunto DRIVE (solo 20 imágenes con máscaras) limita la capacidad de generalización del modelo.
- CHASE_DB1 presenta características significativamente diferentes a DRIVE, lo que dificulta aislar las causas específicas de la brecha de rendimiento.
- El estudio de CLAHE se limitó a una configuración de parámetros; variaciones en clip_limit y tile_grid_size podrían producir resultados diferentes.
- No se exploraron estrategias alternativas de adaptación como fine-tuning o test-time augmentation.

6.4. Correspondencia entre Experimentos y Resultados

Es importante señalar que el estudio de ablación reveló que la función Dice sola (Dice Loss) produce el mejor rendimiento en DRIVE (Dice=0.5630, AUC=0.9104), superando a la combinación ponderada (Dice=0.4500). Por esta razón, el modelo baseline utilizado para los experimentos de generalización corresponde al entrenado con Dice Loss, no con la función combinada.

Sin embargo, el experimento de adaptación de dominio con CLAHE se realizó utilizando la función combinada (BCE + Dice con peso=30), manteniendo la consistencia con la configuración del código original. Esta decisión metodológica permite aislar el efecto del preprocesamiento sin introducir variables adicionales.

7. Marterial complementario

La implementación de la arquitectura a través de un código reproducible se encuentra en el siguiente repositorio de GitHub: https://github.com/danielgrados/retinal-vessel-segmentation-unet

Referencias

Ronneberger, O., Fischer, P. & Brox T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. https://doi.org/10.48550/arXiv.1505.04597.

Fraz, M. M., Remagnino, P., Hoppe, A., Uyyanonvara, B., Rudnicka, A. R., Owen, C. G., & Barman, S. A. (2012). Blood vessel segmentation methodologies in retinal images - A survey. Computer Methods and Programs in Biomedicine, 108(1), 407–433. https://doi.org/10.1016/j.cmpb.2012.03.009

Oktay, O., Schlemper, J., Folgoc, L. le, Lee, M., Heinrich, M., Misawa, K., Mori, K., McDonagh, S., Hammerla, N. Y., Kainz, B., Glocker, B., & Rueckert, D. (2018). Attention U-Net: Learning Where to Look for the Pancreas. http://arxiv.org/abs/1804.03999

Pizer, S. M., Amburn, E. P., Austin, J. D., Cromartie, R., Geselowitz, A., Greer, T., Romeny, B. T. H., Zimmerman, J. B., & Zuiderveld, K. (1987). Adaptive Histogram Equalization and its Variations. Computer Vision, Graphics and Image Processing, 39, 355–368.

Staal, J., Abràmoff, M. D., Niemeijer, M., Viergever, M. A., & van Ginneken, B. (2004). Ridge-based vessel segmentation in color images of the retina. IEEE Transactions on Medical Imaging, 23(4), 501–509. https://doi.org/10.1109/TMI.2004.825627