Examen Parcial de Redes Neuronales y Aprendizaje Profundo

Ph.D. Aldo Camargo

Este es un proyecto de grupo. **Cada grupo debe estar conformado por 5 estudiantes.** Cada pregunta requiere un informe escrito (6–10 páginas) y un repositorio de código reproducible entregado a través de GitHub. Los informes deben incluir: motivación, trabajos relacionados (mínimo 5 referencias), metodología, experimentos, resultados y una discusión crítica de las limitaciones. Se pueden utilizar pesos preentrenados del backbone donde se indique, pero los componentes principales de la arquitectura deben ser implementados por el estudiante. El plagio de cualquier tipo — incluyendo el de cuadernos públicos — resultará en la reprobación automática del curso.
Duración del proyecto: aproximadamente 5 semanas a partir de la fecha de asignación de este examen (ver fecha límite al final del documento).

Pregunta 1 — Clasificación Multietiqueta de Anomalías de Rodilla en Resonancia Magnética (CNN + Aprendizaje Débilmente Supervisado)

Enunciado del Problema

La resonancia magnética (MRI) de rodilla es el estudio de referencia para evaluar lesiones de ligamentos, meniscos, cartílago y otras estructuras articulares, pero su interpretación depende de radiólogos especializados y está sujeta a variabilidad inter-observador. Los estudiantes deben desarrollar un modelo de **clasificación multietiqueta** (multi-label) basado en redes neuronales convolucionales, capaz de predecir simultáneamente la presencia de **doce hallazgos clínicamente relevantes** a partir de series de imágenes de MRI de rodilla.

A diferencia de las Preguntas 2 y 3, este problema tiene una dificultad adicional que lo hace especialmente interesante desde el punto de vista de aprendizaje profundo aplicado: **solo una fracción muy pequeña del conjunto de datos cuenta con etiquetas "doradas" verificadas por un experto**. La gran mayoría de los estudios solo cuentan con el **reporte radiológico en texto libre** (en uno de aproximadamente doce idiomas distintos) que acompaña al estudio, y no con una etiqueta estructurada. Esto convierte al problema en un caso realista de **aprendizaje con etiquetas débiles/ruidosas** (weak supervision), donde parte del trabajo del grupo consiste en construir su propio pipeline de extracción de etiquetas a partir del texto clínico, antes incluso de poder entrenar el clasificador de imágenes.

El proyecto no se limita a entrenar un clasificador multietiqueta: los estudiantes deben explorar al menos **dos arquitecturas diferentes** (por ejemplo, una CNN 2D/2.5D entrenada desde cero sobre cortes de la serie de MRI, y un modelo preentrenado en ImageNet con fine-tuning, como ResNet-50 o EfficientNet, adaptado a doce salidas sigmoides), comparar su rendimiento de forma rigurosa, e interpretar las decisiones del modelo mediante Grad-CAM sobre casos representativos de cada hallazgo.

Conjunto de Datos

RSNA Knee Abnormality Detection — competencia pública de Kaggle, organizada por la Radiological Society of North America (RSNA), disponible en: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection

Características del conjunto (verificadas a partir de la página de la competencia y material de difusión de RSNA):

Estudios de MRI de rodilla en formato DICOM, organizados jerárquicamente en studies → series → instances. Tamaño total reportado: aproximadamente 569.76 GB / 819,640 archivos DICOM.

Cada estudio está emparejado con su reporte radiológico original en texto libre, en aproximadamente doce idiomas distintos, proveniente de 16 centros en cinco continentes — es el primer conjunto de datos de un reto de RSNA que empareja cada estudio de imagen con su reporte clínico original.

Doce hallazgos objetivo (a confirmar con el esquema exacto de la pestaña “Data” de la competencia antes de fijar la rúbrica de evaluación): lesión de ligamento cruzado anterior (LCA), lesión de ligamento colateral medial, daño de menisco medial, daño de menisco lateral, osteoartrosis del compartimento medial, osteoartrosis del compartimento lateral, osteoartrosis patelofemoral, derrame articular (effusion), sinovitis, quiste de Baker, contusión ósea y fractura.

Solo del orden de 58 estudios cuentan con etiquetas doradas anotadas por radiólogos; el resto de las etiquetas de entrenamiento deben derivarse del texto de los reportes.

Métrica oficial de la competencia: AUC-ROC macro-promediado, con las doce etiquetas ponderadas por igual.

Nota importante para los estudiantes. La competencia sigue activa (cierre de envíos: 22 de octubre de 2026) y su formato es de tipo Code Competition sobre Kaggle Notebooks. Este examen no requiere enviar una solución al leaderboard de Kaggle; el conjunto de datos se usa únicamente como fuente de datos reales para el proyecto del curso. Cada estudiante debe crear una cuenta gratuita en Kaggle y aceptar las reglas de la competencia para poder descargar los datos. Antes de iniciar, el grupo debe revisar la pestaña “Rules” de la competencia para confirmar las condiciones de uso de los datos fuera del contexto de la competencia.

Reducción de Escala Recomendada

Dado el tamaño del conjunto completo (más de 800,000 archivos DICOM) y el plazo de 4 semanas, **no se espera que los grupos procesen el conjunto de datos completo**. Se recomienda explícitamente:

Restringir el trabajo a uno o dos planos/secuencias de MRI (por ejemplo, sagital DP/T2 con supresión de grasa), en vez de usar todas las series disponibles por estudio.

Trabajar con cortes 2D (o un pequeño volumen 2.5D de cortes contiguos) en lugar del volumen 3D completo.

Construir un subconjunto estratificado de estudios (sugerido: entre 300 y 600 estudios) en lugar de los 819,640 archivos totales, asegurando representación de casos positivos para cada uno de

los doce hallazgos.

Reservar los ∼58 estudios con etiqueta dorada como conjunto de validación limpio, y usar una muestra de estudios con etiquetas derivadas del texto como conjunto de entrenamiento (posiblemente ruidoso).

Entregables Requeridos

1. **Pipeline de extracción de etiquetas débiles.** Diseñar e implementar un método (basado en reglas/palabras clave multilingües, o en *embeddings* multilingües con clasificación de texto de bajo costo) que extraiga las doce etiquetas objetivo a partir de los reportes en texto libre. Validar este pipeline comparando sus etiquetas contra los estudios con etiqueta dorada, y reportar una tasa de acuerdo/ruido estimada.

2. Implementación y entrenamiento de al menos dos arquitecturas de clasificación multietiqueta: una CNN diseñada desde cero (2D o 2.5D) y una basada en transfer learning con backbone preentrenado en ImageNet, adaptado con doce salidas sigmoides independientes.

3. Evaluación con la métrica oficial de la competencia (AUC-ROC macro-promediado sobre las doce etiquetas) y desglose por etiqueta, usando el conjunto de validación de etiqueta dorada. Incluir además precisión, recall y F1 a un umbral elegido y justificado.

4. Estudio de ablación sobre al menos dos factores: elección de secuencia/plano de MRI, función de pérdida (BCE estándar vs. pérdida focal, dado el desbalance esperado en hallazgos raros como fractura o quiste de Baker), estrategia de manejo de etiquetas ruidosas (por ejemplo, ponderar por confianza vs. entrenar solo con estudios de alta confianza), o profundidad del backbone.

5. Análisis de interpretabilidad mediante Grad-CAM: mostrar mapas de activación para al menos tres hallazgos distintos y discutir si las regiones resaltadas son anatómicamente plausibles (por ejemplo, si el mapa para “daño de menisco” efectivamente resalta la región meniscal).

6. Análisis del desbalance de clases: cuantificar la prevalencia de cada uno de los doce hallazgos en la muestra usada, e implementar y evaluar al menos una estrategia de mitigación para los hallazgos más raros.

7. Discusión breve (media página) sobre el riesgo de sesgo geográfico/lingüístico: dado que los datos provienen de 16 centros en cinco continentes con reportes en distintos idiomas, comentar cómo la calidad de la extracción de etiquetas podría variar entre idiomas y qué implicancias tendría esto en un despliegue clínico real.

Pregunta 2 — Mapeo de Inundaciones a partir de Radar Satelital Sentinel-1 (U-Net)

Enunciado del Problema

Durante un evento de inundación, saber *dónde* está el agua en las horas siguientes al desastre es crítico para la respuesta de emergencia — y las nubes que suelen acompañar a las tormentas hacen inútiles a los satélites ópticos justo cuando más se los necesita. El radar de apertura sintética (SAR),

como el del satélite Sentinel-1, atraviesa las nubes y puede adquirir imágenes de noche, lo que lo convierte en la herramienta de facto para el mapeo rápido de inundaciones (un problema relevante también para el Perú, donde eventos como El Niño costero generan inundaciones repentinas que deben mapearse con imágenes disponibles de inmediato). Los estudiantes deben implementar una U-Net (o una variante mejorada como Attention U-Net o U-Net++) para segmentar, píxel a píxel, la extensión del agua de inundación a partir de imágenes SAR de Sentinel-1.

El reto no es solo arquitectónico: al igual que en la Pregunta 1, **no todas las etiquetas del conjunto de datos son igualmente confiables**. El dataset distingue explícitamente entre un pequeño subconjunto de *chips* etiquetados a mano por expertos y un subconjunto mucho más grande con etiquetas generadas automáticamente mediante algoritmos clásicos de umbralización — ruidosas, pero abundantes. Los estudiantes deben decidir, y justificar empíricamente, cómo combinar ambas fuentes de supervisión. Además, el propio dataset reserva un país completo como conjunto de prueba geográficamente independiente, lo que permite — igual que en las demás preguntas de este examen — evaluar qué tan bien generaliza el modelo a una región nunca vista durante el entrenamiento.

Conjunto de Datos

Sen1Floods11 — dataset georreferenciado desarrollado por Cloud to Street y la NASA para entrenar y evaluar algoritmos de detección de inundaciones sobre Sentinel-1. Disponible en: https://github.com/cloudtostreet/Sen1Floods11

Características verificadas:

Cubre 11 eventos de inundación en distintos países, continentes y biomas. Cada evento incluye imágenes Sentinel-1 SAR (bandas VV y VH, en dB) y su contraparte óptica Sentinel-2 (13 bandas espectrales), en chips de 512×512 px a 10 m de resolución (formato GeoTIFF).

446 chips con etiqueta “dorada”: máscaras binarias (agua / no agua / sin datos) anotadas a mano por expertos.

4,385 chips con etiqueta débil derivada de Sentinel-1 y otros 4,385 derivados de Sentinel-2, generados mediante algoritmos clásicos de umbralización (no por un humano) — una fuente de entrenamiento mucho mayor, pero ruidosa.

Los autores del dataset reservan todos los chips con etiqueta dorada de Bolivia como conjunto de prueba geográficamente independiente, específicamente para medir la generalización a un evento de inundación no visto durante el entrenamiento.

Métrica de referencia usada por los autores: IoU (Intersection over Union) promedio sobre los chips, junto con tasas de omisión y comisión.

Entregables Requeridos

1. Implementación personalizada de U-Net en PyTorch (sin copiar código de bibliotecas de segmentación existentes), que reciba como entrada al menos las dos bandas SAR (VV, VH).

2. Estudio de ablación que compare al menos dos decisiones: (a) entrenar solo con los 446 chips de etiqueta dorada vs. añadir los chips de etiqueta débil al entrenamiento, y (b) función de

pérdida (BCE vs. Dice vs. combinada) u otra decisión arquitectónica (profundidad, diseño de las conexiones de salto).

3. Evaluación en distribución (chips dorados de eventos vistos durante entrenamiento): IoU, F1, precisión y recall de la clase “agua”, más matriz de confusión comentada.

4. Experimento de generalización geográfica: entrenar excluyendo Bolivia, evaluar únicamente sobre los chips dorados de Bolivia (siguiendo la partición oficial del dataset). Reportar la brecha de rendimiento frente al punto 3 y proponer al menos dos hipótesis sobre su causa (tipo de cobertura del suelo, ángulo de incidencia del radar, urbanización vs. vegetación inundada, etc.).

5. Análisis cualitativo de fallos característicos del SAR: identificar y explicar al menos tres tipos de error (p. ej. sombra de radar, doble rebote en zonas urbanas inundadas, confusión entre suelo húmedo y agua abierta) con ejemplos visuales concretos.

6. Comparación opcional (bono): añadir las bandas ópticas de Sentinel-2 como canales adicionales de entrada en los chips donde estén libres de nubes, y cuantificar si la fusión SAR+óptico mejora el IoU frente al modelo solo-SAR.

Pregunta 3 — Monitoreo de Fauna Silvestre con Cámaras Trampa (YOLO)

Enunciado del Problema

Las cámaras trampa (activadas por movimiento, sin operador humano) son hoy la herramienta más usada para monitorear biodiversidad en áreas protegidas — incluyendo programas de conservación en la Amazonía y los Andes peruanos — pero generan más imágenes de las que un equipo humano puede revisar manualmente. Los estudiantes deben entrenar y evaluar un modelo YOLO (se recomienda YOLOv8 o YOLOv9) para detectar y clasificar la especie de los animales presentes en fotografías de cámaras trampa.

La tarea tiene varias dificultades que van más allá de la detección de objetos estándar: un **desbalance de clases extremo** (la gran mayoría de las fotografías activadas por el sensor de movimiento no contienen ningún animal, y entre las que sí, algunas especies son mucho más raras que otras), **oclusión por vegetación**, animales **pequeños o lejanos** respecto al sensor, y un problema de **generalización geográfica particularmente severo**: los modelos de reconocimiento de fauna en cámaras trampa tienden a memorizar el fondo característico de cada cámara (una roca, un tronco, un patrón de iluminación) en lugar de aprender rasgos reales del animal, por lo que su desempeño cae fuertemente al desplegarse en una cámara o locación nueva.

Además del detector, los estudiantes deben implementar un **módulo de posprocesamiento de monitoreo ecológico**: un sistema basado en reglas que agregue las detecciones por fotograma en un reporte de actividad por cámara y por especie (conteo de detecciones, especies distintas observadas, tasa de fotografías vacías vs. con fauna), tal como lo usaría un equipo de manejo de fauna silvestre.

Conjunto de Datos

Caltech Camera Traps (CCT-20) — disponible a través de LILA BC (Labeled Information
Library of Alexandria: Biology and Conservation), el repositorio abierto de referencia para datasets de cámaras trampa: https://lila.science/datasets/caltech-camera-traps

Características verificadas:

243,100 imágenes capturadas en 140 ubicaciones de cámara distintas en el suroeste de Estados Unidos.

21 categorías de animales (más la clase "vacío"), con aproximadamente 66,000 anotaciones de bounding box disponibles para las imágenes con animal presente.

Aproximadamente el 70 % de las imágenes están vacías (activaciones falsas del sensor de movimiento: viento, vegetación, cambios de luz).

El dataset incluye una partición oficial (eccv_train / eccv_val) diseñada específicamente para distinguir entre generalización dentro de las mismas ubicaciones de cámara y generalización a ubicaciones de cámara nunca vistas — usar esta partición oficial para el experimento del punto 3 de los entregables.

Nota. LILA BC agrega decenas de datasets de cámaras trampa de todo el mundo (incluyendo Sudamérica). Un grupo que lo desee puede, como extensión opcional, incorporar un segundo dataset de otra región geográfica del catálogo de LILA BC (https://lila.science/datasets) para un experimento de generalización entre-datasets adicional al de entre-ubicaciones.

Entregables Requeridos

1. Modelo YOLO ajustado con decisiones de entrenamiento completamente documentadas (resolución de entrada, estrategia de aumento de datos, manejo explícito de las imágenes vacías como clase de fondo).

2. Evaluación cuantitativa: mAP@0.5 y mAP@0.5:0.95 sobre el conjunto de prueba, con desglose por especie, señalando explícitamente el efecto del desbalance entre especies comunes y especies con pocos ejemplos de entrenamiento.

3. Experimento de generalización entre ubicaciones de cámara: usando la partición oficial `eccv_train` / `eccv_val`, comparar el desempeño en ubicaciones vistas durante el entrenamiento frente a ubicaciones completamente nuevas. Reportar la brecha y discutir evidencia de que el modelo esté aprendiendo el fondo de la escena en vez de rasgos del animal (por ejemplo, mediante Grad-CAM sobre el backbone de detección).

4. Análisis de robustez ante oclusión y tamaño del objeto: particionar el conjunto de prueba por nivel estimado de oclusión (bajo/medio/alto) y por tamaño relativo del bounding box, y reportar la caída de desempeño entre grupos.

5. Implementación del módulo de monitoreo ecológico con demostración: a partir de una secuencia de fotogramas de una cámara no vista en entrenamiento, generar un reporte tabular de actividad por especie y por periodo de tiempo.

6. Discusión breve (media página) sobre el uso responsable de IA en conservación: el costo relativo de un falso negativo (una especie amenazada no detectada y excluida de las decisiones de manejo)

frente a un falso positivo (tiempo de un especialista desperdiciado revisando una detección incorrecta), y el riesgo de desplegar un modelo entrenado en una región en una locación geográfica distinta sin validación local.

Informe (PDF, formato NeurIPS) + enlace al repositorio de GitHub entregados a través de la plataforma del curso. Las entregas tardías serán penalizadas con un 10 % por día. El código debe ejecutarse de extremo a extremo con un único comando documentado en el README, sobre una especificación de entorno proporcionada (`requirements.txt` o `environment.yml`). Grupos de **5 estudiantes**.
Fecha de entrega y presentación: 30 de octubre del 2026, en clase (aproximadamente 5 semanas a partir de la asignación del examen).