Clasificación multietiqueta de anomalías de rodilla con CNN 2.5D y supervisión débil multilingüe

Chilón Cruzado Josué
Concepción Tiza Miguel Ángel
Neyra Dianderas Enzo Israel
Tello Guerra Omar Salvador
Alexander Vladimir Paco Cornejo

Universidad Nacional de Ingeniería (UNI)
Unidad de Posgrado
Facultad de Ingeniería Industrial y de Sistemas
Lima, Perú

Abstract

Se ejecutó una comparación factorial de ocho variantes de clasificación de doce hallazgos con CNN propia y ResNet-50, BCE/focal y dos tratamientos del ruido textual. Los 600 estudios incluyen 58 expertos reservados para evaluación. El AUC macro oficial quedó definido para las doce etiquetas. El baseline previamente fijado obtuvo AUC macro de doce etiquetas 0.578 sobre 12 etiquetas y F1 macro 0.361. Se auditaron predicciones y checkpoints y se generaron explicaciones para tres hallazgos. La muestra pequeña, el ruido lingüístico y una única semilla limitan las conclusiones.

1. Motivación y trabajos relacionados

Las imágenes y los reportes de RSNA constituyen fuentes complementarias de supervisión [5]. Una etiqueta ausente en el reporte no implica que un radiólogo haya descartado el hallazgo. El objetivo es evaluar cuánto afecta esta diferencia a la clasificación, manteniendo independiente la selección del modelo respecto de los estudios expertos.

ResNet introduce conexiones residuales para facilitar la optimización de redes profundas [1]. Se utiliza su implementación oficial como backbone preentrenado y se implementa una cabeza multietiqueta propia. Focal loss reduce la contribución de ejemplos fáciles [3]; aquí se adapta a doce salidas binarias, con pesos por frecuencia calculados únicamente en entrenamiento. La supervisión débil requiere distinguir entre reglas, abstenciones y etiquetas verificadas [6]; este trabajo no implementa el modelo generativo de Snorkel. Grad-CAM proporciona una visualización de la sensibilidad espacial [7], sin establecer que las regiones activadas tengan significado clínico causal.

2. Datos y separación experimental

Se validaron 4407 estudios y 24371 descriptores. La muestra efectiva tiene 434 estudios de entrenamiento, 108 de validación débil y 58 expertos. Se comprobaron hashes, identificadores y decodificación de 22954 DICOM. La caché coincide byte a byte con sus originales. Planos: {'Sagittal': 600}. Grupos de escritura de la muestra: {'Latin/mixed': 532, 'Greek': 65, 'Cyrillic': 3}.

El esquema observado en los CSV contiene 4 407 estudios y 58 estudios con doce etiquetas binarias completas. Se seleccionan hasta 600 estudios: todos los expertos y una muestra de reportes compatibles con el léxico. La selección usa una puntuación de rareza multietiqueta y semilla 42; no garantiza

Preprint.

positivos para etiquetas sin evidencia textual. Las particiones se realizan por StudyInstanceUID; ningún corte de un estudio se distribuye entre entrenamiento, validación y evaluación.

Los estudios no expertos se dividen en entrenamiento y validación débil, aproximadamente 80/20. La versión final asigna cuotas de positivos por etiqueta a validación, conservando evidencia positiva en entrenamiento. Una primera ejecución utilizó una asignación por rareza que dejó Lateral OA sin positivos débiles en entrenamiento (0 frente a 14 en validación). Se conservó esa ejecución, se corrigió la partición usando exclusivamente etiquetas débiles y se repitió toda la matriz. Los mismos 58 expertos se evaluaron en ambas ejecuciones; la cohorte final no constituye una nueva prueba externa nunca consultada. Las cuotas no se ajustaron por resultados expertos. Los expertos se utilizan exclusivamente para evaluación y para medir el acuerdo de las reglas fijadas previamente. No se cambia el léxico, el umbral ni los hiperparámetros tras observar esa evaluación. Los CSV no proporcionan un identificador de paciente transversal. La auditoría de los PatientID disponibles en DICOM no detectó intersecciones entre particiones, pero su carácter anonimizado no permite garantizar independencia de personas reales entre estudios.

Se prefiere una serie sagital sensible a líquido con supresión grasa. Cualquier alternativa queda registrada. Los DICOM se ordenan por geometría y se verifican orientación, identificadores y discontinuidades. La alternativa basada en InstanceNumber genera una advertencia. Se aplica la transformación de modalidad, corrección MONOCHROME1 y escalado por percentiles 0.5/99.5 del volumen. Se toman ocho grupos de tres cortes contiguos, redimensionados a 224×224. Los tres cortes actúan como canales de entrada; no representan color RGB real.

3. Extracción y tratamiento de ruido

El léxico cubre términos en inglés, español, francés, alemán, neerlandés, portugués, italiano, turco, griego, búlgaro, croata, chino y tailandés. Es una cobertura de vocabulario, no una demostración de competencia lingüística equivalente. Las cláusulas, entidades vecinas y ventanas locales limitan el alcance de las negaciones. Incertidumbre o afirmaciones contradictorias producen abstención. Una afirmación explícita recibe peso 0.9; una etiqueta no mencionada en un reporte compatible recibe 0.2; un reporte sin entidades reconocidas queda completamente enmascarado. Estos valores son pesos heurísticos, no probabilidades calibradas.

La tasa de desacuerdo se calcula por etiqueta entre predicciones textuales comparables y etiquetas expertas, junto con su cobertura. Se presenta por separado para todas las reglas y para confianza $\geq 0{,}8$. El grupo de escritura del texto sirve para auditar cobertura y no se interpreta como idioma o centro de origen.

4. Arquitecturas y pérdidas

La CNN propia tiene cuatro bloques Conv–GroupNorm–ReLU–MaxPool con 32, 64, 128 y 256 canales. Tras el pooling global se aplica dropout 0.2 y una capa lineal de doce logits. La implementación contiene 391 980 parámetros entrenables. La alternativa usa ResNet-50 con pesos ImageNet locales y ajusta todo el backbone. Su encoder y cabeza suman 23 532 620 parámetros entrenables; se usan los pesos oficiales ImageNet V2 de torchvision, verificados mediante su SHA-256. En ambos casos se promedian los logits de los ocho grupos y se aplica sigmoid por etiqueta.

Con m_{ij} como peso de supervisión y y_{ij} como etiqueta observada:

$$\mathcal{L}_{BCE} = \frac{\sum_{ij} m_{ij}[-y_{ij} \log p_{ij} - (1 - y_{ij}) \log(1 - p_{ij})]}{\max(1, \sum_{ij} m_{ij})}. \tag{1}$$

Para focal loss se multiplica cada término por $\alpha_{t,j}(1 - p_{t,ij})^2$. Los pesos positivos se calculan como $1 - \text{prevalencia}_j$ y se limitan al intervalo $[0{,}1, 0{,}9]$. En la variante filtrada, la prevalencia se calcula después de excluir las etiquetas de confianza inferior a 0.8. La alternativa de alta confianza conserva únicamente etiquetas con confianza $\geq 0{,}8$; el filtro se aplica por etiqueta. Se excluiría un estudio totalmente sin supervisión; en esta ejecución se conservan los 434 estudios de entrenamiento y los 108 de validación. Para sinovitis, el filtro deja 140 etiquetas observadas en entrenamiento, todas positivas: no aporta negativos explícitos para ese hallazgo y no equivale a supervisión limpia.

5. Protocolo experimental

La matriz factorial comprende dos arquitecturas, dos pérdidas y dos estrategias de ruido: ocho experimentos. Todos usan semilla 42, AdamW [4], tasa 3×10^{-4}, weight decay 10^{-4}, batch 4, hasta 50 épocas y parada temprana con paciencia 10 sobre pérdida de validación débil. Los checkpoints incluyen optimizador, AMP, generadores y estados aleatorios. La repetibilidad numérica entre hardware y versiones deberá verificarse; una semilla no la garantiza. La pérdida de cada época promedia por estudio las pérdidas normalizadas de sus minibatches; la validación mantiene orden fijo. No se aplican aumentos de imagen en esta comparación base.

El umbral de clasificación 0.5 se fija antes de evaluar como baseline simétrico. Se reportan precisión, recall, F1 y AUC por etiqueta. El AUC macro oficial se informa solamente si las doce etiquetas tienen ambas clases; un promedio parcial se identifica explícitamente y no sustituye la métrica oficial. Precisión, recall y F1 usan la convención zero_division=0; un cero por ausencia de predicciones positivas se interpreta junto con el soporte, no como evidencia de rendimiento estable. El análisis de prevalencia documenta las etiquetas poco frecuentes y la comparación focal/BCE mide una estrategia de mitigación. La pequeña evaluación experta limita especialmente las estimaciones de hallazgos raros.

6. Resultados e interpretabilidad

Tabla 1: Ocho variantes con el mismo conjunto experto. ND no se sustituye por el promedio parcial.

Variante	Épocas	Mejor	AUC 12	AUC parcial	F1 macro
CNN/bce/pond.	48	38	0.5776	0.5776	0.3610
CNN/bce/filtro	23	13	0.5130	0.5130	0.4535
CNN/focal/pond.	29	19	0.5723	0.5723	0.4961
CNN/focal/filtro	23	13	0.5204	0.5204	0.4253
ResNet/bce/pond.	12	2	0.6189	0.6189	0.3614
ResNet/bce/filtro	11	1	0.6020	0.6020	0.4513
ResNet/focal/pond.	12	2	0.6199	0.6199	0.5056
ResNet/focal/filtro	12	2	0.5877	0.5877	0.4863

Tabla 2: Baseline CNN/BCE/ponderación fijado previamente. Evaluación de 58 estudios, umbral 0,5.

Hallazgo	Positivos	AUC	Precisión	Recall	F1
ACL	24	0.6777	0.5000	0.7500	0.6000
MCL	9	0.5646	0.1667	0.5556	0.2564
Medial Meniscus	26	0.5385	0.4182	0.8846	0.5679
Lateral Meniscus	23	0.4348	0.2857	0.0870	0.1333
Medial OA	15	0.6605	1.0000	0.0667	0.1250
Lateral OA	11	0.7331	0.0000	0.0000	0.0000
PF OA	21	0.6718	1.0000	0.0476	0.0909
Effusion	35	0.5478	0.6034	1.0000	0.7527
Synovitis	27	0.4946	0.4694	0.8519	0.6053
Baker's	12	0.5236	0.2432	0.7500	0.3673
Contusion	19	0.6167	0.3600	0.9474	0.5217
Fracture	18	0.4681	0.2593	0.3889	0.3111

Tabla 3: Positivos y porcentaje sobre 434 estudios de entrenamiento, incluidas abstenciones en el denominador. La ausencia de mención recibe peso 0,2; no es negación experta. Filtro obs. cuenta etiquetas observadas, no estudios.

Hallazgo	Train + (%)	Val +	Gold +	Filtro obs.	Filtro +
ACL	143 (32.9 %)	42	24	226	143
MCL	102 (23.5 %)	39	9	189	102
Medial Meniscus	158 (36.4 %)	47	26	222	158
Lateral Meniscus	127 (29.3 %)	41	23	233	127
Medial OA	35 (8.1 %)	12	15	51	35
Lateral OA	10 (2.3 %)	4	11	36	10
PF OA	45 (10.4 %)	18	21	123	45
Effusion	282 (65.0 %)	77	35	318	282
Synovitis	140 (32.3 %)	41	27	140	140
Baker's	145 (33.4 %)	43	12	206	145
Contusion	129 (29.7 %)	39	19	146	129
Fracture	124 (28.6 %)	42	18	182	124

Tabla 4: Comparación diagnóstica de reglas congeladas con los 58 expertos; observados/58 expresa cobertura.

Hallazgo	Todas obs.	Desacuerdo	Filtro obs.	Desacuerdo
ACL	50	0.1600	28	0.0714
MCL	53	0.0755	21	0.1429
Medial Meniscus	54	0.3704	21	0.1905
Lateral Meniscus	52	0.2885	16	0.1250
Medial OA	54	0.2407	5	0.2000
Lateral OA	54	0.2037	1	0.0000
PF OA	54	0.3333	16	0.1875
Effusion	53	0.3962	45	0.3111
Synovitis	54	0.3148	15	0.2667
Baker's	54	0.1852	19	0.3158
Contusion	51	0.2941	15	0.4667
Fracture	49	0.1429	18	0.1667

Tabla 5: Cobertura del extractor en todos los 4.349 reportes no expertos. Escritura no identifica idioma ni centro; Thai tiene solo tres casos.

Escritura	Reportes débiles	Compatibles	Cobertura
Latin/mixed	3811	3488	0.9152
Cyrillic	217	209	0.9631
Greek	318	239	0.7516
Thai	3	3	1.0000

En esta evaluación se dispone de AUC para 12 de los doce hallazgos. El AUC macro de doce etiquetas de las variantes varía entre 0.513 y 0.620; F1 macro varía entre 0.361 y 0.506. Estos intervalos describen la matriz ejecutada y no son intervalos de confianza. No se elige una variante para despliegue por estos resultados de evaluación. Las curvas muestran el criterio aplicado para elegir cada checkpoint; no se comparan los valores absolutos de BCE y focal como si fueran la misma escala. Comparaciones pareadas por arquitectura y tratamiento del ruido: CNN/bce/pond.: diferencia focal menos BCE de AUC -0.005 y de F1 macro +0.135; CNN/bce/filtro: diferencia focal menos BCE de AUC +0.007 y de F1 macro -0.028; ResNet/bce/pond.: diferencia focal menos BCE de AUC +0.001 y de F1 macro +0.144; ResNet/bce/filtro: diferencia focal menos BCE de AUC -0.014 y de F1 macro +0.035. Con una semilla y una cohorte experta pequeña, estas diferencias no establecen superioridad general. La mitigación del desbalance debe evaluarse por hallazgo y soporte, incluyendo posibles pérdidas de precisión al elevar recall. El umbral 0,5 permanece fijo aun cuando una variante produce probabilidades mal calibradas. La distribución tras el filtro explica qué etiquetas conservan positivos y negativos explícitos; no se interpreta el filtrado como limpieza perfecta. Las figuras 1–3 presentan la discriminación y las curvas completas.

Medial OA y Lateral OA tienen respectivamente 35/434 (8.1 %) y 10/434 (2.3 %) positivos débiles en entrenamiento. En ResNet con ponderación, cambiar BCE por focal eleva el recall experto de Medial OA de 0.133 a 0.867 y F1 de 0.222 a 0.473, mientras la precisión baja de 0.667 a 0.325. Para Lateral OA, recall pasa de 0 a 0.182 y F1 de 0 a 0.222, pero AUC disminuye de 0.683 a 0.644. Esta mitigación modifica el compromiso al umbral fijo; no mejora uniformemente la discriminación de hallazgos raros. Los soportes expertos de 15 y 11 positivos limitan la estabilidad de estas cifras.

El baseline cualitativo de la figura 4 se fija como CNN propia, BCE y ponderación, evitando seleccionarlo por el conjunto experto. Los mapas se calculan respecto del logit de cada hallazgo y muestran el grupo de cortes con mayor activación media. En los tres casos mostrados, la probabilidad supera 0.5 y la etiqueta experta es positiva; esto no hace que su localización sea correcta. La inspección gráfica del caso LCA muestra una respuesta amplia y zonas periféricas, sin un foco que permita atribuir inequívocamente la señal al ligamento. En menisco medial, la respuesta cubre de forma difusa el tejido visible y no delimita una región meniscal selectiva. En derrame, los focos destacados son periféricos e incluyen fondo fuera del tejido; tampoco ofrecen evidencia convincente de localización del hallazgo. La heurística de máximo promedio seleccionó grupos extremos: 7 para LCA y 0 para menisco y derrame, en índices de 0 a 7. Este criterio puede privilegiar extensión del mapa y fondo en lugar de una estructura relevante; es una limitación del protocolo de visualización, no una localización clínica validada. Los ocho mapas por caso se conservan en archivos NPZ para permitir revisar el volumen muestreado completo. Estas observaciones son exploratorias: no hay regiones objetivo anotadas, métricas de localización ni revisión radiológica profesional registrada. La resolución del último bloque de la CNN es 14×14; interpolar a 224×224 suaviza el mapa sin añadir precisión anatómica. El color se normaliza por grupo de cortes, por lo que su intensidad no compara causalmente los tres hallazgos. Una evaluación posterior debería confrontar cada mapa con regiones marcadas por un especialista y añadir falsos positivos y falsos negativos, sin cambiar esta evaluación final ni seleccionar ejemplos por apariencia.

7. Discusión, sesgo y limitaciones

La calidad de supervisión depende de la cobertura del léxico, abreviaturas y alcance de la negación. La identificación de una escritura no equivale a determinar el idioma: el grupo latino reúne varias lenguas y textos mixtos. Incluso cuando una entidad se reconoce, una construcción coordinada, una negación distante, terminología local o un matiz de incertidumbre pueden producir errores. Una traducción literal tampoco demuestra equivalencia de criterios clínicos. El desacuerdo de las reglas debe leerse junto con la cobertura: una regla selectiva puede aparentar mejor acuerdo al abstenerse en los casos difíciles. Los 58 expertos no permiten validar de forma sólida todas las combinaciones de idioma, centro y hallazgo; los CSV no identifican de manera fiable los 16 centros ni su geografía.

La selección por rareza busca cobertura de positivos y modifica la distribución respecto al universo de estudios. Las métricas no son estimaciones de prevalencia poblacional, y el filtrado adicional por confianza puede concentrar ciertos estilos de reporte. Las imágenes asociadas a textos con menor cobertura tienen menos supervisión, de modo que una desigualdad lingüística puede convertirse en desigualdad de aprendizaje visual. La ponderación preserva evidencia de baja confianza, pero también

introduce falsos negativos al tratar la ausencia de mención como un negativo débil. El filtro elimina esa evidencia y puede dejar hallazgos con muy pocos negativos explícitos.

El riesgo de despliegue consiste en aprender correlaciones de adquisición y de anotación. Una normalización por volumen no elimina diferencias de equipos, secuencias o poblaciones. Son necesarias etiquetas expertas adicionales estratificadas por idioma y centro, auditoría de negación por hablantes competentes y evaluación externa con revisión profesional. El presente ejercicio no acredita un sistema apto para uso clínico. Los mapas de activación ofrecen indicios espaciales y no sustituyen esa revisión. Una normalización uniforme no elimina diferencias entre protocolos de adquisición. Usar una sola serie y un muestreo 2.5D puede omitir hallazgos visibles en otros planos. La validación débil comparte el mecanismo de ruido con entrenamiento y puede favorecer las mismas reglas erróneas. El análisis de acuerdo es diagnóstico y no mide sensibilidad clínica en una población independiente. Los reportes y las imágenes permanecen en el equipo local; no se publican con el código.

8. Reproducibilidad y trabajo pendiente

El código, la configuración congelada y los comandos se documentan en MRI_RUN.md. La versión de entrega se identifica en MRI_DELIVERY.md y en la rama `codex/mri-delivery` del repositorio del curso:

`https://github.com/miguelsff/maestria-ia-uni-ciclo-2-redes-neuronales`

El notebook se ejecuta leyendo los resultados persistidos, con los flags de entrenamiento desactivados. La caché local de Docker contiene copias de las series elegidas verificadas por SHA-256; los originales se mantienen montados en solo lectura. Las métricas se recalculan a partir de las predicciones persistidas; esta auditoría no repite inferencia. Se verifica la selección del checkpoint contra las curvas registradas. La prueba de reanudación verifica igualdad exacta de los parámetros con una ejecución continua, en un fixture controlado; no demuestra igualdad entre versiones o equipos distintos.

Tabla 6: Tiempo de entrenamiento y evaluación, y máximo de memoria asignada por PyTorch; no equivalen al consumo total del dispositivo.

Variante	Segundos	VRAM tensor GiB
CNN/bce/pond.	115.5191	1.0720
CNN/bce/filtro	54.7096	1.0738
CNN/focal/pond.	70.3960	1.0730
CNN/focal/filtro	56.4852	1.0738
ResNet/bce/pond.	67.0683	1.7379
ResNet/bce/filtro	60.8994	1.7352
ResNet/focal/pond.	68.6879	1.7352
ResNet/focal/filtro	68.8144	1.7352

Las guías de habilidades procedimentales orientaron la preparación y la evaluación [2]; no constituyen validación experimental. La autoría corresponde a los cinco integrantes del grupo. La revisión técnica y visual de esta versión no sustituye la aprobación editorial de sus autores, que queda pendiente. No se registra validación clínica ni revisión radiológica profesional.

9. Conclusiones

La matriz factorial muestra que arquitectura, pérdida y tratamiento del ruido afectan de forma distinta la discriminación y las decisiones al umbral fijo. Focal mejora algunos recalls de hallazgos raros a costa de precisión, sin una ventaja uniforme en AUC. El filtrado elimina supervisión incierta pero también puede eliminar todos los negativos explícitos de una etiqueta. Los resultados sobre 58 expertos reutilizados, una sola semilla y mapas sin validación de localización sustentan una comparación exploratoria, no una recomendación clínica ni una selección de modelo para despliegue.

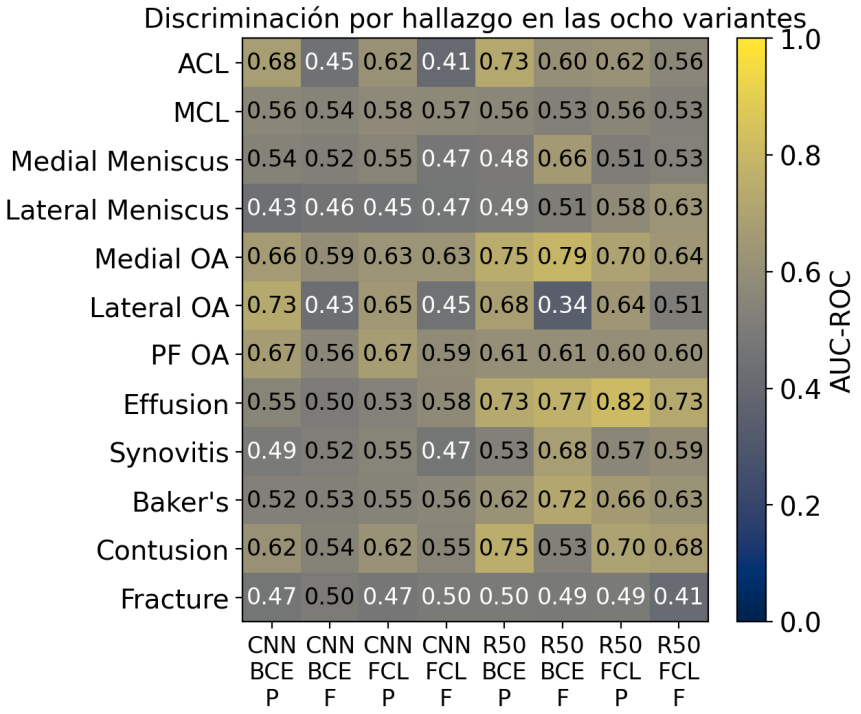


Figura 1: AUC por hallazgo y variante: CNN propia y R50 (ResNet-50); FCL: focal; P: ponderación; F: filtro. Las cifras y ND también están disponibles en metrics_all_labels.csv.

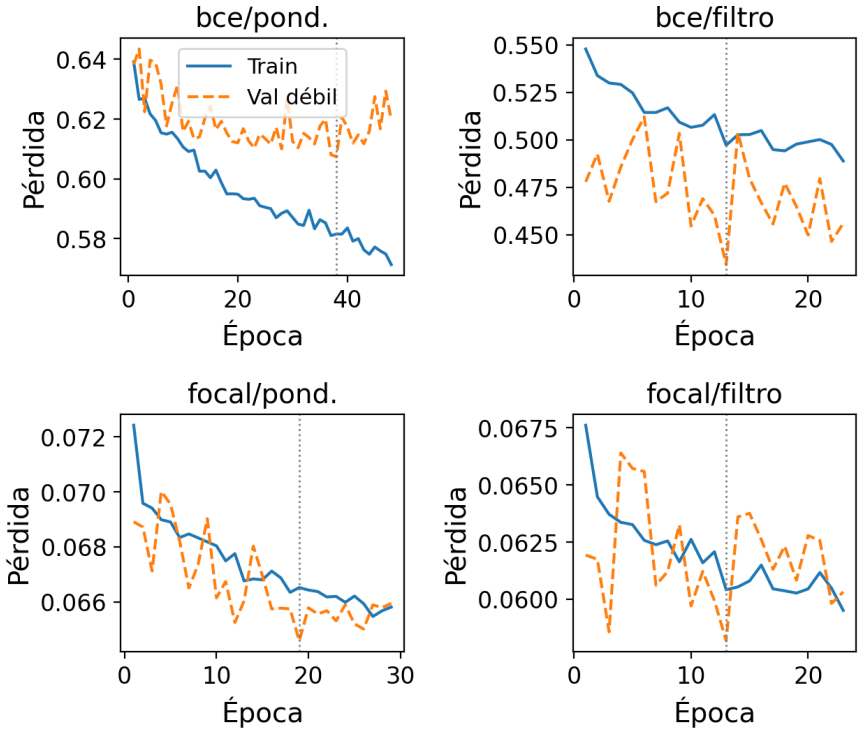


Figura 2: Curvas completas de la CNN propia. La línea vertical marca el checkpoint elegido. Las escalas dependen de la pérdida y no deben compararse como una misma magnitud.

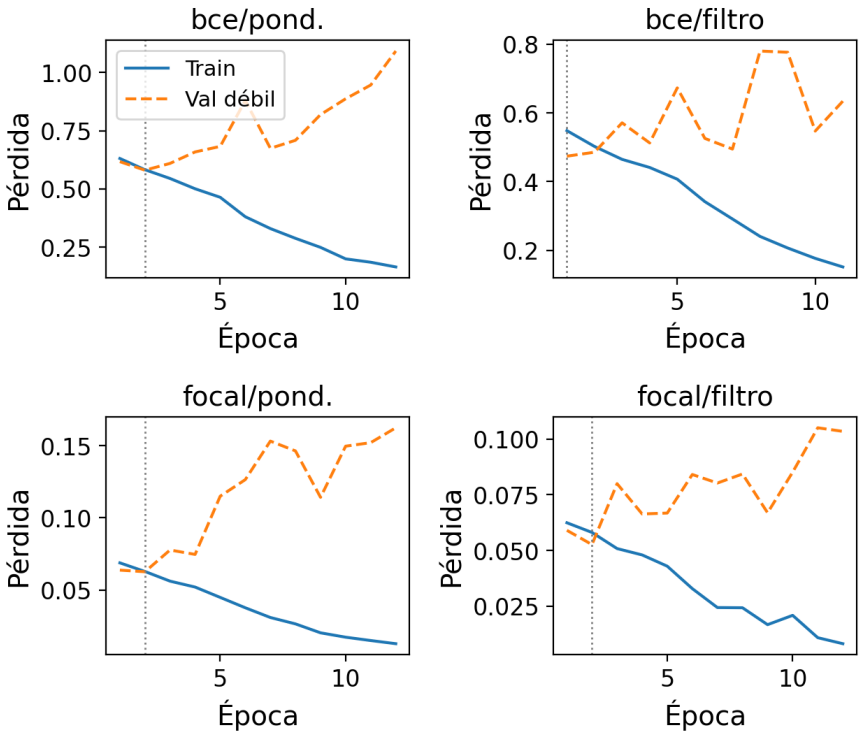


Figura 3: Curvas completas de ResNet-50. La selección utiliza únicamente pérdida de validación débil, con paciencia de diez épocas.

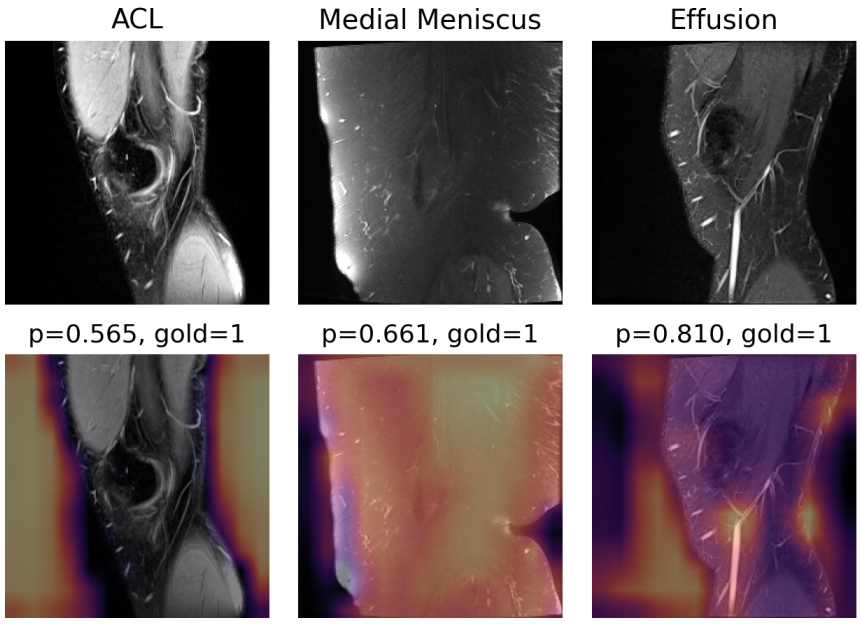


Figura 4: Grad-CAM del baseline para tres positivos expertos, con probabilidades al umbral fijo. Casos fijados por orden del manifiesto; no elegidos por apariencia ni por acierto.

Referencias

[1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016. https://arxiv.org/abs/1512.03385.

[2] Timothy Kassis, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner. Scientific agent skills: A library of procedural knowledge for research agents, 2026. https://arxiv.org/abs/2609.00065.

[3] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *ICCV*, 2017. https://arxiv.org/abs/1708.02002.

[4] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *ICLR*, 2019. https://arxiv.org/abs/1711.05101.

[5] Radiological Society of North America. Rsna knee abnormality detection: Data. https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/data, 2026.

[6] Alexander Ratner, Stephen H. Bach, Henry Ehrenberg, Jason Fries, Sen Wu, and Christopher Ré. Snorkel: Rapid training data creation with weak supervision, 2017. https://arxiv.org/abs/1711.10160.

[7] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *ICCV*, 2017. https://arxiv.org/abs/1610.02391.