Detección de fauna con YOLOv8s y monitoreo de actividad en cámaras conocidas y nuevas

Chilón Cruzado Josué
Concepción Tiza Miguel Ángel
Neyra Dianderas Enzo Israel
Tello Guerra Omar Salvador
Alexander Vladimir Paco Cornejo
Universidad Nacional de Ingeniería (UNI)
Unidad de Posgrado
Facultad de Ingeniería Industrial y de Sistemas
Lima, Perú

Abstract

Se ajustó YOLOv8s de Ultralytics sobre CCT20 con catorce categorías animales y 1 000 fotografías vacías adicionales de entrenamiento. Las noventa imágenes de la muestra de etiquetas cuentan con revisión humana. El entrenamiento terminó en 39 épocas y seleccionó el checkpoint de la época 29 mediante validación. La mAP50:95 fue 0.4358 en cámaras conocidas y 0.2625 en cámaras nuevas, con una brecha de 0.1733. Se calcularon ocho grupos de intervalos con 200 remuestreos de secuencias cada uno y se generaron doce casos Grad-CAM, tres sin señal espacial positiva. Un módulo propio resumió 1 853 fotografías de una cámara nueva. Una revisión independiente aceptó 582 de 600 objetos muestreados de cámaras nuevas. La mAP50:95 por oclusión baja, media y alta fue 0.0875, 0.0271 y 0.0244, respectivamente, con intervalos de 200 remuestreos por nivel y alcance condicionado a esa submuestra; no se afirma representatividad poblacional.

1. Motivación y trabajos relacionados

Las cámaras trampa producen fotografías con fondos relativamente persistentes. Recognition in Terra Incognita [1] estudia la generalización a ubicaciones nuevas. El objetivo es localizar animales y resumir actividad, conservando la distinción entre detecciones, fotografías e individuos. YOLO plantea la predicción conjunta de cajas y clases [4]; se utiliza el detector YOLOv8s existente de Ultralytics [6], sin atribuir su arquitectura específica al artículo original de YOLO. La evaluación usa AP de COCO [2], la optimización usa AdamW [3] y la inspección exploratoria utiliza Grad-CAM [5].

2. Benchmark, depuración y revisión humana

Se usan las imágenes reducidas y las cinco particiones oficiales de CCT20 ECCV: train, cis_val, cis_test, trans_val y trans_test. Las 57 864 imágenes originales del benchmark no equivalen a toda la colección de Caltech. Las categorías empty y car no son clases animales. Una imagen explícitamente vacía genera etiquetas vacías; se excluyen vehículos sin animales y fotografías con alguna anotación animal sin caja completa, evitando convertir objetos sin localización en negativos.

El train ECCV no contiene fotos empty. Se añadieron 1 000 negativos del train oficial de la colección completa: ocho cámaras externas a las veinte del benchmark, 125 secuencias por cámara y un fotograma por secuencia. La selección usó metadatos y semilla 42, excluyó todos los identificadores y

Preprint.

secuencias ECCV y conservó hashes y comprobaciones del proveedor. No se reasignaron fotografías reservadas. Estos negativos tienen resolución original, distinta de las fotos positivas reducidas; ambos grupos se redimensionan a 640 durante la inferencia.

Las cajas se normalizan con las dimensiones originales de metadatos. Se verifican límites, unidades e independencia de fotografías y secuencias frente a entrenamiento; las secuencias compartidas con cis_val se eliminan de validación y las cámaras trans son disjuntas de train. El conjunto elegible contiene 48 254 imágenes. La tabla de inventario informa fotos, fondos, cámaras y secuencias por partición.

Miguel aprobó las noventa fotografías de la muestra visual. La corrección de una tercera ave conserva las otras dos cajas y coincide con el recuadro humano $(681,\ 333,\ 707,\ 381)$ en la referencia de 960×700 píxeles. Las notas individuales de fotos correctas son opcionales. Las decisiones, hashes y migración se conservan sin modificar los holdouts ni los fotogramas de monitoreo.

Los originales permanecen en solo lectura. Para 1 000 JPEG de los negativos añadidos, V6 elimina únicamente espacios posteriores a un marcador final existente en una copia de trabajo. No recomprime y comprueba igualdad exacta de los píxeles decodificados. El comprobador instalado de Ultralytics aceptó las 48 254 imágenes sin descartar cajas.

3. Detector y entrenamiento

El detector principal y sus pesos preentrenados proceden de Ultralytics. La preparación, evaluación, Grad-CAM y agregación ecológica son módulos propios. El ajuste conserva catorce clases, resolución 640, batch 16, semilla 42, AdamW con tasa inicial $3 \times 10{-}4$, weight decay $10{-}4$, máximo 50 épocas y paciencia 10. Mosaic tiene probabilidad 1, el giro horizontal 0.5 y el vertical 0; se conservan los argumentos efectivos registrados por Ultralytics. La parada temprana se produjo en la época 39 y el mejor checkpoint fue el de la 29. La selección utiliza cis_val depurado y no optimiza sobre los tests.

Se conserva el desbalance observado: cinco cajas de fox y nueve de badger en train, frente a 2 514 de opossum. cis_val carece de deer y fox; trans_test carece de deer. Una categoría sin referencia mantiene AP indefinida. Mosaic y una media global no sustituyen la evaluación por categoría ni justifican afirmar buen desempeño en fauna rara.

4. Protocolo de evaluación

Se calcula mAP50 y mAP50:95 en cámaras conocidas y nuevas, con AP y soporte por categoría. La inferencia para AP conserva confianza $\geq 0{,}001$, NMS IoU 0.7 y máximo 300 detecciones por imagen. La brecha es $\mathrm{mAP}_{cis} - \mathrm{mAP}_{trans}$; también se compara el mismo conjunto de trece clases con soporte en ambos tests. El tamaño relativo usa área de caja sobre área de imagen: pequeño $< 1\ \%$, mediano 1–5 % y grande $> 5\ \%$. Un sistema virtual de 1000×1000 preserva IoU y permite evaluar estas áreas relativas sin confundirlas con tamaños COCO absolutos.

Los intervalos percentiles del 95 % usan 200 remuestreos de secuencias completas por grupo, semilla 42 y el checkpoint fijo. Son condicionales a las cámaras observadas; no miden variación entre entrenamientos ni incertidumbre de nuevas regiones. La revisión independiente de oclusión muestreó 600 de los 17 620 objetos elegibles de trans_test. Se aceptaron 582: 340 low, 69 medium, 48 high y 125 ambiguous. Baja significa más de 75 % del cuerpo visible; media, 25–75 %; alta, menos de 25 %. Visibilidad incierta o truncamiento se conserva como ambiguous. Se excluyeron 18 casos sin nivel por decisión expresa del responsable; las notas se aceptaron como opcionales y 398 permanecen vacías. El caso 121 conserva medium según Miguel, sin agregar nota; la discrepancia inicial se preserva en los retornos originales.

Cada nivel supera el mínimo protocolario de 30 objetos. La AP no ponderada reutiliza predicciones y checkpoint V6, sin entrenamiento ni inferencia nuevos. Mantiene los 18 647 fotogramas de trans_test, incluidos 1 778 vacíos y sus posibles falsos positivos. Las cajas no revisadas, excluidas, ambiguas o de otro nivel son regiones crowd ignoradas: sus coincidencias de la misma clase pueden ignorarse bajo las reglas COCO; las detecciones no absorbidas conservan su posibilidad de ser falsos positivos. Reducir los positivos evaluables sin retirar esos fotogramas cambia la tarea de evaluación. Estas mAP no son directamente comparables con la mAP global V6 ni con una evaluación restringida a fotos revisadas. El anexo independiente conserva el detalle por especie, decisiones y trazabilidad.

5. Resultados e interpretabilidad

Tabla 1: Inventario efectivo después de depurar anotaciones y secuencias. Train oficial no contiene imágenes empty. V2 añade 1.000 fondos de ocho cámaras oficiales adicionales de entrenamiento.

Partición	Fotos	Fondos	Cámaras	Secuencias
train	12399	1000	18	5733
val	2543	995	10	980
cis_test	13073	1180	10	5378
trans_val	1592	61	1	589
trans_test	18647	1778	9	7438

Tabla 2: Evaluación COCO global con el mismo checkpoint, 101 puntos de recall y máximo 300 detecciones por imagen.

Partición	Clases con soporte	mAP50	mAP50:95
cis_test	14	0.6878	0.4358
trans_test	13	0.4231	0.2625

Tabla 3: Rendimiento por especie: cis_test. ND indica ausencia de referencia.

Especie	Cajas	AP50	AP50:95
opossum	4008	0.8844	0.4932
raccoon	980	0.8970	0.5917
squirrel	510	0.7037	0.3696
bobcat	772	0.8561	0.6084
skunk	161	0.9355	0.6175
dog	723	0.6932	0.4858
coyote	1180	0.9035	0.6901
rabbit	1556	0.8874	0.5534
bird	752	0.6435	0.3334
cat	1528	0.8749	0.5866
badger	4	0.0112	0.0056
deer	139	0.5146	0.3383
fox	2	0.0000	0.0000
rodent	146	0.8236	0.4269

Tabla 4: Rendimiento por especie: trans_test. ND indica ausencia de referencia.

Especie	Cajas	AP50	AP50:95
opossum	4659	0.8826	0.4590
raccoon	4769	0.7549	0.4959
squirrel	777	0.3644	0.1957
bobcat	1974	0.6268	0.4176
skunk	273	0.4402	0.2840
dog	958	0.7377	0.4994
coyote	1901	0.6746	0.4788
rabbit	722	0.5912	0.2994
bird	179	0.0687	0.0383
cat	1366	0.2829	0.1842
badger	15	0.0736	0.0583
deer	0	ND	ND
fox	1	0.0000	0.0000
rodent	26	0.0021	0.0016

Tabla 5: Comparación con el mismo conjunto de clases con soporte en ambos tests: opossum, raccoon, squirrel, bobcat, skunk, dog, coyote, rabbit, bird, cat, badger, fox, rodent.

Partición	mAP50	mAP50:95
cis_test	0.7011	0.4432
trans_test	0.4231	0.2625

Tabla 6: Intervalos percentiles de mAP50:95 mediante remuestreo de secuencias completas, modelo fijo. No cuantifican variación entre semillas ni entre nuevas regiones.

Grupo	IC95 inferior	IC95 superior	Réplicas
cis_test: Global	0.4288	0.4785	200
trans_test: Global	0.2538	0.3023	200
cis_test: small_lt_1pct	0.2452	0.3377	200
cis_test: medium_1_to_5pct	0.4516	0.5232	200
cis_test: large_gt_5pct	0.5312	0.5720	200
trans_test: small_lt_1pct	0.1430	0.1942	200
trans_test: medium_1_to_5pct	0.3085	0.3440	200
trans_test: large_gt_5pct	0.2572	0.3597	200

Tabla 7: Robustez por área relativa en cis_test: menor de 1 %, 1–5 %, mayor de 5 %.

Tamaño relativo	Cajas	AP50	AP50:95
Pequeño	1149	0.5631	0.2792
Mediano	8925	0.7516	0.4683
Grande	2387	0.7583	0.5480

Tabla 8: Robustez por área relativa en trans_test: menor de 1 %, 1–5 %, mayor de 5 %.

Tamaño relativo	Cajas	AP50	AP50:95
Pequeño	1922	0.3216	0.1619
Mediano	12169	0.5272	0.3220
Grande	3529	0.4024	0.2870

La brecha global de mAP50:95 es de 17.33 puntos porcentuales. Con las mismas trece categorías, la mAP pasa de 0.4432 a 0.2625: la diferencia no desaparece al igualar la cobertura taxonómica. Las tablas conservan las clases sin soporte como ND.

Tabla 9: Oclusión en la submuestra aceptada de trans_test. AP no ponderada sobre todos sus fotogramas; IC95 por bootstrap de secuencias, 200 réplicas por nivel. Los 125 ambiguos no son un cuarto grupo de AP.

Nivel	Cajas	mAP50 [IC95]	mAP50:95 [IC95]
Baja	340	0.1582 [0.1457, 0.2117]	0.0875 [0.0809, 0.1217]
Media	69	0.0582 [0.0389, 0.1035]	0.0271 [0.0184, 0.0523]
Alta	48	0.0563 [0.0329, 0.1164]	0.0244 [0.0160, 0.0567]

La mAP50:95 baja 6.04 puntos porcentuales de low a medium y 6.31 de low a high. La diferencia medium–high es 0.28 puntos, con intervalos ampliamente superpuestos. Los grupos tienen 13, 10 y 11 categorías con soporte, respectivamente; no se aisló el efecto causal de la oclusión ni se estimó un intervalo de la diferencia.

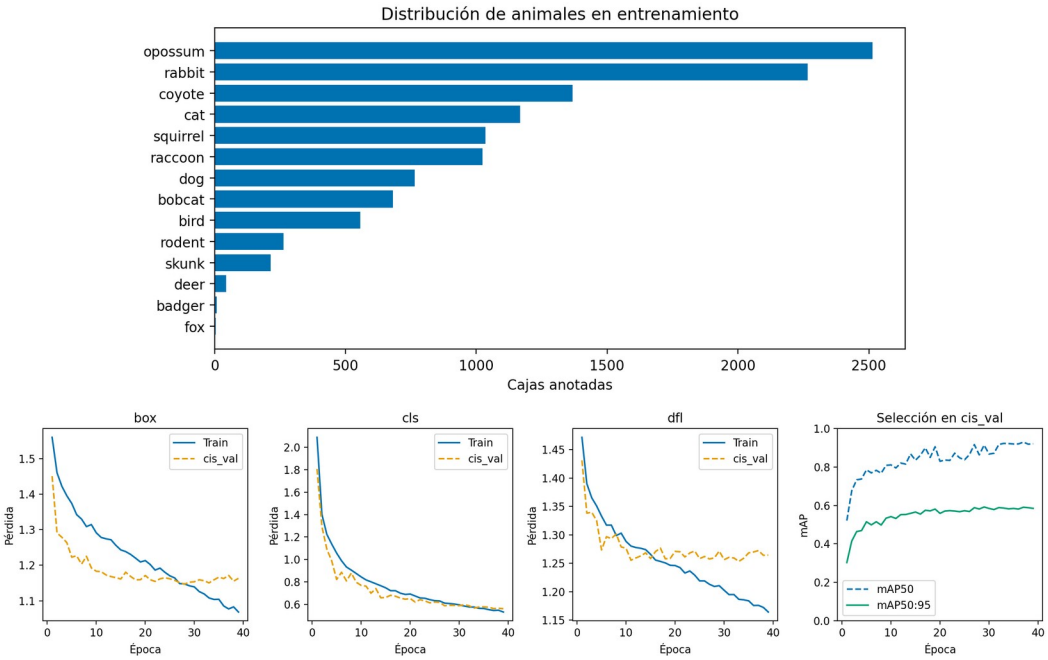


Figura 1: Distribución de cajas de entrenamiento y evolución de pérdidas y mAP en cis_val. El mejor checkpoint corresponde a la época 29; las curvas no utilizan los tests.

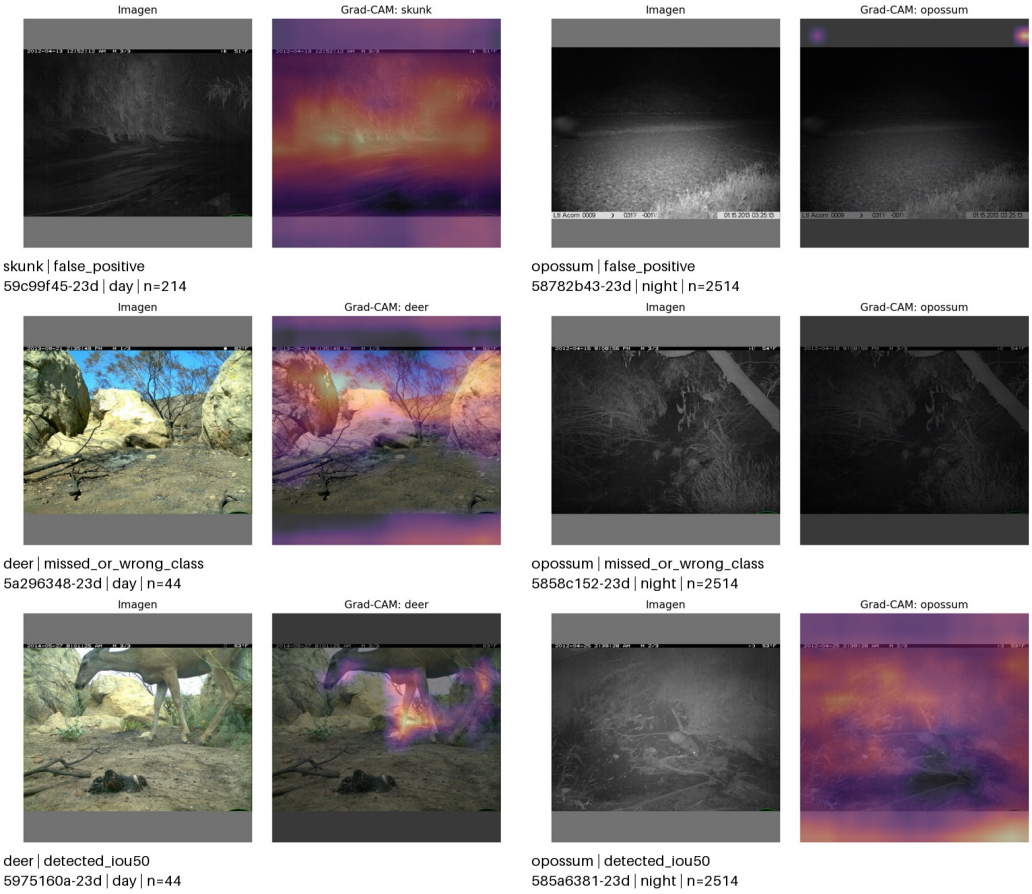


Figura 2: Seis casos en cámaras conocidas. Se conserva el mapa plano de cis_test_3 como limitación del método; no se interpreta como evidencia de ausencia de atención. Los rótulos day/night son aproximaciones de metadatos.

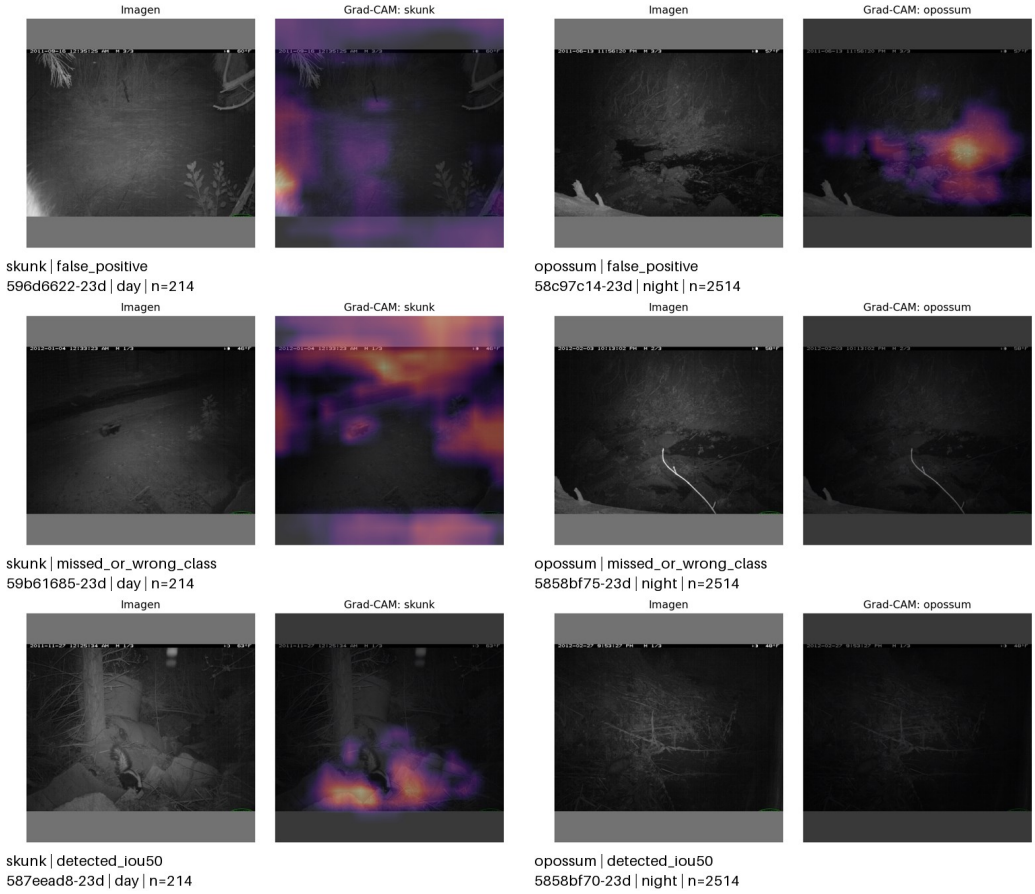


Figura 3: Seis casos en cámaras nuevas. trans_test_3 y trans_test_5 tienen mapas planos. Las zonas resaltadas en fondos y bordes no demuestran causalidad ni memorización.

Grad-CAM fija una propuesta y el score diferenciable de una clase antes de NMS, con una capa del backbone y el letterbox declarados. Hay seis casos por test que cubren aciertos a IoU $\geq 0{,}5$, omisiones o clase incorrecta y falsos positivos en fondos. La selección prioriza categorías raras y frecuentes mediante reglas deterministas. Tres mapas tienen rango $[0,\ 0]$ y no ofrecen una explicación espacial. Los rótulos day/night proceden de la hora en metadatos; varias fotos rotuladas day son oscuras y de apariencia infrarroja. No se infiere iluminación real de ese rótulo ni se presenta una comparación cuantitativa por iluminación.

6. Demostración de monitoreo

La cámara trans 7 aporta todos sus 1 853 fotogramas oficiales, incluidos los excluidos de la evaluación de cajas. Con confianza $\geq 0{,}25$, 1 420 fotografías contienen detecciones y la tasa predicha de fotos vacías es 23.37 %. Se resumen 211 fechas con fotografías y once categorías detectadas. Se conserva la zona horaria sin especificar de los metadatos; no se inventan fechas ni tiempo de exposición. La ráfaga de demostración tiene tres fotogramas consecutivos del 8 de mayo de 2011: los dos primeros no tienen detecciones y el tercero registra opossum.

Tabla 10: Actividad predicha de la cámara 7: primeros diez días de la cohorte completa de esa cámara.

Día	Fotos	Con fauna	Especies	Vacías
2011-05-07	1	0	0	1.0000
2011-05-08	9	2	1	0.7778
2011-05-10	3	1	1	0.6667
2011-05-20	3	3	1	0.0000
2011-05-25	2	1	1	0.5000
2011-06-03	3	1	2	0.6667
2011-06-05	3	3	1	0.0000
2011-06-17	2	1	1	0.5000
2011-06-19	6	3	2	0.5000
2011-06-20	15	14	2	0.0667

Tabla 11: Resumen de todos los días de la cámara de demostración. Las detecciones no representan individuos únicos.

Especie	Detecciones	Fotos con especie
bird	92	91
bobcat	49	49
cat	45	43
coyote	477	449
deer	1	1
dog	33	32
opossum	649	643
rabbit	81	80
raccoon	90	85
skunk	10	10
squirrel	38	34

Tabla 12: Secuencia completa con fecha de captura válida. Identificadores completos disponibles en activity_sequence.csv.

Fotograma	Captura	Detecciones	Especies
1	2011-05-08 11:39:22	0	ND
2	2011-05-08 11:39:23	0	ND
3	2011-05-08 11:39:24	1	opossum

Una foto con varias cajas de la misma categoría se cuenta una vez en fotos con categoría. bird y rodent agrupan taxones, por lo que el conteo de categorías no mide diversidad biológica completa. Las detecciones no representan individuos únicos y la tasa predicha de vacíos no equivale a una revisión humana de ausencia.

7. Discusión y uso responsable

La mAP50:95 disminuye de 0.4358 en cámaras conocidas a 0.2625 en cámaras nuevas. Los intervalos del 95 % son $[0{,}4288,\ 0{,}4785]$ y $[0{,}2538,\ 0{,}3023]$, respectivamente. La comparación con trece categorías comunes conserva una brecha de 18.08 puntos porcentuales. Es consistente con dificultad de transferencia entre cámaras, pero los intervalos no son una prueba causal del efecto del fondo ni estiman variación entre semillas o nuevas regiones. El modelo fue seleccionado en validación; los resultados de prueba se conservan como evaluación de ese ajuste.

Los objetos pequeños tienen mAP50:95 de 0.2792 en cis_test y 0.1619 en trans_test. En cámaras nuevas, los medianos alcanzan 0.3220 y los grandes 0.2870; el rendimiento no crece monótonamente con el área. La composición de categorías y escenas difiere entre estratos, por lo que el tamaño no se aísla como una causa mediante estas tablas. bird pasa de AP50:95 0.3334 a 0.0383 y rodent de 0.4269 a 0.0016, con 179 y 26 cajas de prueba trans, respectivamente. Estas caídas necesitan evaluación

específica. Fox obtiene AP cero con solo dos referencias cis y una trans, después de cinco cajas de entrenamiento; badger tiene nueve cajas de entrenamiento. Esos soportes impiden considerar la media global como evidencia de detección fiable de categorías raras.

Los doce casos Grad-CAM incluyen nueve mapas con variación espacial y tres planos. En algunos aciertos se resaltan partes del animal; los falsos positivos también resaltan vegetación, suelo o bordes de la entrada. Estas observaciones son exploratorias. Los mapas planos de opossum no permiten localizar contribuciones positivas para la propuesta y capa fijadas. No se reemplazaron los casos ni se modificó la técnica congelada para obtener visualizaciones favorables. Los rótulos de horario no son mediciones de iluminación, especialmente cuando una fotografía oscura se rotula day. La galería no estima la frecuencia de estos patrones ni demuestra dependencia causal del fondo. Para comprobarla harían falta intervenciones controladas sobre las imágenes.

La submuestra aceptada muestra menor AP en oclusión media y alta que en baja. Sus intervalos del 95 % remuestrean las 7 438 secuencias de trans_test, con 200 réplicas por nivel, semilla 42 y modelo fijo. No capturan desacuerdo entre revisores, notas faltantes, variación del entrenamiento ni cámaras futuras. Los 18 casos excluidos son falta de respuesta humana: las proporciones de los 582 aceptados son descriptivas y no se reutilizan intervalos poblacionales ni la garantía de planificación de los 600 originales. La composición de especies, el soporte y el tratamiento crowd impiden atribuir toda diferencia a la oclusión. La demostración de la cámara 7 muestra una agregación reproducible de fotografías; sus 1 420 fotos con detecciones y once categorías no son un censo de individuos.

La ampliación v2 incorpora solo negativos en ocho cámaras adicionales; no agrega animales de esas cámaras. El fondo puede entonces ayudar a distinguir la procedencia de los negativos. La resolución original de esa cohorte también difiere de las imágenes ECCV reducidas. El resultado se describe como entrenamiento ampliado y no como reproducción estricta del train ECCV. Una comparación futura necesitaría otra ejecución controlada, conservando los mismos tests y sin ajustar a sus resultados. Un falso negativo de una especie amenazada puede invisibilizar su presencia en decisiones de manejo, mientras que un falso positivo consume tiempo de revisión y puede crear registros de distribución incorrectos. El umbral 0.25 de la demostración no se considera óptimo para todas las especies ni para una decisión de conservación.

Debe mantenerse revisión profesional de observaciones sensibles, documentar esfuerzo de muestreo y validar en cámaras y hábitats del destino. Una tasa baja de detecciones también puede reflejar fallos del sensor o cambio de iluminación. Los conteos de imágenes no estiman población ni individuos. La separación entre cámaras ayuda a evaluar generalización, pero el entrenamiento en Estados Unidos no justifica despliegue en Amazonía o Andes sin validación local.

Para registros sensibles se deben conservar fotografía, caja, confianza y decisión del especialista. La etiqueta automática no constituye un registro confirmado. La revisión debe considerar el costo de omisión, el de identificación incorrecta y la capacidad del equipo de campo. Un umbral global no sustituye un protocolo por especie ni el control del esfuerzo por cámara. Los soportes, exclusiones y categorías sin referencia deben acompañar cada comparación: una AP indefinida no demuestra ausencia biológica. La galería orienta nuevas muestras, pero no mide frecuencia de errores. Las decisiones de manejo conservan responsabilidad humana y deben admitir corrección cuando aparezcan evidencias adicionales.

8. Reproducibilidad y alcance

Se conservaron 44 fuentes experimentales congeladas, manifiestos, exclusiones, argumentos efectivos, pesos, predicciones y métricas. Las dependencias están fijadas y se verificaron CUDA, NMS, gradientes y AMP en RTX 5090. La prueba pequeña de reanudación comprueba época, optimizador y paciencia; no afirma equivalencia bit a bit. El entrenamiento científico y esa prueba tienen salidas independientes.

Un límite de memoria interrumpió el cálculo inicial de intervalos después del entrenamiento. La recuperación ejecutó cada grupo en un proceso nuevo con la función original, conservando semilla, réplicas, datos y modelo. No repitió el entrenamiento; las pruebas verificaron igualdad exacta de resultados en casos de referencia. Los ocho grupos V6 quedaron guardados. El notebook final consulta esos resultados y la oclusión aceptada, verifica hashes y conserva la demostración y los doce casos Grad-CAM. El original V6 permanece intacto; el anexo de oclusión es independiente. El código está

en https://github.com/miguelsff/maestria-ia-uni-ciclo-2-redes-neuronales. Los resultados de oclusión complementan la evaluación V6 con el alcance muestral declarado. No se registra aprobación del docente ni envío a la plataforma.

Referencias

[1] Sara Beery, Grant Van Horn, and Pietro Perona. Recognition in terra incognita. In *ECCV*, 2018. https://arxiv.org/abs/1807.04975.

[2] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft coco: Common objects in context. In *ECCV*, 2014. https://arxiv.org/abs/1405.0312.

[3] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *ICLR*, 2019. https://arxiv.org/abs/1711.05101.

[4] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *CVPR*, 2016. https://arxiv.org/abs/1506.02640.

[5] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *ICCV*, 2017. https://arxiv.org/abs/1610.02391.

[6] Ultralytics. Ultralytics yolov8: Model documentation. https://docs.ultralytics.com/models/yolov8/, 2026.