UNIVERSIDAD NACIONAL DE INGENIERÍA — Facultad de Ingeniería Industrial y de Sistemas — Unidad de Posgrado

Laboratorio 13: Modelos de Difusión

Implementar DDPM, DDIM y *classifier-free guidance* desde cero

Redes Neuronales y Aprendizaje Profundo
Aldo Camargo Fernández-Baca, Ph.D.

Clase asociada	Clase 13: Modelos de Difusión
Modalidad	Grupos de hasta 3 estudiantes
Duración	**2 horas** (máximo)
Entorno	Google Colab con GPU (T4 o superior)
Material	`Lab13_Difusion_inicio.ipynb` (notebook de inicio), notas y notebook de la Clase 13
Fecha de entrega	_____
Puntaje total	20 puntos

Objetivos del laboratorio

1. Implementar y verificar el **proceso directo** en forma cerrada y el **posterior** $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$.
2. Implementar la pérdida L_{simple} (Algoritmo 1) y el muestreador **DDPM** (Algoritmo 2), y comprobar que un modelo de difusión **no colapsa** en los datos donde la GAN de la Clase 11 sí lo hacía.
3. Implementar **DDIM** y medir el compromiso entre número de pasos, tiempo y calidad (FID) en Fashion-MNIST.
4. Implementar **classifier-free guidance** y medir la curva **fidelidad–diversidad** en función de la escala de guía w.

Antes de la sesión (10 min, sin GPU)

Relea las Secciones 2–4, 7.2 y 8.2 de las notas de la Clase 13: en el laboratorio implementará las ecuaciones (4), (9), (16), el Algoritmo 2, (26) y (29). No necesita modelos preentrenados: todo se entrena durante la sesión (dos entrenamientos de ≈4 min cada uno con T4).

Plan de la sesión

Parte	Contenido	Tiempo	Puntos
0	Preparación: datos, redes y clasificador auxiliar	10 min	—
1	Proceso directo, posterior y horarios	15 min	3
2	Pérdida y muestreo DDPM; anillo de 8 gaussianas	25 min	5
3	DDIM en Fashion-MNIST: pasos vs. calidad vs. tiempo	30 min	5
4	*Classifier-free guidance*: fidelidad vs. diversidad	30 min	5
5	Preguntas de cierre	10 min	2
	Total	**120 min**	**20**

Cómo funciona el notebook

Solo complete las celdas marcadas con `# TODO`. Debajo de cada función hay una **prueba automática**: no avance hasta que imprima `OK`. Varias pruebas usan un **oráculo**: para datos gaussianos $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{m}, s^2\mathbf{I})$ el ruido óptimo $\boldsymbol{\epsilon}_\theta$ tiene fórmula exacta (función `oraculo_gaussiano`), así que un muestreador correcto debe devolver exactamente esa gaussiana. Así se separan los errores de *su código* de los errores *de la red*.

Consejo de organización

Lance la celda de entrenamiento de la Parte 3 en cuanto llegue a ella: mientras corre (≈4 min), Colab le deja *escribir* `muestrear_ddim` en la celda siguiente (se ejecutará en cola). Haga lo mismo con el entrenamiento condicional de la Parte 4 y `eps_guiado`. Repártanse el trabajo: un integrante programa, otro prepara la tabla y las respuestas.

Parte 0. Preparación

Abra `Lab13_Difusion_inicio.ipynb` en Colab con GPU y ejecute la Parte 0 sin modificarla. Define:

- los horarios `horario_lineal` y `horario_coseno`, la utilidad `e(v, t, x)` (toma v_t por elemento del lote con la forma correcta para multiplicar a `x`) y `rapido(modelo)` (muestreo en media precisión);
- `MLPRuido` y `UNet`, idénticas a las del notebook de clase (la U-Net acepta una etiqueta opcional `y`);
- Fashion-MNIST normalizado a $[-1, 1]$ y un **clasificador auxiliar** (≈90 % de exactitud) cuyas características se usan para el **FID** y la **diversidad intra-clase**, como en la sección G8 de la Clase 11.

La última celda imprime el FID entre dos mitades del conjunto de prueba: **anótelo**, es el piso que ningún modelo puede bajar con $N = 1000$ muestras.

```
q_sample(h, x0, t, eps) # Parte 1 (ec. 4)
posterior(h, x0, xt, t) # Parte 1 (ec. 9)
perdida_simple(modelo, h, x0, **kw) # Parte 2 (ec. 16, Algoritmo 1)
muestrear_ddpm(modelo, h, forma, sigma='beta', xT=None, **kw) # Algoritmo 2
muestrear_ddim(modelo, h, forma, pasos=50, eta=0.0, xT=None, **kw) # ec. 26
eps_guiado(modelo, x, t, y, w) # Parte 4 (ec. 29)
```

Estas son las funciones que usted escribe. **Convención de índices:** el índice de Python `t = 0, …, T-1` corresponde al paso $t+1$ de las notas; $T = 1000$ con el horario lineal de DDPM.

Parte 1. Proceso directo, posterior y horarios

Tarea 1.1 Forma cerrada [1 pts]

Implemente `q_sample`: $\mathbf{x}_t = \sqrt{\bar\alpha_t}\,\mathbf{x}_0 + \sqrt{1-\bar\alpha_t}\,\boldsymbol{\epsilon}$. La prueba compara media y varianza con 300 pasos de la cadena iterada sobre 200 000 copias de un punto.

Tarea 1.2 Posterior [1 pts]

Implemente `posterior`, que devuelve $(\tilde{\boldsymbol{\mu}}_t, \tilde\beta_t)$ según la ec. (9). La prueba verifica la identidad (10), $\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}}\big(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar\alpha_t}}\boldsymbol{\epsilon}\big)$, y que $\tilde\beta_t \le \beta_t$.

Tarea 1.3 Horarios [1 pts]

Implemente `analizar_horario`: para los horarios lineal y coseno, (a) el paso donde $\mathrm{SNR}(t) = \bar{\alpha}_t/(1-\bar{\alpha}_t)$ cruza 1 y (b) cuántos pasos tienen $\mathrm{SNR} < 10^{-2}$. Grafique $\log_{10}\mathrm{SNR}$. ¿Qué fracción de la cadena "se desperdicia" con cada horario? Relacione con el argumento de Nichol & Dhariwal (notas §2.3).

Parte 2. Pérdida y muestreo DDPM sobre 8 gaussianas

Los datos son el anillo de 8 gaussianas pequeñas ($\sigma = 0.05$, radio 2) de la sección G4 de la Clase 11, donde la GAN desincronizada colapsaba a uno o dos modos.

Tarea 2.1 La pérdida simple [1 pts]

Implemente `perdida_simple` (Algoritmo 1): $t \sim \mathcal{U}\{0,\dots,T-1\}$ y $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0},\mathbf{I})$ *por ejemplo*, $\mathbf{x}_t$ con `q_sample`, y el MSE entre $\boldsymbol{\epsilon}$ y `modelo(x_t, t, **kw)`. La prueba exige pérdida ≈ 1 con un modelo que predice cero y, con el oráculo, el **mínimo teórico** $\frac{1}{T}\sum_t \frac{\bar{\alpha}_t s^2}{\bar{\alpha}_t s^2 + 1 - \bar{\alpha}_t} > 0$: ni el mejor modelo posible lleva L_{simple} a cero, porque $\boldsymbol{\epsilon}$ no se puede adivinar exactamente a partir de $\mathbf{x}_t$.

Tarea 2.2 Muestreo DDPM [1.5 pts]

Implemente `muestrear_ddpm` (Algoritmo 2) con dos opciones de varianza: `sigma='beta'` ($\sigma_t^2 = \beta_t$) y `sigma='btil'` ($\sigma_t^2 = \tilde{\beta}_t$). Sin ruido en el último paso. Con el oráculo de $\mathcal{N}\big((2,-1),\, 0.5^2\mathbf{I}\big)$ sus muestras deben tener esa media y desviación (± 0.03).

Tarea 2.3 ¿Colapsa un modelo de difusión? [1.5 pts]

El notebook entrena `MLPRuido` con *su* pérdida ($\approx$1 min) y muestrea 3000 puntos con *su* muestreador. Haga la figura (datos en gris, muestras en color) con los modos cubiertos y la fracción de muestras dentro de algún modo (`evaluar_anillo`). Compare con la GAN de la Clase 11 (G4) y explique la diferencia en términos de lo que optimiza cada modelo.

Tarea 2.4 $\sigma_t^2 = \beta_t$ vs. $\sigma_t^2 = \tilde{\beta}_t$ [1 pts]

Muestree el mismo modelo con ambas varianzas (misma semilla). Compare modos cubiertos, fracción en modos y la desviación de las muestras alrededor de su centro más cercano (los datos tienen 0.05). ¿Confirma la afirmación de Ho et al. de que dan "resultados similares"? ¿Cuál dispersa más las muestras y por qué?

Parte 3. DDIM en Fashion-MNIST

Primero lance el entrenamiento

La primera celda de la Parte 3 entrena la U-Net incondicional con *su* `perdida_simple` durante `EPOCAS = 5` ($\approx$4 min con T4; precisión mixta y EMA ya incluidas). Si su GPU es más lenta, use `EPOCAS = 3` y anótelo en el informe.

Tarea 3.1 DDIM [1.5 pts]

Implemente `muestrear_ddim` con la ec. (26) sobre la subsecuencia `seq` de `pasos` índices (ya calculada). Atención al último paso: después del último índice, $\bar{\alpha}_{\text{prev}} = 1$. La prueba usa el oráculo con $S = 1000$ pasos para $\eta = 0$ y $\eta = 1$ (debe recuperar la gaussiana exacta), verifica que con $\eta = 0$ el muestreo es **determinista**, y muestra qué pasa con 100, 50 y 20 pasos: aun con el ruido exacto, la desviación de las muestras **se encoge**. Anote esos valores; los necesitará en la Tarea 3.2.

Tarea 3.2 Pasos vs. calidad vs. tiempo [2 pts]

Con el modelo EMA, genere $N = 1000$ imágenes con cada configuración de la Tabla 1 (misma semilla), mida el tiempo y el FID. Entregue: la tabla completa, una figura de FID vs. evaluaciones

de la red por muestra (eje x logarítmico) y 20 muestras por configuración. ¿Con cuántos pasos DDIM iguala a DDPM? ¿Por qué $\eta = 1$ con 50 pasos es peor que $\eta = 0$ con 50 pasos? Relacione la caída de calidad con pocos pasos con lo que observó en la prueba del oráculo (Tarea 3.1). Compare con la tendencia que reportan Song, Meng & Ermon (2021).

Muestreador	**Pasos**	**Tiempo (s)**	**FID* ↓**	**Aceleración vs. DDPM**
Piso (prueba vs. prueba)	—	—		—
DDPM, $\sigma_t^2 = \beta_t$	1000			1×
DDIM, $\eta = 0$	10			
DDIM, $\eta = 0$	25			
DDIM, $\eta = 0$	50			
DDIM, $\eta = 0$	100			
DDIM, $\eta = 1$	50			

Tabla 1: DDPM vs. DDIM con el mismo modelo ($N = 1000$ muestras, Fashion-MNIST).

Tarea 3.3 Determinismo e interpolación [1.5 pts]

(a) Genere dos veces desde el mismo $\mathbf{x}_T$ con DDIM ($\eta = 0$) y con DDPM; reporte la diferencia máxima.

(b) Implemente la interpolación esférica $\text{slerp}(\mathbf{z}_1, \mathbf{z}_2, \lambda) = \frac{\sin((1-\lambda)\theta)}{\sin\theta}\mathbf{z}_1 + \frac{\sin(\lambda\theta)}{\sin\theta}\mathbf{z}_2$, con $\cos\theta = \frac{\mathbf{z}_1 \cdot \mathbf{z}_2}{\|\mathbf{z}_1\|\|\mathbf{z}_2\|}$, y genere 4 filas de 10 imágenes entre pares de ruidos, más una fila con interpolación **lineal**. Reporte la norma de los ruidos intermedios en ambos casos (compare con $\sqrt{784} = 28$) y explique la diferencia visual.

Parte 4. Classifier-free guidance

Tarea 4.1 Etiqueta vacía [0.5 pts]

Implemente `reemplazar_por_vacio(y, p, vacio)`: cada etiqueta se reemplaza por el índice 10 ($\varnothing$) con probabilidad p, de forma independiente. Luego lance el entrenamiento condicional ($p_{\text{vacío}} = 0.1$, ≈4 min).

Tarea 4.2 El ruido guiado [1 pts]

Implemente `eps_guiado` con la ec. (29), $\tilde{\boldsymbol{\epsilon}} = (1 + w)\,\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t, c) - w\,\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t, \varnothing)$, evaluando ambos términos en **una sola** pasada de la red (concatene el lote consigo mismo). La prueba comprueba que $w = 0$ da el modelo condicional y $w = -1$ el incondicional.

Tarea 4.3 La curva fidelidad–diversidad [2 pts]

Para $w \in \{0, 0.5, 1, 2, 4, 8\}$ genere 1000 imágenes (100 por clase) con DDIM ($\eta = 0$, 50 pasos) **desde el mismo ruido**, y complete la Tabla 2:

- **exactitud de clase**: fracción de muestras que el clasificador auxiliar asigna a la clase pedida;
- **diversidad relativa**: distancia media entre pares de características dentro de cada clase, dividida por la de los datos reales;
- **FID** contra el conjunto de prueba.

Grafique las tres métricas contra w, la diversidad contra la exactitud (puntos etiquetados por w), y una cuadrícula (filas = clases) para $w = 0$, 2 y 8.

w	**Exactitud de clase ↑**	**Diversidad relativa**	**FID* ↓**
0			
0.5			
1			
2			
4			
8			

Tabla 2: *Classifier-free guidance* en Fashion-MNIST (DDIM, 50 pasos, $N = 1000$).

Tarea 4.4 Análisis [1.5 pts]

En no más de media página:

(a) ¿Qué w minimiza el FID? ¿Por qué el FID empeora para w grande aunque la exactitud siga subiendo?

(b) Relacione su curva diversidad–exactitud con muestrear de $p(\mathbf{x})\, p(c \mid \mathbf{x})^{1+w}$ (notas §8). ¿A qué técnica de las GANs se parece este compromiso?

(c) ¿Qué artefactos ve con $w = 8$? ¿Qué pasaría si se entrenara con $p_{\text{vacío}} = 0$?

Parte 5. Preguntas de cierre

Tarea 5.1 Preguntas de cierre [2 pts]

Responda brevemente (3–5 líneas cada una), **usando sus propios números**:

(a) Compare el modelo de difusión con la GAN de la Clase 11 en estabilidad del entrenamiento, cobertura de modos (Tarea 2.3 vs. G4) y costo de generar una imagen (evaluaciones de la red).

(b) ¿Por qué pudo usar DDIM sin reentrenar el modelo entrenado con el Algoritmo 1? Responda con una frase sobre qué depende L_{simple}.

(c) Stable Diffusion trabaja en un espacio latente de $64 \times 64 \times 4$. Con sus tiempos de la Tabla 1, estime cuánto más lento sería muestrear directamente en $512 \times 512 \times 3$ si el costo creciera en proporción al número de valores. ¿Por qué en la práctica sería aún peor?

Qué entregar

- El notebook `Lab13_Difusion_inicio.ipynb` completo, **con todas las salidas** (todas las pruebas en `OK`) y las respuestas en las celdas *Respuesta*.
- Las Tablas 1 y 2 completas y las figuras de las Partes 2–4 (con títulos, ejes y leyendas).
- Si cambió `EPOCAS` u otro parámetro por falta de tiempo, indíquelo al inicio del notebook.

No suba los modelos ni el conjunto de datos.

Rúbrica

Parte	Criterio	Puntos
1	`q_sample` y `posterior` pasan las pruebas; análisis de horarios con números propios	3
2	Pérdida y DDPM pasan las pruebas del oráculo; figura del anillo con modos y fracción; comparación argumentada con la GAN; análisis de σ_t^2	5
3	DDIM pasa las pruebas; Tabla 1 completa con figura y muestras; determinismo; slerp vs. lineal con normas y explicación	5
4	Etiqueta vacía y guía pasan las pruebas; Tabla 2 y curvas; análisis relacionado con la teoría	5
5	Preguntas de cierre respondidas con números propios; claridad del notebook	2
	Total	**20**

Honestidad académica

Pueden usar asistentes de IA para depurar código, pero cada respuesta conceptual debe estar escrita por el grupo y todos los números reportados deben provenir de **sus propias corridas**. Modificar las pruebas automáticas para que pasen se calificará con cero en la tarea correspondiente.

Sobre la escala

Con 5 épocas, $N = 1000$ muestras y un FID calculado con un clasificador pequeño, sus números no son comparables con los publicados y tendrán varianza entre corridas. Se evalúa el análisis de las *tendencias* y su relación con la teoría, no los valores absolutos.

Referencias

[1] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. *NeurIPS*. https://arxiv.org/abs/2006.11239

[2] Nichol, A., & Dhariwal, P. (2021). Improved Denoising Diffusion Probabilistic Models. *ICML*. https://arxiv.org/abs/2102.09672

[3] Song, J., Meng, C., & Ermon, S. (2021). Denoising Diffusion Implicit Models. *ICLR*. https://arxiv.org/abs/2010.02502

[4] Ho, J., & Salimans, T. (2022). Classifier-Free Diffusion Guidance. arXiv:2207.12598.

[5] Rombach, R., et al. (2022). High-Resolution Image Synthesis with Latent Diffusion Models. *CVPR*.

[6] Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747.